Mini Project 2
Data Model and Evaluation ด้วย RapidMiner / Altair AI Studio
งานรายบุคคล 5 คะแนน

วัตถุประสงค์:

ฝึกทำ Model และ Evaluation เพื่อเตรียมตอบข้อสอบ Midterm: Data Model and Evaluation

โจทย์ Mini Project

ให้นักศึกษาหา Dataset จริงจากแหล่งข้อมูลที่น่าเชื่อถือ โดยมีข้อมูลไม่น้อยกว่า 100,000 ระเบียน และเลือกโจทย์แบบ Binary Classification ที่มี Target 2 Classes จากนั้นใช้ Auto Model ทดสอบแบบจำลองทั้ง 9 Models เปรียบเทียบผล และสรุปผลเป็นรายงานส่งอาจารย์

ข้อกำหนด

1. Dataset หลังเตรียมข้อมูลต้องมีอย่างน้อย 1,000,000 ระเบียน และระบุแหล่งที่มา/URL
2. ต้องเป็น Binary Classification และระบุ Target กับ Positive Class ให้ชัดเจน
3. ตรวจ Input ที่ใช้จริง และนำ ID/Identifier หรือข้อมูลที่ทำให้เกิด Target Leakage ออก
4. แบ่งข้อมูลเป็น Training Data และ Testing Data โดยใช้ข้อมูลทดสอบชุดเดียวกันในการเปรียบเทียบทุกโมเดล
5. ทดสอบครบทั้ง 9 Models และบันทึกผล Accuracy, Precision, Recall, F1-Score และ AUC ของแต่ละโมเดล

9 Models ที่ต้องทดสอบ

1. Naive Bayes
2. Generalized Linear Model (GLM)
3. Logistic Regression
4. Fast Large Margin
5. Deep Learning
6. Decision Tree
7. Random Forest
8. Gradient Boosted Trees (GBT)
9. Support Vector Machine (SVM)

สิ่งที่ต้องทำ

1. **Prepare Data** ตรวจ Target, Positive Class, Input, Data Type, Missing Values และนำ ID/Target Leakage ออก
2. **Build Models** เข้า Auto Model > Predict > เลือก Target/Positive Class > เลือก Inputs > ทดสอบครบ 9 Models
3. **Read Results** ทุกโมเดลให้บันทึก Accuracy, Precision, Recall, F1 และ AUC พร้อมเขียนสรุปผลสั้น ๆ 1–2 บรรทัดว่าโมเดลนั้นเด่นหรือด้อยด้านใด
4. **Read Key Models** Logistic Regression: อ่านทิศทางของ coefficient/weight; Decision Tree: ระบุ Root และอ่านเส้นทางถึง Leaf; Random Forest: ระบุ Feature Importance 3 อันดับแรก
5. **Evaluate** เลือกโมเดลที่เหมาะสมที่สุด 1 โมเดล อ่าน Confusion Matrix (TP, FP, FN, TN) และตัวอย่าง Scoring 1 ระเบียน โดยอธิบาย Prediction, Confidence และ Threshold 0.50

รูปแบบรายงาน

รายงานประกอบด้วย 5 ส่วนดังนี้

1. Dataset: ชื่อ/URL, จำนวนระเบียน, Target, Positive Class และ Input ที่ใช้
2. Model Setup: ภาพการกำหนด Predict, Target, Positive Class, Inputs และ Training/Testing
3. Model Comparison: ตารางผลครบทั้ง 9 Models และสรุปแต่ละโมเดลสั้น ๆ
4. Model Reading: Logistic Regression, Decision Tree, Random Forest และ Confusion Matrix ของโมเดลที่เลือก
5. Conclusion: เลือกโมเดลสุดท้าย 1 โมเดล พร้อมอธิบายเหตุผลจากผล Evaluation

คำถามที่ต้องตอบในรายงาน

1. Dataset นี้เป็นปัญหาอะไร? Target และ Positive Class คืออะไร?
2. มี Input กี่ตัว และตัดตัวแปรใดออกเพราะเป็น ID หรือ Target Leakage?
3. โมเดลใดมี Accuracy, Precision, Recall, F1 และ AUC สูงสุด?
4. Logistic Regression มีตัวแปรใดที่มีผลเด่น และทิศทางเป็นบวกหรือลบต่อ Positive Class?
5. Decision Tree มี Root Node คืออะไร และตัวอย่าง 1 เส้นทางจาก Root ถึง Leaf เป็นอย่างไร?
6. Random Forest มี Feature Importance 3 อันดับแรกคืออะไร?
7. จาก Confusion Matrix ของโมเดลที่เลือก ค่า TP, FP, FN และ TN เป็นเท่าใด? หากต้องการลด False Negative ควรดู Metric ใด?
8. เลือกโมเดลใดเป็น Final Model และเพราะเหตุใด? อธิบายจาก Metric และข้อผิดพลาดของโมเดล

ตารางสรุปผล 9 Models

กรอกค่าจาก Testing Data ชุดเดียวกัน และใช้ Positive Class เดียวกันทุกโมเดล

Model	Accuracy	Precision	Recall	F1	AUC	อธิบายผล
Naive Bayes						
GLM						
Logistic Reg.						
Fast Large Margin						
Deep Learning						
Decision Tree						
Random Forest						
GBT						
SVM						

สิ่งที่ต้องส่ง

1. รายงาน Word หรือ PDF ตามโครงสร้างข้างต้น
2. ภาพผลโมเดล ทั้ง 9 โมเดล พร้อมการอธิบายการแสดงผลโมเดล
3. Dataset หรือ URL ดาวน์โหลด Dataset ที่ใช้จริง

เกณฑ์คะแนน 5 คะแนน

รายการ	คะแนน
Dataset และการเตรียมข้อมูล	1.0
ทดสอบครบ 9 Models	1.5
อ่านผล Model และตารางเปรียบเทียบ	1.5
Evaluation และเลือก Final Model	1.0