

มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ

KING MONGKUT'S UNIVERSITY OF TECHNOLOGY NORTH BANGKOK

BUSINESS INTELLIGENCE

Chapter 6

Data Preparation

Asst.Prof. Sakchai Tangprasert (Ph.D. in IT)
Sakchai.t@sci.kmutnb.ac.th

Analytics and Big Data for Accountants
By Jim Lindell
© 2017 Association of International Certified Professional Accountants, Inc.

1. การเตรียมข้อมูลให้มีคุณภาพ

- ในการวิเคราะห์ข้อมูลหลาย ๆ ครั้ง มักจะนำข้อมูลมาจากหลาย Data Sources ที่มีหลาย Formats ที่แตกต่างกันมารวมกัน ซึ่งมักพบว่าข้อมูลที่มีที่มาต่างกัน มักจะยังไม่ถูกต้องเสียทั้งหมด เป็นข้อมูลคุณภาพต่ำที่ยังไม่เหมาะจะนำไปใช้งาน จำเป็นต้องมีการรวบรวมข้อมูล (Data Blending) และ การทำข้อมูลให้สมบูรณ์ (Data Cleansing) เพื่อรวบรวมและแปลงรูปแบบข้อมูลให้สอดคล้องกัน และนำไปใช้ประโยชน์ได้จริง ช่วยเปลี่ยนข้อมูลที่ไร้ค่าให้เป็นข้อมูลที่มีประโยชน์ เรียกขั้นตอนนี้ว่าการเตรียมข้อมูล (Data Preparation)

2. ข้อมูล (Data) หรือ ข้อมูลขนาดใหญ่ (Big Data)

- ข้อมูล (Data) หรือ ข้อมูลขนาดใหญ่ (Big Data) คือ สินทรัพย์ที่มีคุณค่าทางธุรกิจสมัยใหม่และโลกอนาคตอย่างแท้จริง แนวคิดใหม่ ๆ เกี่ยวกับการใช้ประโยชน์จากข้อมูล ได้เข้ามาสร้างโอกาสสำคัญให้กับธุรกิจและอุตสาหกรรมด้านต่าง ๆ จึงมีความจำเป็นในการรวบรวมและวิเคราะห์ข้อมูลเพื่อให้มีความชัดเจนและถูกต้องมากที่สุดคือสิ่งที่สำคัญที่สุด
- หากใช้ข้อมูลคุณภาพต่ำ (Low/Poor Data Quality) ผลการวิเคราะห์ก็จะไร้ประโยชน์ ข้อมูลจะบอกอะไรไม่ได้เลย ซึ่งสิ่งที่ส่งผลต่อคุณภาพข้อมูลนั้นมีหลายสาเหตุ เริ่มตั้งแต่ความผิดพลาดของมนุษย์ ไปจนถึงการรวบรวมข้อมูลก่อนนำไปใช้ทำได้ไม่ดี สิ่งเหล่านี้ลดทอนคุณค่าในตัวข้อมูล (Value Data) และ การปรับเปลี่ยนสู่ดิจิทัล (Digital Transformation) ที่ขึ้นอยู่กับข้อมูลนั้น

3. การประเมินคุณภาพของข้อมูล (Data Quality)

- การประเมินคุณภาพของข้อมูล (Data Quality) ว่ามีคุณภาพหรือไม่นั้นจะต้องใช้การสำรวจและแปลงข้อมูล โดยมักจะเริ่มจากการรวบรวมข้อมูลจากหลายแหล่ง มารวมไว้ในที่เดียวกันเพื่อความสมบูรณ์ของข้อมูลที่ส่งผลต่อการวิเคราะห์ และประสิทธิภาพของโมเดลโดยตรง พอนำข้อมูลมารวมกันไว้ที่คลังข้อมูล หรือระบบ หรือแพลตฟอร์ม (Platform) ที่เตรียมไว้แล้ว การจะประกอบหรือผนวกรวมข้อมูลแต่ละส่วนเข้าด้วยกัน ก็เป็นขั้นตอนที่ต้องตระเตรียมวิธีการพอสมควร เพราะข้อมูลจากต่างที่ก็จะต่างสายพันธุ์ แล้วยังต้องผ่านกระบวนการคัดเลือกข้อมูล จึงต้องอาศัยเครื่องมือที่ฉลาดเพื่อจัดการกับความยุ่งยากเหล่านี้เพื่อให้ได้ข้อมูลที่มีคุณภาพในรูปแบบที่เหมาะสมเพื่อนำไปใช้ประโยชน์ต่อไป

4. ตัวอย่างสาเหตุที่ทำให้คุณภาพของข้อมูลต่ำ

ข้อผิดพลาดของมนุษย์:

- เช่น เมื่อพนักงานป้อนข้อมูลด้วยมือผ่านคีย์บอร์ด อาจจะเกิดข้อผิดพลาดอย่างใดอย่างหนึ่ง เช่น พิมพ์ข้อมูลผิด กรอกรายละเอียดไม่ครบ หรือการผิดช่อง ป้อนคำที่มากหรือน้อยเกินไป ข้อมูลที่ผิดปกติ หรือ Outliers เป็นต้น

มาตรฐานการป้อนข้อมูลที่ไม่สอดคล้องกัน:

- เป็นหนึ่งในสาเหตุของคุณภาพข้อมูลที่พบบ่อยการวางมาตรฐานการป้อนข้อมูลให้เหมือนกัน ควรป้อนหรือบันทึกข้อมูลอย่างไร เช่น วิธีป้อนข้อมูลระบุเพศที่อาจพบได้หลายรูปแบบจากพนักงานแต่ละคน หรือจากสาขาต่าง ๆ เช่น Male หรือ Female, Man หรือ Woman และ M หรือ F เป็นต้น ซึ่งอาจถูกต้องในความหมายของมนุษย์ แต่คือสิ่งที่ตอมพิวเตอร์ไม่สามารถเข้าใจได้ และกลายเป็นข้อมูลที่ไร้ประโยชน์

4. สาเหตุที่ทำให้คุณภาพของข้อมูลต่ำ (ต่อ)

ขาด Data Source ที่เชื่อถือได้:

- บางครั้งเราตรวจพบความผิดพลาดในตัวข้อมูลที่ดึงมาใช้จากแหล่งอื่น และแก้ไขให้ถูกต้องในฐานข้อมูลของเรา แต่ไม่สามารถไปแก้ไขที่ต้นทางได้ รายงานที่ทำขึ้นจากข้อมูลฉบับแก้ไข ก็อาจจะขาดความน่าเชื่อถือ เช่น ปัญหาข้อมูลระบุเพศข้างต้น หากมีการแก้ไขในการรายงาน แต่ไม่มีใครตรวจสอบย้อนกลับ และตรวจสอบว่าข้อมูลถูกคลีนที่ต้นทางแล้ว ก็อาจสร้างปัญหาให้กับผู้จัดทำที่ทำให้เกิดความสับสนจากข้อมูลในรายงานกับข้อมูลจริงที่ต้นทางไม่ตรงกัน

กระบวนการรวมข้อมูลไม่ดี:

- ต้องเข้าใจว่า คุณภาพของข้อมูลอาจแตกต่างกันอย่างมากหากมีการดึงจากหลายแหล่งมารวมกัน อย่างเช่น หากมีข้อมูลซ้ำกันก็จะทำให้การวิเคราะห์บิดเบือนได้

ข้อมูลขาดการอัพเดตให้เป็นปัจจุบัน:

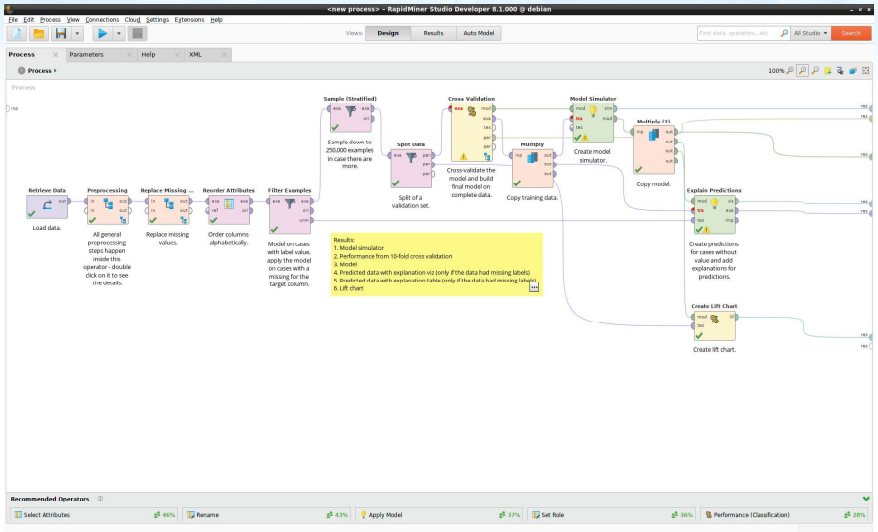
- จำเป็นจะต้องตรวจสอบให้แน่ใจว่า ไม่มีข้อมูลที่ซ้ำกัน (Duplicate), ไม่ถูกต้อง (Incorrect) หรือล้าสมัย (Outdated) ถ้าตรวจพบให้ดำเนินการแก้ไขให้ถูกต้องตามวิธีการทาง Cleaning Data Methods เสียก่อน

5. Rapidminer

- Rapidminer คือ ซอฟต์แวร์ Data Science ใช้สำหรับการเตรียมข้อมูล การเรียนรู้เครื่อง การเรียนรู้ลึก การทำเหมืองข้อความ และการวิเคราะห์การทำนาย (Predictive Analysis) ช่วยในการจัดส่งข้อมูล และลดข้อผิดพลาดจนแทบจะไม่จำเป็นต้องเขียนโค้ดเพิ่ม แต่ที่ทำให้เป็นเครื่องมือที่เหล่า Data Scientist นิยมเลือกใช้เป็นเพราะ Rapidminer มีขั้นตอนพร้อม สำหรับการทำ Data mining และ Machine learning ซึ่งรวมไปถึงการโหลดและการแปลงข้อมูล (ETL) การประมวลผลล่วงหน้าและการวาดภาพจากข้อมูล การวิเคราะห์เชิงพยากรณ์และการสร้างแบบจำลองทางสถิติ การประเมินผลและการปรับใช้ ต่าง ๆ

RAPIDMINER

6. ตัวอย่าง Rapidminer



7. การเตรียมข้อมูลด้วย Rapid Miner

- เมื่อมีการใช้งานข้อมูลจากหลายแหล่ง จึงต้องมีขั้นตอนของการรวมข้อมูลเข้าด้วยกัน รวมถึงขั้นตอนการปรับปรุงข้อมูลที่มีความผิดพลาด หรือที่นิยมเรียกกันว่า การทำความสะอาดข้อมูล (Data Cleansing) เพื่อให้ได้ข้อมูลที่มีคุณภาพ โดย Data Science Tools มีเครื่องมือสำหรับปรับปรุงคุณภาพข้อมูลอยู่ในขั้นตอน การเตรียมข้อมูล (Data Preparation) ของกระบวนการ Data Science

8. Rapid Miner Turbo Prep

- Turbo Prep มีข้อดีตรงที่ช่วยให้ผู้ใช้สามารถเตรียมข้อมูลได้ง่าย ๆ สามารถจัดการแก้ไขข้อมูลผ่านทางอินเตอร์เฟสในแบบ Step by step และยังสามารถบันทึกกระบวนการ (Process) เก็บไว้ใช้ได้ โดยจะแปลงขั้นตอนการทำงานให้กลายเป็นกระบวนการของ Rapid Miner เพื่อจะได้นำมาใช้ได้เลยทันทีในครั้งต่อไป จะได้ไม่ต้องทำงานซ้ำในขั้นตอนเดิม ๆ
- ปกติแล้ว ขั้นตอนการเตรียมข้อมูลให้พร้อมใช้สำหรับการวิเคราะห์นั้น จะใช้เวลาดำเนินการมากที่สุด เนื่องจากจะต้องมีการสำรวจข้อมูล เพื่อค้นหาข้อมูลที่เหมาะสมก่อนจะนำมาใช้ หาความเชื่อมโยงหรือสอดคล้องกันของข้อมูล รวมถึงมีการตรวจสอบความถูกต้องต่าง ๆ โดยละเอียด เพราะไม่มีทางสร้างโมเดลได้สำเร็จ หากใช้ข้อมูลที่ไร้ประโยชน์ หรือไม่สอดคล้องกัน

8. Rapid Miner Turbo Prep (ต่อ)

- ขั้นตอนการเตรียมข้อมูลมีความสำคัญมาก เป็นงานที่หนัก และต้องใช้เวลามากที่สุดเมื่อเทียบกับขั้นตอนอื่น ๆ แต่ด้วยความสามารถของ Turbo Prep ซึ่งเป็น Data Preparation Tools สำหรับใช้ในการ Blending & Cleaning Data ที่จะช่วยแปลงรูปแบบข้อมูลให้สอดคล้องกันและใช้ประโยชน์ได้จริง ช่วยเปลี่ยนข้อมูลที่ไร้ค่าให้เป็นข้อมูลที่มีประโยชน์