มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ
KING MONGKUT'S UNIVERSITY OF TECHNOLOGY NORTH BANGKOK

BUSINESS INTELLIGENCE

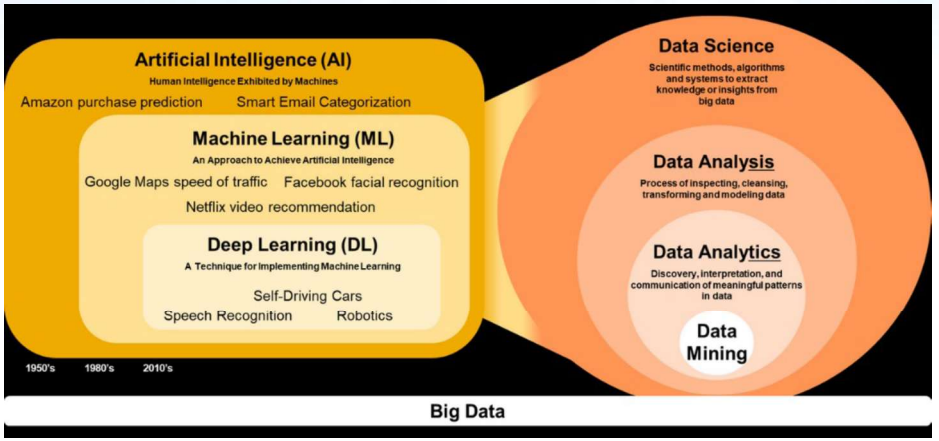
Chapter 7

Data Model

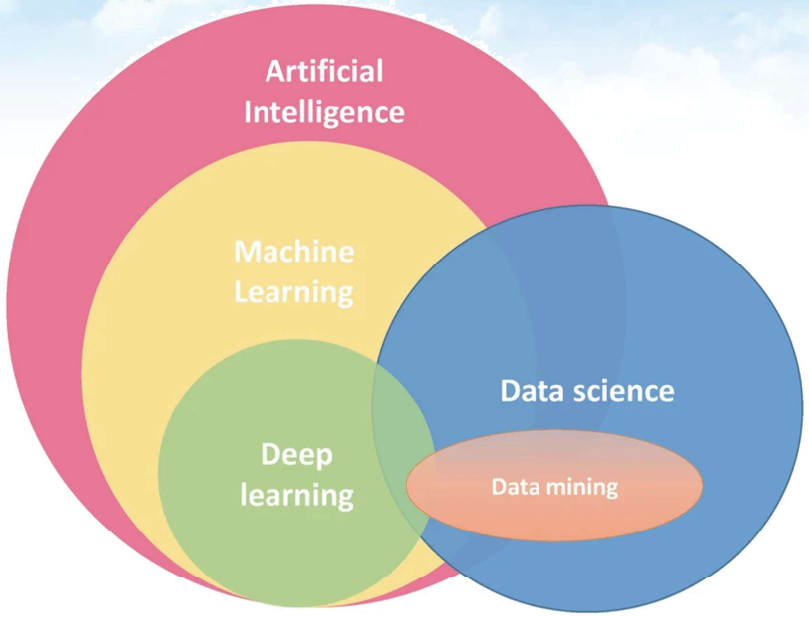
Asst.Prof. Sakchai Tangprasert (Ph.D. in IT)
Sakchai.t@sci.kmutnb.ac.th

Analytics and Big Data for Accountants
By Jim Lindell
© 2017 Association of International Certified Professional Accountants, Inc.

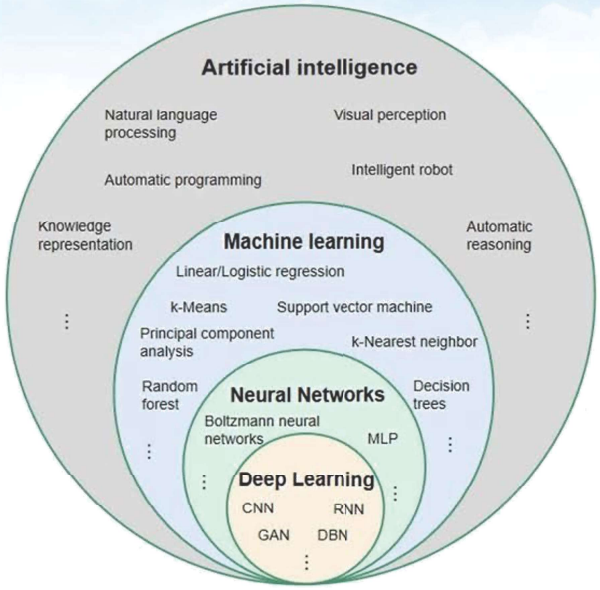
Data Science World



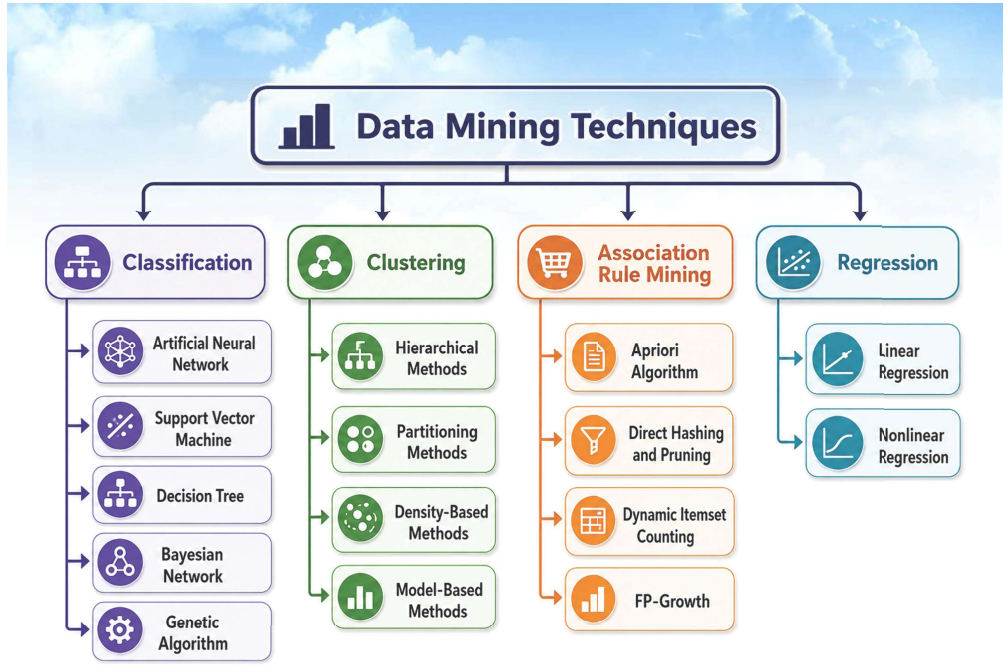
Data Science World

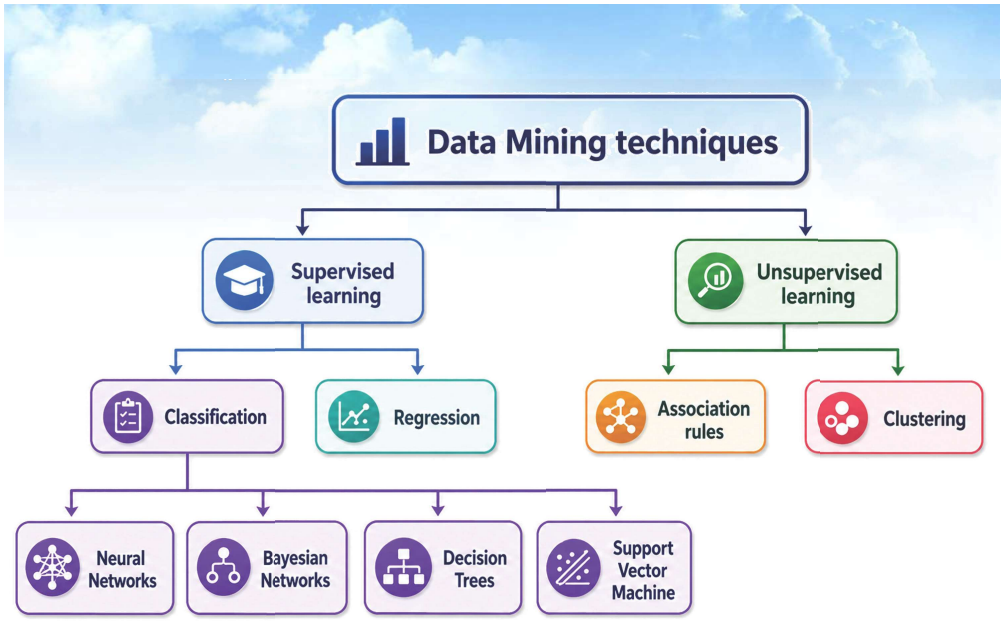


Data Science World









1. แนวคิดพื้นฐานของเทคนิคการเรียนรู้ของเครื่อง

(Basic Concepts in Machine Learning)

- การเรียนรู้ของเครื่อง (Machine Learning: ML) เป็นเทคนิคหนึ่งของเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) ที่พัฒนาขึ้นมาตั้งแต่ช่วงปี ค.ศ. 1980 เนื่องจากการเรียนรู้โดยใช้ผู้เชี่ยวชาญเริ่มมีข้อจำกัด แนวคิดพื้นฐาน Machine Learning นั้นจะเป็นการให้คอมพิวเตอร์เรียนรู้จากข้อมูลในอดีต เพื่อหารูปแบบที่สำคัญ และนำรูปแบบเหล่านั้นมาอธิบายหรือสร้างเงื่อนไข เพื่อใช้ในการพยากรณ์สิ่งที่อาจเกิดขึ้นในอนาคต
- เทคนิคของ Machine Learning จะแตกต่างจากการเขียนโปรแกรม (Traditional Programming) เนื่องจากการเขียนโปรแกรมจะต้องกำหนดเงื่อนไข หรือโปรแกรมค่าต่าง ๆ ไว้เสียก่อน เช่น เมื่อ 2 + 3 = 5 แต่ถ้าเป็นเทคนิคของการเรียนรู้ของเครื่อง จะใช้วิธีการหาฟังก์ชันที่หาความสัมพันธ์ระหว่าง Input ไปเป็น Output

2. ตัวอย่างข้อมูล Input และ Output

- ตารางตัวอย่างข้อมูล Input และ Output ที่ให้เครื่องคอมพิวเตอร์ทำการเรียนรู้
- จากตารางจะเห็นว่าข้อมูลทั้ง 4 ตัวอย่างจะได้ความสัมพันธ์ระหว่างตัวแปร x_1, x_2 และตัวแปร Y คือ ฟังก์ชั่นการบวก (Addition) เนื่องจากเมื่อนำตัวแปร $x_1 + x_2$ จะเท่ากับค่าในตัวแปร Y

ค่า Input	ค่า Output
x_1 = 1 และ x_2 = 2	Y = 3
x_1 = 2 และ x_2 = 2	Y = 4
x_1 = 3 และ x_2 = 1	Y = 4
x_1 = 1 และ x_2 = 3	Y = 4

3. ตัวอย่างข้อมูล Input และ Output และการประยุกต์ใช้แนวคิดของการเรียนรู้ของเครื่อง

ข้อมูล Input	ข้อมูล Output	การประยุกต์ใช้งาน (Application)
ข้อความในอีเมล	อีเมลประเภทสแปมหรือปกติ	การจำแนกอีเมล (Email Classification)
รูปภาพใบหน้าคน	ชื่อของคนในรูปภาพ	การจดจำใบหน้า (Face Recognition)
รูปภาพใบหน้าคน	อารมณ์ของบุคคลในรูปภาพ	การจำแนกอารมณ์จากใบหน้า (Emotion Classification)
ประวัติการใช้งานโทรศัพท์มือถือ	ลูกค้ายกเลิกการใช้บริการหรือยังใช้บริการอยู่	การพยากรณ์โอกาสการยกเลิกการใช้บริการ (Propensity To Churn)
ข้อมูลการตรวจร่างกาย	เป็นโรคเบาหวานหรือไม่	การพยากรณ์โอกาสการเกิดโรคเบาหวาน (Diabetes Prediction)
ข้อมูลการประเมินประวัติการลาออกของพนักงาน	พนักงานลาออกหรือไม่	การพยากรณ์โอกาสการลาออกของพนักงาน (Propensity To Retention)
ข้อมูลปริมาณน้ำ	เหตุการณ์การเกิดอุทกภัย	การพยากรณ์โอกาสการเกิดอุทกภัย (Flood Prediction)

4. ประเภทของการเรียนรู้ของเครื่อง (Types of Learning in Machine Learning)

1. การเรียนรู้แบบมีผู้สอน (Supervised Learning)
2. เทคนิคการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)
3. เทคนิคการเรียนรู้แบบเสริมแรง (Reinforcement Learning)

4.1 การเรียนรู้แบบมีผู้สอน (Supervised Learning)

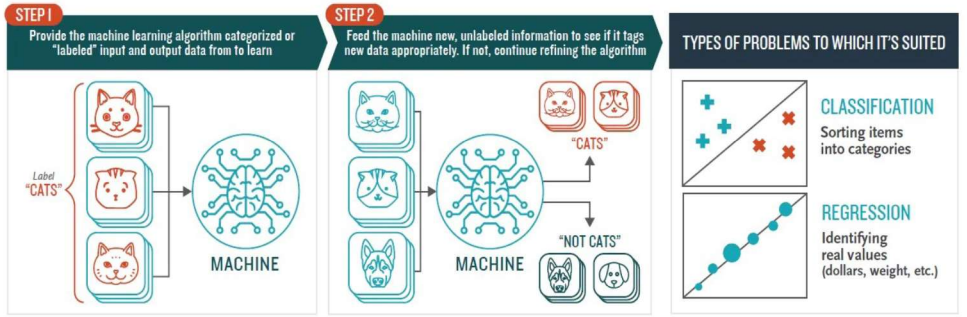
- การเรียนรู้แบบมีผู้สอน (Supervised Learning)
- เทคนิคการเรียนรู้แบบมีผู้สอน (Supervised Learning) จะเป็นการเรียนรู้จากข้อมูลในอดีต และนำมาสร้างตัวแบบจำลองหรือโมเดล (Model) เพื่อพยากรณ์สิ่งที่อาจเกิดขึ้นในอนาคต ซึ่งการวิเคราะห์ลักษณะนี้จะอยู่ในกลุ่ม การวิเคราะห์เชิงพยากรณ์ (Predictive Analytics)

4.1 การเรียนรู้แบบมีผู้สอน (Supervised Learning) Cont.

- เริ่มจากการนำ ชุดข้อมูล (Datasets) มาให้ผู้เชี่ยวชาญ (Expert) กำหนด
- ค่าป้ายกำกับให้กับข้อมูลแต่ละตัวอย่าง (Labeled Data) ซึ่งข้อมูลที่ได้จะเรียกว่า ข้อมูลฝึกสอน (Training Data) ซึ่งจะใช้ข้อมูลชุดนี้ในการสร้างสิ่งที่เรียกว่า Machine Learning Algorithm
- อัลกอริทึม ในการเขียนโปรแกรม หมายถึง ขั้นตอนการทำงานตั้งแต่เริ่มต้นจนจบ เพื่อให้มีผลลัพท์ออกมาเป็นโปรแกรมที่สามารถทำงานได้ตามที่ออกแบบไว้แต่ อัลกอริทึมในทาง Machine Learning จะได้จากการให้คอมพิวเตอร์เรียนรู้รูปแบบ (Patterns) จากชุดข้อมูลฝึกสอนนี้ จนกว่าจะได้ อัลกอริทึม หรือขั้นตอนการทำงาน ที่ทำงานได้ถูกต้อง เพื่อนำมาสร้างโมเดล (ML Model) จำแนกประเภทข้อมูล ออกตามป้ายกำกับต่าง ๆ ได้อย่างแม่นยำ ซึ่งคล้ายกันกับที่มนุษย์เรียนรู้ได้ดีขึ้นจากตัวอย่าง

4.1 การเรียนรู้แบบมีผู้สอน (Supervised Learning) Cont.

- รูปแนวคิดของการเรียนรู้แบบมีผู้สอน (Supervised Learning)



4.1 การเรียนรู้แบบมีผู้สอน (Supervised Learning) Cont.

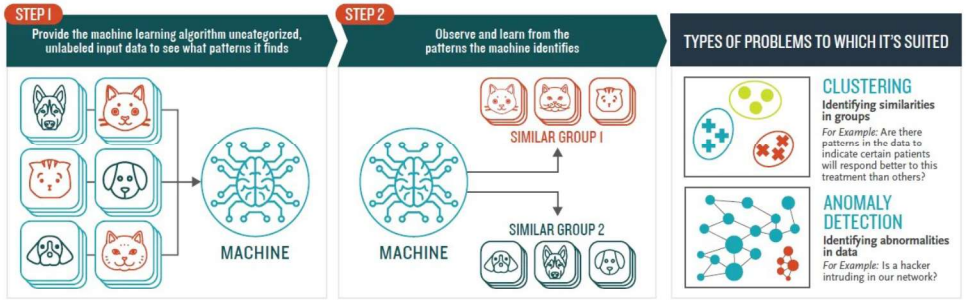
- การวิเคราะห์ในลักษณะนี้จะมีทั้งตัวแปร Input (X) และตัวแปร Output (Y) ซึ่งมีข้อมูลฝึกสอนเป็นภาพต่าง ๆ (ตัวแปร Input) และมีการกำหนดค่า Label ว่าเป็น "CATS" หรือ "NOT CATS" จะให้คอมพิวเตอร์เรียนรู้จากข้อมูลฝึกสอนเหล่านี้ จนกว่าจะได้อัลกอริทึมที่ สามารถแยกแยะภาพได้อย่างถูกต้อง แล้วนำมาสร้างโมเดลเพื่อใช้ในการตอบภาพใหม่ ๆ (Testing Data) ที่ใส่เข้าไปว่าเป็นภาพของแมวหรือไม่ใช่เทคนิคในกลุ่มนี้จะแบ่งออกเป็น 2 ประเภทคือ การจำแนกประเภทข้อมูล (Classification) และ การวิเคราะห์ การถดถอย (Regression)

4.2 การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)

- เทคนิคการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) จะไม่มีการสร้างโมเดลขึ้นมาแต่จะใช้การอธิบายข้อมูล หรือเรียกว่า การวิเคราะห์เชิงบรรยาย (Descriptive Analytics) ซึ่งการวิเคราะห์ในลักษณะนี้จะมีเฉพาะตัวแปร Input เพียงอย่างเดียว จะไม่มีตัวแปร Output
- แนวคิดของเทคนิคนี้จะเริ่มจากการส่งข้อมูลที่ไม่มีป้ายกำกับ (Unlabeled Data) ไปให้คอมพิวเตอร์แบ่งกลุ่มข้อมูลตามความคล้ายคลึงออกเป็นกลุ่มต่าง ๆ จากภาพตัวอย่างจะเป็นภาพต่าง ๆ ที่ไม่มีการติดป้ายกำกับว่าเป็นสัตว์ประเภทไหน ดังนั้นคอมพิวเตอร์จะต้องเรียนรู้เพื่อที่จะแบ่งกลุ่มภาพเหล่านี้ตามความคล้ายคลึง เช่น ภาพที่มีลักษณะเป็นรูปวงกลมและมีสามเหลี่ยม 2 อัน อยู่ด้านบนจะอยู่กลุ่มเดียวกัน หลังจากนั้นมนุษย์จะเป็นคนกำหนด ชื่อของแต่ละกลุ่มเอง เช่น กลุ่มที่มีลักษณะแบบนี้คือ ภาพแมว และอีกกลุ่มคือ ภาพสุนัข เป็นต้น

4.2 การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)

- รูปแนวคิดของการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)



4.3 การเรียนรู้แบบเสริมแรง (Reinforcement Learning)

- เทคนิคการเรียนรู้แบบเสริมแรง (Reinforcement Learning) จะเป็นการเรียนรู้โดย Agent, การกระทำบางอย่าง (Action) และได้ผลลัพธ์หรือรางวัล (Reward) ออกมา ซึ่งอาจจะเป็น ค่าบวก (Positive) หรือค่าลบ (Negative) ก็ได้ หลังจากนั้น Agent จะเรียนรู้จากรางวัลที่ได้และเปลี่ยนการกระทำไปเรื่อย ๆ จนได้ผลลัพธ์ที่ดีขึ้น

4.3 การเรียนรู้แบบเสริมแรง (Reinforcement Learning) Cont.

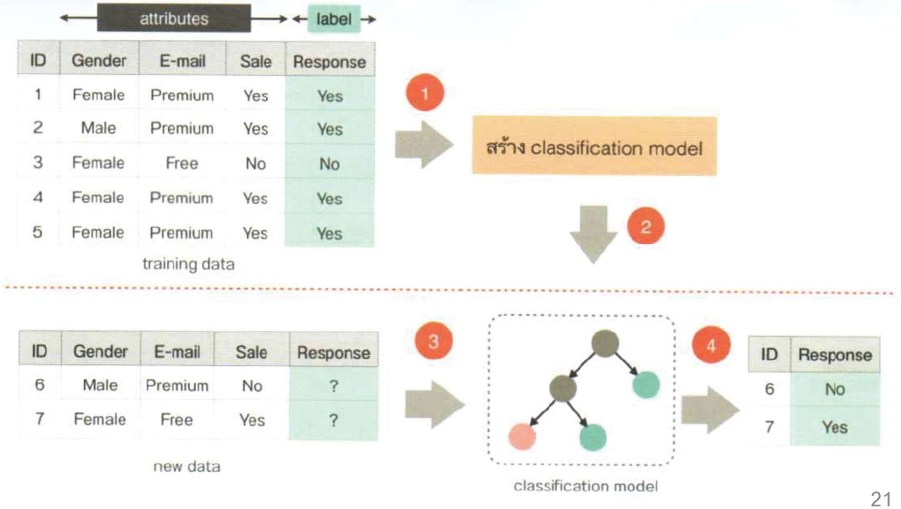
- ตัวอย่างเช่น เมื่อนำหุ่นยนต์ดูดฝุ่นมาใช้ครั้งแรก หุ่นยนต์จะเริ่มเรียนรู้เส้นทางภายในห้องโดยการเคลื่อนที่ไปตามส่วนต่าง ๆ หากเคลื่อนที่ไปแล้วกระทบกับกำแพง หุ่นยนต์จะได้ค่ารางวัลที่มีค่าติดลบ และเรียนรู้ว่าไม่ควรมาถึงจุดนี้ แต่ถ้าเคลื่อนที่ไปไม่เจอกำแพง หุ่นยนต์ จะได้ค่ารางวัลเป็นค่าบวก และสามารถเดินทางต่อไปจากจุดนี้ได้ ซึ่งขั้นตอนการทำงานลักษณะนี้ เป็นการสอนให้หุ่นยนต์ได้เรียนรู้ลักษณะของพื้นที่ภายในห้องจากประสบการณ์ และหลังจากนั้นหุ่นยนต์ก็จะทำความสะอาดได้อย่างมีประสิทธิภาพมากขึ้น โดยไม่ต้องวิ่งชนกำแพงหรือ สิ่งกีดขวางอีกต่อไป

5. แนวคิดของการเรียนรู้แบบมีผู้สอน

- การเรียนรู้แบบมีผู้สอน เป็นการเรียนรู้จากข้อมูลที่มีคำตอบ/ลาเบล (Label) /คลาส (Class) อยู่แล้ว ซึ่งเป็นข้อมูลในอดีต หรือให้ผู้เชี่ยวชาญเป็นผู้กำหนดลาเบลเหล่านี้ให้ ซึ่งข้อมูลนี้เรียกว่า ข้อมูลฝึกสอน (Training Data) แนวคิดการทำงานของเทคนิคในกลุ่มนี้ จะเริ่มจากการส่งข้อมูลฝึกสอนไปให้คอมพิวเตอร์เรียนรู้ และได้เป็นเงื่อนไข (Rules) หรือสมการทางคณิตศาสตร์ (Math Equation) ที่ช่วยในการพยากรณ์ค่าสำหรับข้อมูลใหม่ต่อไปได้ ซึ่งสามารถสรุปได้ดังรูป

5. แนวคิดของการเรียนรู้แบบมีผู้สอน (Cont.)

- รูปแนวคิดของการเรียนรู้แบบมีผู้สอน



5. แนวคิดของการเรียนรู้แบบมีผู้สอน (Cont.)

- จากรูปสามารถแบ่งออกได้ 2 ขั้นตอน ดังนี้
  - ขั้นตอนของการเรียนรู้จากข้อมูลฝึกสอน ซึ่งในตัวอย่างนี้คือ จากข้อมูลในอดีตพบว่า ลูกค้าคนใดบ้างที่ตอบรับโปรโมชันที่นำเสนอหรือไม่ (Response) ซึ่งจะมีค่าเป็นตอบรับ (Yes) และไม่ตอบรับ (No) และดูปัจจัยอื่น ๆ เช่น เพศ (Gender), อีเมล (E-mail) และประวัติการซื้อสินค้าที่ผ่านมา (Sale) เรียกขั้นตอนนี้ว่า "Build Model"
  - ขั้นตอนของการใช้โมเดลที่สร้างขึ้นมา เพื่อพยากรณ์ค่าให้กับข้อมูลใหม่ (Unseen Data) ซึ่งในที่นี้คือ ข้อมูลลูกค้าหมายเลข 6 และ 7 ซึ่งถือว่าเป็นลูกค้าใหม่ โดยโมเดลได้พยากรณ์ว่าลูกค้าหมายเลข 6 จะไม่ตอบรับ (No) แต่ลูกค้าคนที่ 7 จะตอบรับ (Yes) เรียกขั้นตอนนี้ว่า "Scoring" เพราะได้คำตอบจากคะแนนที่กำหนดให้ข้อมูลใหม่

6. การแบ่งข้อมูลเพื่อใช้ทดสอบประสิทธิภาพ

- ก่อนที่จะนำโมเดลที่สร้างขึ้นไปใช้งานกับข้อมูลใหม่นั้น ควรจะมีการวัดประสิทธิภาพของโมเดลเสียก่อน โดยใช้ข้อมูลชุดใหม่มาทดสอบ และข้อมูลชุดนี้ก็จะต้องมีลาเบลทำกับไว้ด้วย เช่นกันการแบ่งข้อมูลมาทดสอบส่วนใหญ่ จะใช้วิธีแบ่งข้อมูลจากข้อมูลฝึกสอนมาบางส่วนซึ่งวิธีการนี้เรียกว่า Split Test

6. การแบ่งข้อมูลเพื่อใช้ทดสอบประสิทธิภาพ

- สำหรับเครื่องมือ Auto Model ใน Rapid Miner เพื่อแบ่งชุดข้อมูล (Datasets) ออกเป็น 2 ส่วน
- โดยมีสัดส่วนของข้อมูลฝึกสอน (Training Data) 60%
- และข้อมูลทดสอบ (Testing Data) 40% ของข้อมูลทั้งหมด และเพื่อไม่ให้การทดสอบเกิดการเอนเอียง (Bias) จึงมีการแบ่งข้อมูลทดสอบ 40% นี้ ออกเป็น 7 ส่วนเท่า ๆ กัน เพื่อใช้ทดสอบประสิทธิภาพโมเดลทั้งหมด 7 รอบ



7. การประเมินประสิทธิภาพของโมเดล (Performance Metrics for Evaluation of Models)

- การประเมินประสิทธิภาพของโมเดล เป็นขั้นตอนการ Evaluate Models สำหรับประเมินประสิทธิภาพของโมเดลเราจะใช้การคำนวณค่า Metrics เป็นตัววัดว่าโมเดลมีประสิทธิภาพแค่ไหน ทั้งความถูกต้องและความแม่นยำในการพยากรณ์ เพื่อใช้ในการเปรียบเทียบและดัดเลือกโมเดลที่เหมาะจะนำไปใช้งานมากที่สุด จึงต้องมีการคำนวณและพิสูจน์ออกมาเป็นคะแนน (Score) ให้เห็น ซึ่งโมเดลแต่ละประเภทก็จะใช้ Metrics ในการประเมินโมเดลที่แตกต่างกัน

7. การประเมินประสิทธิภาพของโมเดล (Performance Metrics for Evaluation of Models) (Cont.)

- การประเมินประสิทธิภาพสำหรับ Classification Models
- หลังจากนำข้อมูลไปทดสอบกับโมเคลที่สร้างขึ้นมาได้แล้ว ก็จะสามารถคำนวณค่าตัววัดประสิทธิภาพต่าง ๆ ได้ โดยตัววัดประสิทธิภาพของโมเดล Classification จะมีการใช้ Metrics อยู่ 4 ค่าหลัก ๆ คือ
  - ค่าความถูกต้อง (Accuracy) หรือ Accuracy Score
  - ค่าความแม่นยำ (Precision) หรือ Precision Score
  - ค่าความครบถ้วน หรือค่าความระลึก (Recall) หรือ Recall Score
  - ค่าการวัดประสิทธิภาพโดยรวม (F-Measure)

7. การประเมินประสิทธิภาพของโมเดล (Performance Metrics for Evaluation of Models) (Cont.)

- โดยค่าเหล่านี้คำนวณได้จากตารางคอนฟิวชันเมทริกซ์ (Confusion Matrix) ซึ่งเป็นตารางที่มีจำนวนแถวและคอลัมน์เท่ากันกับจำนวนค่าของคลาสคำตอบ จากตัวอย่างที่แสดงข้างต้นจะพบว่ามีคลาสคำตอบอยู่ 2 คลาสคือ ‘ตอบรับ (Yes)’ และ ‘ไม่ตอบรับ (No)’ โปรโมชันที่นำเสนอ จึงสร้างเป็นตารางที่มีจำนวน 2 แถวและ 2 คอลัมน์

7. การประเมินประสิทธิภาพของโมเดล (Performance Metrics for Evaluation of Models) (Cont.)

- แสดงตารางคอนฟิวชันเมทริกซ์
- สำหรับการจำแนกประเภทการตอบรับโปรโมชัน

		ค่าจริง (Actual Value)	
		ตอบรับ (Yes)	ไม่ตอบรับ (No)
ค่าพยากรณ์ (Predicted Value)	ตอบรับ (Yes)	TP	FP
	ไม่ตอบรับ (No)	FN	TN

7. การประเมินประสิทธิภาพของโมเดล (Performance Metrics for Evaluation of Models) (Cont.)

เมื่อพิจารณาในแนวคอลัมน์จะเป็น ค่าจริง (Actual Value) ที่อยู่ในข้อมูลทดสอบ และเมื่อพิจารณาในแนวแถวจะเป็น ค่าพยากรณ์ (Predicted Value) ที่ได้จากแบบจำลองและค่า TP, TN, FP, FN ในตารางฟิวชันเมทริกซ์ สามารถอธิบายได้ดังนี้

- ค่า True Positive (TP): จำนวนข้อมูลที่พยากรณ์ถูกว่าเป็นคลาส ซึ่งกำลังพิจารณา เช่น เมื่อลูกค้ามีการตอบรับ (Yes) แต่โมเดลก็พยากรณ์ว่าตอบรับ (Yes) ตรงกัน
- ค่า True Negative (TN): จำนวนข้อมูลที่พยากรณ์ถูกว่าเป็นคลาส ซึ่งไม่ได้พิจารณา เช่น เมื่อลูกค้าไม่มีการตอบรับ (No) และโมเดลก็พยากรณ์ว่าไม่ตอบรับ (No) ตรงกัน
- ค่า False Positive (FP): จำนวนข้อมูลที่พยากรณ์ผิดมาเป็นคลาส ซึ่งกำลังพิจารณา เช่น เมื่อลูกค้าไม่มีการตอบรับ (No) แต่โมเดลกลับพยากรณ์ว่าตอบรับ (Yes)
- ค่า False Negative (FN): จำนวนข้อมูลที่พยากรณ์ผิดมาเป็นคลาส ซึ่งไม่ได้พิจารณา เช่น เมื่อลูกค้ามีการตอบรับ (Yes) แต่โมเดลพยากรณ์ว่าไม่ตอบรับ (No)

- หลังจากได้ตารางคอนฟิวชันเมทริกซ์แล้ว จะนำมาคำนวณค่าตัววัดประสิทธิภาพของโมเดล Classification

8. ค่าความถูกต้อง (Accuracy)

- ค่าความถูกต้อง (Accuracy): เป็นการวัดความถูกต้องของ ML Model โดยคำนวณรวมทุกลาเบลคำตอบ

$$Accuracy = \frac{True\ Positives\ \ + True\ Negatives}{Total\ Number\ of\ Examples}$$

$$Accuracy = \frac{TP\ + TN}{TP\ + TN + FP + FN}$$

8. ค่าความแม่นยำ (Precision)

- ค่าความแม่นยำ (Precision): เป็นการคำนวณค่า Precision ถูกต้องของ ML Model โดยคำนวณแยกทีละลาเบลคำตอบ

$$precision = \frac{True\ Positives}{True\ \ Positives + False\ Positive}$$

$$Precision = \frac{TP}{TP\ +\ FP}$$

9. ค่าความครบถ้วน หรือค่าความละลึก (Recall)

- ค่าความครบถ้วน หรือค่าความละลึก (Recall): เป็นการคำนวณค่า Recall ของ ML Model โดยคำนวณแยกทีละลาเบลคำตอบ

$$Recall = \frac{True\ Positives}{True\ Positives + False\ Negatives}$$

$$Recall = \frac{TP}{TP\ +\ FN}$$

10. ค่าการวัดประสิทธิภาพโดยรวม (F-Measure)

- ค่าการวัดประสิทธิภาพโดยรวม (F-Measure): เป็นการคำนวณค่าเฉลี่ยฮาร์โมนิก (Harmonic Mean) ของ Recall โดยคำนวณแยกทีละลาเบลคำตอบ

$$F_1 = 2\,x\,\frac{Precision\ x\ Recall}{Precision\ +\ Recall}$$

11. การประเมินประสิทธิภาพสำหรับ Regression Models

- การประเมินประสิทธิภาพสำหรับ Regression Models
- สำหรับตัววัดประสิทธิภาพของ โมเดลแบบ Regression ซึ่งมีค่าลาเบลคำตอบเป็นตัวเลข จะวัดเป็นค่าความคลาดเคลื่อน (Error) ต่าง ๆ และเพื่อให้เข้าใจการคำนวณค่าวัดต่าง ๆ มากยิ่งขึ้น ซึ่งเป็นการพยากรณ์ยอดการผลิตสินค้ารายวันของบริษัทแห่งหนึ่งซึ่งตัวอย่างนี้เรียกว่า การพยากรณ์อุปสงค์ (Demand Forecast)

12. การคำนวณค่าความคลาดเคลื่อน

- ตารางแสดงค่าจริงและค่าที่พยากรณ์เพื่อใช้ ในการคำนวณค่าความคลาดเคลื่อน

วันที่	ค่าจริง (Actual Value)	ค่าพยากรณ์ (Predicted Value)	ค่าความคลาดเคลื่อน (Error)	ค่าความคลาดเคลื่อนสัมบูรณ์ (Absolute Error)	ค่าความคลาดเคลื่อนกำลังสอง (Square Error)
1	1,000	1,100	100	100	10,000
2	1,050	1,000	-50	50	2,500
3	1,300	1,200	-100	100	10,000
4	1,250	1,300	50	50	2,500
5	1,090	1,100	10	10	100
6	1,000	1,020	20	20	400
7	1,100	1,150	50	50	2,500
8	1,150	1,200	50	50	2,500
9	1,200	1,300	100	100	10,000
10	1,250	1,260	10	10	100

13. ค่า Mean Absolute Error (MEA)

- ค่าวัดประสิทธิภาพของการเรียนรู้แบบ Regression จะเป็นการวัดค่าความคลาดเคลื่อนซึ่งมีหลายแบบดังนี้
- ค่า Mean Absolute Error (MEA): เป็นการวัดค่าเฉลี่ยของความคลาดเคลื่อนโดยการใส่ค่าสัมบูรณ์ เพื่อให้ค่าความคลาดเคลื่อนเป็นบวกทั้งหมด

$$MAE = \frac{|predicted\ value\ -\ acturl\ value|}{number\ of\ examples}$$

- เช่น ค่า MEA ของข้อมูลชุดนี้เท่ากับ
- (100 + 50 + 100 + … + 10) / 10 = 63.72

14. ค่า Root Mean Square Error (RMSE)

- ค่า Root Mean Square Error (RMSE): เป็นการวัดค่าเฉลี่ยของความคลาดเคลื่อนโดยการใส่ค่ายกกำลังสอง เพื่อให้ค่าความคลาดเคลื่อนเป็นบวกทั้งหมด แล้วค่อยถอดรากที่สอง

$$RMSE = \sqrt{\frac{(predicted\ value\ - actual\ value)^2}{number\ of\ examples}}$$

- เช่น ค่า RMSE ของข้อมูลชุดนี้เท่ากับ
- (10,000 + 2,500 + 10,000 + … + 100) / 10 = 63.72
- จะเห็นว่า การคำนวณค่าความคลาดเคลื่อนแบบ RMSE จะมีค่าสูงกว่า MAE เป็นผลมาจากการนำความคลาดเคลื่อนไปยกกำลังสอง ซึ่งจะทำให้ค่ามีปริมาณมากขึ้นนั่นเอง

15. ขั้นตอนการสร้างโมเดล (Build Model) และการนำไปใช้งาน (Deployment)

- การสร้างโมเดลใน Rapid Miner โดยใช้ Auto Model จะมีขั้นตอนดังนี้

STEP 1 Load Data: โหลดหรือเลือกข้อมูลจาก Repository

STEP 2 Select Task: เลือกการวิเคราะห์ข้อมูล ซึ่งมี 3 แบบคือ

Predict: การสร้างโมเดลเพื่อพยากรณ์ต่าง ๆ

Clusters: การแบ่งกลุ่มข้อมูลที่มีลักษณะคล้ายกัน

Outliers: การหาข้อมูลที่มีค่าผิดปกติ เช่น ค่ามากหรือน้อยผิดปกติ

STEP 3 Prepare Target: การเลือกแอตทริบิวต์ (Attribute) ที่เป็นลาเบล (Label)

STEP 4 Select Inputs: การเลือกแอตทริบิวต์ (Attribute) ที่จะใช้ในการสร้างโมเดล

STEP 5 Model Types: การเลือกเทคนิคสำหรับสร้างโมเดล

STEP 6 Results: การแสดงผลการวิเคราะห์ข้อมูล

16. การสร้าง ML Model ด้วยเทคนิค Decision Tree

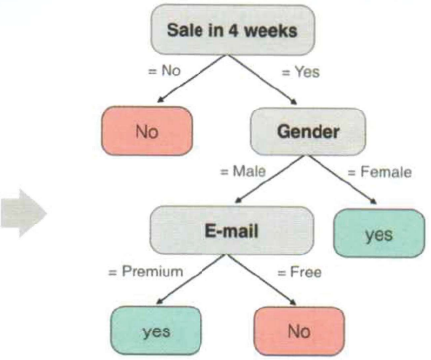
- เทคนิค Decision Tree หรือ ต้นไม้ตัดสินใจ เป็นชุดของอัลกอริทึมหนึ่งของ Machine Learning ที่มีประโยชน์ใน การแก้ปัญหาทั้งการจำแนกประเภทข้อมูล (Classification) และการวิเคราะห์การถดถอย (Regression)
- เทคนิค Decision Tree จะเป็นการสร้างโมเดลในลักษณะตรวจสอบเงื่อนไขไล่ระดับจากบน ลงล่าง โดยจะเป็นการเรียนรู้จากข้อมูลฝึกสอนที่มี 10 แถว (ตารางด้านซ้าย) และสร้างเป็นโมเดลต้นไม้ตัดสินใจ (ด้านขวา) เวลาอ่านค่าให้อ่านจากบนลงล่าง เช่น ถ้ามีการซื้อสินค้าในช่วง 4 สัปดาห์ก่อน (Sale in 4 Weeks) และเป็นเพศหญิง (Female) จะพยากรณ์ได้ว่าจะมีการตอบรับโปรโมชัน (Yes)

17. โมเดล Decision Tree จากข้อมูลฝึกสอน

- รูปการสร้างโมเดล Decision Tree จากข้อมูลฝึกสอน

ID	Gender	E-mail	Sale in 4 Weeks	Response
1	Female	Premium	Yes	Yes
2	Male	Premium	Yes	Yes
3	Female	Free	No	No
4	Female	Premium	Yes	Yes
5	Female	Premium	Yes	Yes
6	Male	Premium	No	No
7	Female	Free	Yes	Yes
8	Male	Free	Yes	No
9	Female	Premium	No	No
10	Male	Free	Yes	No

Training data



18. แนวคิดของการสร้างโมเดล Decision Tree

- แนวคิดของการสร้างโมเดล Decision Tree สรุปได้ดังนี้
  - ต้องการจะแบ่งข้อมูลออกจากกันให้ได้มากที่สุดเท่าที่จะทำได้
  - เลือกตัวแปรที่แบ่งลาเบลคำตอบได้ดีที่สุดมาวางไว้เป็นโหนดแรก
  - หลังจากนั้นก็หาตัวแปรอื่น ๆ มาแบ่งข้อมูลในลำดับชั้นถัดไป
  - ทำซ้ำจนข้อมูลแยกออกจากกัน
- การอ่านโมเดล Decision Tree จะไล่จากบนลงล่าง เช่น ถ้าลูกค้าไม่เคยซื้อสินค้ามาก่อน (Sale in 4 weeks = No) จะไม่ตอบรับโปรโมชันที่นำเสนอ (Response = No)

19. ข้อดี - ข้อจำกัดของเทคนิค Decision Tree

- ข้อดีของเทคนิค Decision Tree
  - เป็นโมเดลที่แปลความได้ง่าย โดยการอ่านไล่จากบนลงล่าง
  - ใช้ได้กับแอตทริบิวต์ที่เป็นตัวเลข (Number) และตัวหนังสือ (Category)
  - เลือกแอตทริบิวต์ที่สำคัญ และตัดแอตทริบิวต์ที่ไม่สำคัญ
  - ปรับเปลี่ยนพารามิเตอร์ของ Decision Tree ได้ง่าย
  - พยากรณ์ลาเบลที่เป็นประเภท Category ได้มากกว่า 2 ค่า
- ข้อจำกัดของเทคนิค Decision Tree
  - ไม่เหมาะกับข้อมูลที่มีความซับซ้อนมาก ๆ
  - ข้อมูลแอตทริบิวต์หรือตัวแปรที่เป็นตัวเลข จะแบ่งได้เป็น 2 ช่วง หรือต้องแปลงให้เป็น Category มาก่อน

20. การสร้างโมเดลพยากรณ์การลา Decision Tree

- การพยากรณ์ว่าพนักงานจะมีโอกาสลาออกบ้าง ปัญหานี้เป็นตัวอย่างการประยุกต์ใช้ทางด้านการบริหารงานบุคคล โดยเทคนิค Decision Tree นี้จะเรียนรู้รูปแบบของตัวแปรต่าง ๆ ในอดีตที่ผ่านมา และสรุปออกมาเป็นโมเดล Decision Tree ซึ่งตัวแปรที่อยู่ด้านบนจะมีความสำคัญมากกว่าตัวแปรที่อยู่ด้านล่าง

21. ข้อมูลชุดข้อมูล

ลำดับที่	คอลัมน์	ความหมาย
1	satisfaction_level	ระดับความพึงพอใจของพนักงาน
2	last_evaluation	คะแนนประเมินผลครั้งล่าสุด
3	number_project	จำนวนโปรเจ็กต์ที่รับผิดชอบ
4	average_monthly_hours	จำนวนชั่วโมงการทำงานเฉลี่ยต่อเดือน
5	time_spend_compan	ระยะเวลาที่ทำงานกับบริษัท
6	work_accident	เคยประสบอุบัติเหตุหรือไม่ (มีค่าเป็น 1 และ 0)
7	left	ปัจจุบันลาออก (yes) หรือไม่ลาออก (no) (ใช้เป็นลาเบล)
8	promote_last_5years	ได้รับการเลื่อนตำแหน่งหรือไม่ในช่วง 5 ปีล่าสุด
9	department	แผนก/ฝ่าย
10	salary	ระดับเงินเดือน (มีค่าเป็น low, medium และ high)

22. การแก้ปัญหาข้อมูลไม่สมดุล (Imbalanced Data)

- Imbalanced Data คือ การที่ข้อมูลของเรามีจำนวนข้อมูลในคลาสที่แตกต่างกันมาก เช่น ข้อมูลที่เกี่ยวกับการโกง (Fraud) จะมีการ Fraud น้อยมาก (0.1%) แต่ข้อมูลปกติเยอะมาก (99.9%) ซึ่งถ้านำข้อมูลมาสร้างโมเดลก็จะพบว่า ไม่สามารถ Predict ข้อมูลการโกงได้ถูกต้อง
- ปัญหาข้อมูลไม่สมดุลคือ การที่ข้อมูลมีลาเบลต่าง ๆ ในจำนวนที่ต่างกัน เช่น พนักงานที่ลาออกมีจำนวน 3,565 คน ซึ่งน้อยกว่าพนักงานที่ยังทำงานอยู่ถึง 11,424 คน หรือจำนวนลูกค้าที่มีการตอบรับโปรโมชันที่นำเสนอ มีจำนวนน้อยกว่าลูกค้าที่ไม่ตอบรับโปรโมชัน (คิดเป็นอัตราส่วน 1:100 หรือ คิดเป็น Response Rate = 1%) ข้อมูลที่มีจำนวนมากกว่านี้เรียกว่า "Majority Class“ และข้อมูลที่มีจำนวนน้อยกว่านี้เรียกว่า "Minority Class"

23. การแก้ปัญหา Imbalanced Data ทำได้หลายวิธี

- การทำ Under Sampling: เป็นการสุ่มข้อมูลที่เป็น Majority Class ลดลงมาให้มีจำนวนใกล้เคียงกับกลุ่มที่เป็น Minority Class
- การทำ Over Sampling: เป็นการสร้างข้อมูลที่เป็น Minority Class ให้มีปริมาณมากขึ้น ซึ่งข้อมูลใหม่นี้อาจจะอยู่ใกล้เคียงกับข้อมูลเดิม เรียกว่า Synthetic Minority Oversampling Technique (SMOTE)
- การสร้างโมเดลด้วยวิธี Cost Sensitive Learning: โดยจะกำหนดค่า Cost หรือน้ำหนักให้กับข้อมูลต่าง ๆ โดยค่า Cost นี้จะเป็นตัวที่เป็น Penalty เวลาสร้างโมเดล นั่นหมายความว่า โมเดลจะพยายามให้ค่าพยากรณ์คำตอบนี้ผิดน้อยลง

24. การสร้าง ML Model ด้วยเทคนิค Naive Bayes

- เทคนิค Naive Bayes (อ่านว่า นาอีฟ-เบย์) เป็นชุดของอัลกอริทึม อีกแบบหนึ่งของ Machine Learning ที่ใช้หลักของความน่าจะเป็น (Probability) โดยมีการคำนวณจากข้อมูลฝึกสอนซึ่งเป็นข้อมูลในอดีต ซึ่งแถวในตารางจะเป็นค่าของตัวแปรต่าง ๆ เช่น
- Gender = Male หมายถึง ลูกค้าเพศชาย และคอลัมน์ในตารางจะเป็นคอลัมน์ที่เป็นลาเบล เช่น
- Response = Yes หมายถึง มีการ ตอบรับโปรโมชันที่นำเสนอ และค่าที่อยู่ในแต่ละช่องของตารางคือ "ความน่าจะเป็น" ซึ่งมีค่าอยู่ในช่วง 0 - 1 (เขียนสั้น ๆ ว่า 'Prob') หากค่า Prob ยิ่งมากก็จะยิ่งมีโอกาสเกิดเหตุการณ์นั้นสูงขึ้น

25. โมเดล Naive Bayes

- รูปแสดงโมเดล Naive Bayes ที่สร้างขึ้นมาจากข้อมูลฝึกสอน

ID	Gender	E-mail	Sale in 4 Weeks	Response
1	Female	Premium	Yes	Yes
2	Male	Premium	Yes	Yes
3	Female	Free	No	No
4	Female	Premium	Yes	Yes
5	Female	Premium	Yes	Yes
6	Male	Premium	No	No
7	Female	Free	Yes	Yes
8	Male	Free	Yes	No
9	Female	Premium	No	No
10	Male	Free	Yes	No

Training data

Attribute/Class	Response = Yes (0.5)	Response = No (0.5)
Gender = Male	Prob = 1/5 (0.20)	Prob = 3/5 (0.60)
Gender = Female	Prob = 4/5 (0.80)	Prob = 2/5 (0.40)
E-mail = Free	Prob = 1/5 (0.20)	Prob = 3/5 (0.60)
E-mail = Premium	Prob = 4/5 (0.80)	Prob = 2/5 (0.40)
Sale in 4 Weeks = Yes	Prob = 5/5 (1.00)	Prob = 2/5 (0.40)
Sale in 4 Weeks = No	Prob = 0/5 (0.00)	Prob = 3/5 (0.60)

Naive Bayes

25. โมเดล Naive Bayes (Cont.)

- จากตารางแปลความได้ว่า
  - ถ้าลูกค้าเคยซื้อสินค้ามาก่อน (Sale in 4 Weeks = Yes) จะมีโอกาสตอบรับโปรโมชันที่นำเสนอ (Response = Yes) มากที่สุด (ความน่าจะเป็นเท่ากับ 1.00)
  - ถ้าลูกค้าเป็นผู้หญิง (Female) จะมีโอกาสตอบรับโปรโมชันที่นำเสนอ (Response = Yes) มากรองลงมา (ความน่าจะเป็นเท่ากับ 0.80)
- ในการพยากรณ์ข้อมูลใหม่นั้น จะนำคู่ Prob ที่คำนวณได้จากตารางมาคูณกัน และดูว่าค่า Prob ของคำตอบไหนมีค่ามากกว่ากัน

26. ข้อดี - ข้อจำกัดของเทคนิค Naive Bayes

- ข้อดีของเทคนิค Naive Bayes
  - เป็นโมเดลที่แปลความได้ง่าย โดยดูจากค่าความน่าจะเป็น (Probability)
  - สร้างโมเดลได้อย่างรวดเร็ว
  - พยากรณ์คำตอบ (Class) ที่เป็นประเภท Category ได้มากกว่า 2 ค่า
- ข้อจำกัดของเทคนิค Naive Bayes
  - แอตทริบิวต์หรือตัวแปรควรจะเป็น Category ถ้าเป็นตัวเลขจะต้องตรวจสอบการกระจายตัว (Distribution) ของข้อมูล
  - เป็นแบบ Parametric เมื่อแอตทริบิวต์หรือตัวแปรเป็นประเภทตัวเลข

27. การสร้างโมเดลแนะนำรถขนส่งสินค้าด้วย เทคนิค Naive Bayes

- การใช้เทคนิค Naive Bayes เพื่อช่วยแนะนำรถขนส่งที่เหมาะจะใช้ในการขนส่งสินค้าไปตามจังหวัดต่าง ๆ เพื่อลดภาระงานของพนักงาน โดยสมมุติว่ามีข้อมูล 6 คอลัมน์ ดังนี้

ลำดับที่	แอตทริบิวต์	ความหมาย
1	ORDER_NO	ลำดับของใบงาน
2	TRUCK_TYPE	ประเภทรถยนต์ที่ขนส่ง (ใช้เป็นลาเบล)
3	SHIP_TO	จังหวัดปลายทาง
4	QTY	จำนวนสินค้า (ชิ้น)
5	GRSWGHT	น้ำหนักรวมของสินค้า
6	PRODUCT_SIZE	ขนาดของสินค้า

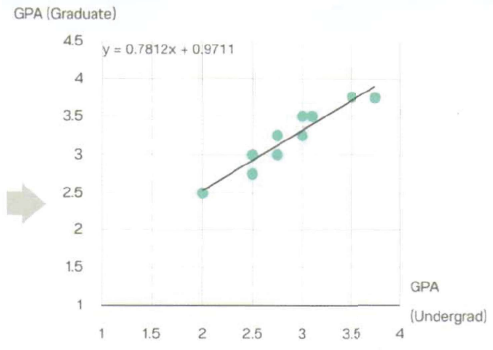
28. การสร้าง ML Model ด้วยเทคนิค Linear Regression

- สรุปแนวคิดของการสร้างโมเดลด้วยเทคนิค Linear Regression
- เทคนิคนี้จะเป็นการคาดการณ์ข้อมูลที่ได้ผลลัพธ์ออกมาเป็นตัวเลข เรียกว่า "โมเดลการเรียนรู้แบบ Linear Regression"
- แนวคิดในการใช้เส้นตรงเส้นหนึ่งเป็นตัวแทนของข้อมูลที่มี ดังรูปดังกล่าวข้างต้นซึ่งสร้างมาจากข้อมูล
- เกรดเฉลี่ยตอนจบปริญญาตรี (GPA ระดับ undergraduate) และข้อมูลเกรดเฉลี่ยตอนจบปริญญาโท (GPA ระดับ graduate) ซึ่งมีความสัมพันธ์เชิงเส้นตรงของ 2 ปริมาณ นั่นคือ ถ้าตอนจบปริญญาตรีได้เกรดเฉลี่ยสูงแล้ว ตอนจบปริญญาโทก็จะมีแนวโน้มว่าเกรดเฉลี่ยจะสูงด้วยเช่นกัน ดังนั้น จึงสามารถหาเส้นตรงมาเป็นตัวแทนของข้อมูลชุดนี้ได้ ซึ่งสมการเส้นตรงนี้คือ
- GPA (grad) = 0.7812 x GPA (undergraduate) + 0.9711
- NOTE: โมเดลนี้สร้างขึ้นจากข้อมูลสมมุติ 10 แถวเท่านั้น ถ้ามีข้อมูลมากขึ้นโมเดลก็จะมีสมการที่เปลี่ยนไป

29. โมเดล Linear Regression

- รูปแสดงโมเดล Linear Regression

ID	GPA (undergrad)	GPA (grad)
1	3.00	3.25
2	2.00	2.50
3	2.50	3.00
4	3.50	3.75
5	3.75	3.75
6	2.75	3.25
7	2.50	2.75
8	2.75	3.00
9	3.00	3.50
10	3.10	3.50



29. โมเดล Linear Regression (Cont.)

- การนำโมเดล Linear Regression ไปใช้งาน ทำได้โดยการแทนค่าในตัวแปรของสมการ ก็จะได้ค่าพยากรณ์ เช่น ถ้ามีนักศึกษามาสมัครเรียนระดับปริญญาโท และอยากทราบว่าตอนจบนักศึกษาคนนี้น่าจะได้เกรดเฉลี่ยเท่าไร ก็ทำได้โดยใส่ค่าเกรดเฉลี่ยระดับปริญญาตรีของนักศึกษาคนนี้ในสมการ เช่น สมมุติว่าได้เกรดเฉลี่ยเป็น 3.00 โมเดลจะพยากรณ์ว่าตอนเรียนจบปริญญาโทน่าจะได้เกรดเฉลี่ย 3.32 (คำนวณจาก 0.7812 x 3.00 + 0.9711 = 3.32)

30. ข้อดี - ข้อจำกัดของเทคนิค Linear Regression

- ข้อดีของเทคนิค Linear Regression
  - เป็นโมเดลที่แปลความได้ง่าย โดยดูจากสมการของ Linear Regression
  - ดูความสำคัญของแอตทริบิวต์หรือตัวแปรได้จากค่าสัมประสิทธิ์ (Coefficient)
  - ทำงานได้อย่างรวดเร็ว
- ข้อจำกัดของเทคนิค Linear Regression
  - พยากรณ์คำตอบ (Class) ที่เป็นตัวเลขได้เท่านั้น
  - ทำได้กับตัวแปรที่เป็นตัวเลข (Number) เท่านั้น
  - ถ้าเป็นตัวแปรประเภท Category ต้องแปลงเป็นตัวเลขเสียก่อน โดยใช้วิธีเข้ารหัสแบบ
  - Dummy Coding หรือ One-Hot Encoding
  - ข้อมูลต้องกระจายเป็นแบบเชิงเส้นตรง (Linear)

31. การสร้างโมเดลคาดการณ์การใช้น้ำมันเพื่อทำความร้อนด้วยเทคนิค Linear Regression

- เทคนิค Linear Regression เพื่อช่วยดาดการณ์การใช้น้ำมันเพื่อทำความร้อนในบ้านแต่ละหลัง โดยข้อมูลนี้อ้างอิงมาจากหนังสือ Data Mining for the Masses (First Edition) มีทั้งหมด 6 คอลัมน์ ดังนี้

ลำดับที่	แอตทริบิวต์	ความหมาย
1	Insulation	ระดับของฉนวนกันความร้อนภายในบ้าน
2	Temperature	อุณหภูมิภายนอกบ้านเมื่อปีที่ผ่านมา
3	Num_Occupants	จำนวนผู้อาศัยอยู่ภายในบ้าน
4	Avg_Age	อายุเฉลี่ยของผู้อาศัยอยู่ในบ้าน
5	Home_Size	ขนาดของบ้าน ตัวเลขมากแสดงว่าใหญ่
6	Heating_oil	ปริมาณการสั่งซื้อน้ำมันเพื่อทำความร้อนในปีที่ผ่านมา (กำหนดให้เป็น label)

32. การสร้าง ML Model ด้วยเทคนิค Logistic Regression

- สรุปแนวคิดของการสร้างโมเดลด้วยเทคนิค Logistic Regression
- เทคนิคนี้เป็นโมเดลการเรียนรู้แบบ Regression เช่นเดียวกันกับในตัวอย่างก่อนหน้านี้ แต่จะต่างกันตรงที่จะมีการแปลงคำตอบจากตัวเลข (Number) ให้เป็นตัวหนังสือ (Category) เพียง 2 ค่าแล้ว หลักการทำงานก็จะคล้ายกับLinear Regression คือ เป็นการหาฟังก์ชันที่เหมาะสมกับข้อมูล

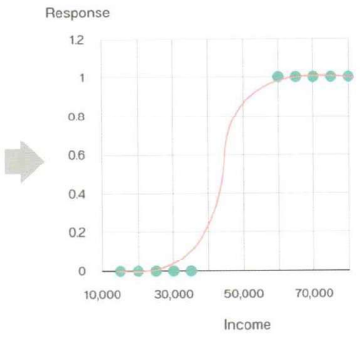
33. ตัวอย่างการสร้าง ML Model ด้วยเทคนิค Logistic Regression

- ตัวอย่าง เช่น ถ้าเรามีข้อมูลที่มีการกระจายตัวในลักษณะ ซึ่งแสดงรายได้ (Income) และการตอบรับโปรโมชัน (Response) จะเห็นว่า ถ้านำข้อมูลไปแสดงบนกราฟทางด้านขวา โดยให้แนวนอนคือ รายได้ และแนวตั้งคือ การตอบรับโปรโมชัน (แปลงค่า 'Yes' ให้เป็น '1' และ 'No' ให้เป็น '0') ดังนั้น กราฟการกระจายตัวลักษณะนี้ จึงไม่ควรใช้ฟังก์ชันของเส้นตรงมาแบ่ง แต่ควรจะเปลี่ยนเป็นฟังก์ชันอื่น นั่นก็คือ ฟังก์ชันซิกมอยด์ (Sigmoid Function) ที่มีลักษณะคล้ายกับรูปตัวอักษร 's' แทน

34. โมเดลของเทคนิค Logistic Regression

- โมเดลของเทคนิค Logistic Regression จะแสดงเป็นสมการคล้ายกันกับเทคนิค Generalized Linear Model
- รูปแสดงข้อมูลและโมเดล Logistic Regression

ID	Income	Response
1	25,000	No
2	20,000	No
3	30,000	No
4	35,000	No
5	15,000	No
6	60,000	Yes
7	75,000	Yes
8	70,000	Yes
9	65,000	Yes
10	80,000	Yes



35. ข้อดี - ข้อจำกัดของเทคนิค Logistic Regression

- ข้อดีของเทคนิค Logistic Regression
  - เป็นโมเดลที่แปลความได้ง่าย โดยดูจากสมการของ Logistic Regression
  - ดูความสำคัญของแอตทริบิวต์หรือตัวแปรได้จากค่าสัมประสิทธิ์ (Coefficient)
  - ทำงานได้อย่างรวดเร็ว
- ข้อจำกัดของเทคนิค Logistic Regression
  - พยากรณ์คำตอบ (Class) ที่เป็นประเภท Category ที่มีแค่ 2 ค่าได้เท่านั้น
  - ทำได้กับแอตทริบิวต์หรือตัวแปรที่เป็นตัวเลข (Number) เท่านั้น
  - ถ้าเป็นแอตทริบิวต์หรือตัวแปรเป็นประเภท Category ต้องแปลงเป็นตัวเลขเสียก่อนด้วยวิธี Dummy Coding หรือ One-Hot Encoding

36. การสร้างโมเดลเพื่อคาดการณ์การเป็นโรคเบาหวาน ด้วยเทคนิค Logistic Regression

- เทคนิค Logistic Regression เพื่อช่วยพยากรณ์ว่าแต่ละคนจะมีโอกาสเป็นโรคเบาหวานเท่าไร โดยข้อมูลนี้ได้มาจาก Dataset: Pima Indians Diabetes Database มีทั้งหมด 9 คอลัมน์

37. Dataset: Pima Indians Diabetes Database

ลำดับที่	แอตทริบิวต์	ความหมาย
1	Pregnancies	จำนวนครั้งในการตั้งครรภ์
2	Glucose	ความเข้มข้นของกลูโคสในร่างกาย
3	BloodPressure	ความดันโลหิต diastolic (mm Hg)
4	SkinThickness	ความหนาของผิวพับ (มม.)
5	Insulin	ระดับอินซูลินในร่างกาย (mu U/ml)
6	BMI	ดัชนีมวลกาย (น้ำหนัก (กก.) / ส่วนสูง (ม.) ^{2})
7	DiabetesPedigreeFunction	ประวัติทางพันธุกรรมของโรคเบาหวานในแผนภูมิต้นไม้ครอบครัว
8	Age	อายุ (ปี)
9	Class	เบาหวาน (positive: เกิด และ negative: ไม่เกิด) (กำหนดให้เป็น label)