มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าพระนครเหนือ
KING MONGKUT'S UNIVERSITY OF TECHNOLOGY NORTH BANGKOK

BUSINESS INTELLIGENCE

Chapter 8
Data Model and Evaluation

Asst.Prof. Sakchai Tangprasert (Ph.D. in IT)
Sakchai.t@sci.kmutnb.ac.th

Analytics and Big Data for Accountants
By Jim Lindell
© 2017 Association of International Certified Professional Accountants, Inc.

วัตถุประสงค์การเรียนรู้

เมื่อสิ้นสุดบทเรียน นักศึกษาสามารถดำเนินการได้ครบถ้วนตั้งแต่การเตรียมข้อมูล (Data Preparation) จนถึงการประเมินผลแบบจำลอง (Evaluation)

1. กำหนด Target, Positive Class และ Input ได้อย่างถูกต้อง
2. เตรียมข้อมูลก่อนสร้างแบบจำลองและป้องกันปัญหา Target Leakage
3. สร้างและเปรียบเทียบแบบจำลองหลายประเภทด้วย Auto Model
4. วิเคราะห์ผลจาก Logistic Regression, Decision Tree และ Feature Importance
5. เปรียบเทียบ Accuracy, Precision, Recall, F1, AUC และ Confusion Matrix อย่างเหมาะสม

รูปแบบการปฏิบัติการ: 19 ขั้นตอนหลัก พร้อมภาคขยายภาพหน้าจอครบทุกไฟล์ใน Prepare, Model และ Evaluation โดยมีคำอธิบาย วิธีอ่านผล และเกณฑ์การตรวจสอบ

กระบวนการดำเนินงานของการปฏิบัติการ

ลำดับการดำเนินงาน: ข้อมูลดิบ ⟶ การเตรียมข้อมูล ⟶ การสร้างแบบจำลอง ⟶ การประเมินผล

1. Load Data	2. Remove Leakage	3. Change Type	4. Auto Model	5. Evaluate
ตรวจสอบจำนวนแถวและคอลัมน์	นำตัวแปรที่เกิดภายหลังเหตุการณ์ออก	กำหนดชนิดข้อมูล Category/Number	กำหนด Predict และ Target	ประเมิน Metrics และ Confusion Matrix

หลักการสำคัญ

ไม่ควรสร้างแบบจำลองจากข้อมูลดิบโดยทันที เนื่องจากอาจเกิด Target Leakage หรือการตีความรหัสประเภทเป็นค่าตัวเลขเชิงปริมาณ ซึ่งทำให้ผลการประเมินคลาดเคลื่อน

ผลลัพธ์ที่กำหนดก่อนสร้างแบบจำลอง: 16 คอลัมน์ ประกอบด้วย 15 nominal และ 1 numerical โดยกำหนด Target = PATIENT_TYPE

แหล่งที่มาของชุดข้อมูล

ก่อนดำเนินการเตรียมข้อมูล ควรทำความเข้าใจแหล่งที่มา วัตถุประสงค์ และข้อจำกัดของชุดข้อมูล

ชุดข้อมูล
COVID-19 Patient Pre-condition Dataset
ผู้เผยแพร่บน Kaggle: Meir Nizri

แหล่งข้อมูลต้นฉบับ
ข้อมูลจากรัฐบาลเม็กซิโก
เป็นข้อมูลผู้ป่วยแบบไม่ระบุตัวตน

รายละเอียดแหล่งข้อมูล

- ใช้ศึกษาข้อมูลอาการ สถานะผู้ป่วย และโรคประจำตัวของผู้ป่วย COVID-19
- เหมาะสำหรับงาน Classification เพื่อพยากรณ์ประเภทผู้ป่วยหรือระดับความเสี่ยง
- ในการปฏิบัติการนี้ ใช้เป็นกรณีศึกษาสำหรับสร้างแบบจำลองพยากรณ์ PATIENT_TYPE: Outpatient หรือ Hospitalized
- สิทธิการใช้งานบน Kaggle: CC0 Public Domain

Kaggle URL: https://www.kaggle.com/datasets/meirnizri/covid19-dataset

ข้อควรพิจารณา: ชุดข้อมูลนี้ใช้เพื่อการเรียนรู้และการวิจัยเชิงข้อมูล ไม่ควรใช้เป็นเครื่องมือวินิจฉัยหรือใช้ตัดสินใจทางการแพทย์โดยตรง

ลักษณะของชุดข้อมูลที่ใช้ในการปฏิบัติการ

ข้อมูล 1 แถวแทนผู้ป่วย 1 ราย หรือ 1 ระเบียน

จำนวนระเบียน	จำนวนคอลัมน์	ตัวแปรเป้าหมาย	ประเภทงานวิเคราะห์
1,048,575	21	PATIENT_TYPE	Binary Classification

การกระจายของคลาสในตัวแปรเป้าหมาย

PATIENT_TYPE	ความหมาย	จำนวน
1	Outpatient / Returned home	848,544
2	Hospitalized	200,031

กลุ่มตัวแปรสำคัญ

- ข้อมูลพื้นฐาน: SEX, AGE, USMER, MEDICAL_UNIT
- สถานะ/อาการ: PATIENT_TYPE, PNEUMONIA
- โรคประจำตัว: DIABETES, COPD, ASTHMA, HIPERTENSION, RENAL_CHRONIC ฯลฯ
- ตัวแปรที่เกิดภายหลัง: DATE_DIED, INTUBED, ICU, CLASIFFICATION_FINAL

ประเด็นสำคัญในการเรียนรู้: ชุดข้อมูลมีความไม่สมดุลของคลาส โดย Outpatient มีประมาณ 80.9% และ Hospitalized มีประมาณ 19.1% ดังนั้นการประเมินผลควรพิจารณา Recall, F1 และ AUC ร่วมกับ Accuracy

การตีความรหัสข้อมูลและข้อควรพิจารณา

ควรตีความรหัสข้อมูลอย่างถูกต้องก่อนกำหนดชนิดข้อมูลและสร้างแบบจำลอง

รหัสข้อมูลที่ใช้ในการปฏิบัติการ

ตัวแปร	รหัส	ความหมาย
PATIENT_TYPE	1 / 2	Outpatient / Hospitalized
SEX	1 / 2	Female / Male
Yes-No variables	1 / 2	Yes / No
Missing codes	97, 98, 99	Not applicable / Unknown / Missing

แนวทางการเตรียมข้อมูล

- กำหนด AGE เป็น Number เนื่องจากเป็นค่าปริมาณเชิงตัวเลข
- กำหนดรหัส 1/2/98/99 เป็น Category/Nominal เนื่องจากเป็นรหัสประเภท
- กำหนด PATIENT_TYPE เป็นตัวแปรเป้าหมาย (Target)
- กำหนด Hospitalized เป็น Positive Class

คอลัมน์ที่กำหนดให้นำออกก่อนสร้างแบบจำลอง
PREGNANT, DATE_DIED, INTUBED, ICU, CLASIFFICATION_FINAL

สาเหตุการดำเนินการ
ลดความซับซ้อนของการปฏิบัติการและป้องกัน Target Leakage จากข้อมูลที่เกิดขึ้นภายหลังการรักษา

เกณฑ์ความพร้อมก่อนเข้าสู่ขั้นตอน MODEL: ข้อมูลต้องเหลือ 16 คอลัมน์ ประกอบด้วย 15 nominal และ 1 numerical และต้องไม่มีคอลัมน์ที่ก่อให้เกิด Leakage

รายละเอียดตัวแปรในชุดข้อมูล COVID-19 Patient Dataset (1/2)

องค์ประกอบของข้อมูลจำนวน 21 คอลัมน์ — ส่วนที่ 1

ลำดับ	ตัวแปร	ความหมาย / ตัวอย่างค่า
1	USMER	ตัวบ่งชี้ระดับหน่วยบริการที่ผู้ป่วยได้รับการรักษา (เก็บเป็นรหัสกลุ่ม)
2	MEDICAL_UNIT	ประเภทสถาบัน/หน่วยงานในระบบสุขภาพแห่งชาติที่ให้การรักษา (เก็บเป็นรหัส)
3	SEX	เพศของผู้ป่วย: 1 = Female, 2 = Male
4	PATIENT_TYPE	ประเภทการดูแล: 1 = กลับบ้าน/Outpatient, 2 = Hospitalized — ใช้เป็น Target ใน Lab นี้
5	DATE_DIED	วันที่เสียชีวิต; ค่า 9999-99-99 หมายถึงไม่มีวันที่เสียชีวิตบันทึกไว้
6	INTUBED	ผู้ป่วยได้รับการใส่ท่อ/เครื่องช่วยหายใจหรือไม่
7	PNEUMONIA	มีภาวะปอดอักเสบหรือไม่
8	AGE	อายุของผู้ป่วย เป็นตัวแปรเชิงตัวเลข (Numerical)
9	PREGNANT	ตั้งครรภ์หรือไม่; ค่า 97 พบในกรณีไม่เกี่ยวข้อง/ไม่มีข้อมูล เช่น ผู้ชาย
10	DIABETES	มีโรคเบาหวานเป็นโรคประจำตัวหรือไม่
11	COPD	มีโรคปอดอุดกั้นเรื้อรัง (Chronic Obstructive Pulmonary Disease) หรือไม่

หมายเหตุ: ตัวแปร Yes/No ส่วนใหญ่ใช้รหัส 1 = Yes, 2 = No และ 97/99 = Missing/Unknown ตามคำอธิบายของชุดข้อมูล

รายละเอียดตัวแปรในชุดข้อมูล COVID-19 Patient Dataset (2/2)

องค์ประกอบของข้อมูลจำนวน 21 คอลัมน์ — ส่วนที่ 2

ลำดับ	ตัวแปร	ความหมาย / ตัวอย่างค่า
12	ASTHMA	มีโรคหอบหืดหรือไม่
13	INMSUPR	มีภาวะภูมิคุ้มกันบกพร่อง/ได้รับการกดภูมิคุ้มกันหรือไม่
14	HIPERTENSION	มีโรคความดันโลหิตสูงหรือไม่
15	OTHER_DISEASE	มีโรคอื่นนอกเหนือจากรายการที่กำหนดหรือไม่
16	CARDIOVASCULAR	มีโรคหัวใจหรือหลอดเลือดหรือไม่
17	OBESITY	มีภาวะอ้วนหรือไม่
18	RENAL_CHRONIC	มีโรคไตเรื้อรังหรือไม่
19	TOBACCO	มีประวัติใช้ยาสูบหรือไม่
20	CLASIFFICATION_FINAL	ผลการจำแนก COVID ขั้นสุดท้าย: ค่า 1–3 = ได้รับการวินิจฉัย COVID ในระดับต่าง ๆ; 4 ขึ้นไป = ไม่เป็นพาหะ/ผลไม่สรุปตามคำอธิบาย Dataset
21	ICU	ผู้ป่วยถูกนำเข้ารักษาในหอผู้ป่วยวิกฤต (ICU) หรือไม่

หมายเหตุ: ตัวแปร Yes/No ส่วนใหญ่ใช้รหัส 1 = Yes, 2 = No และ 97/99 = Missing/Unknown ตามคำอธิบายของชุดข้อมูล

ตัวอย่างระเบียนจากชุดข้อมูล

ตัวอย่าง 5 ระเบียนแรกจากไฟล์ที่ใช้ในการปฏิบัติการ โดยเลือกแสดงบางคอลัมน์เพื่อความสะดวกในการนำเสนอ

SEX	PATIENT_TYPE	PNEUMONIA	AGE	DIABETES	HIPERTENSION	OBESITY	RENAL_CHRONIC	DATE_DIED	ICU
1	1	1	65	2	1	2	2	03/05/2020	97
2	1	1	72	2	1	1	1	03/06/2020	97
2	2	2	55	1	2	2	2	09/06/2020	2
1	1	2	53	2	2	2	2	12/06/2020	97
2	1	2	68	1	1	2	2	21/06/2020	97

ตัวอย่างการตีความรหัสข้อมูล

- SEX: 1 = Female, 2 = Male
- PATIENT_TYPE: 1 = Outpatient, 2 = Hospitalized
- กลุ่มโรคส่วนใหญ่: 1 = Yes, 2 = No
- ICU: 1 = Yes, 2 = No, 97/99 = Missing/Not applicable

ข้อสังเกตก่อนสร้างแบบจำลอง

- รหัส 1/2 เป็นค่าประเภท (Category) ไม่ใช่ค่าปริมาณเชิงตัวเลข
- DATE_DIED, INTUBED และ ICU เป็นข้อมูลที่เกิดขึ้นภายหลัง จึงไม่นำมาใช้เป็น Input สำหรับการพยากรณ์ Hospitalized
- AGE เป็นค่าปริมาณเชิงตัวเลข จึงกำหนดเป็น Numerical

ประเด็นสำคัญในการเรียนรู้: ข้อมูล 1 แถวแทนผู้ป่วย 1 ระเบียน และแต่ละคอลัมน์แทนคุณลักษณะ (Feature) หรือผลลัพธ์ที่บันทึกของผู้ป่วยรายนั้น

ขั้นตอนที่ 1 การนำเข้าข้อมูลและการตรวจสอบภาพรวมชุดข้อมูล

รูปที่ 1 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

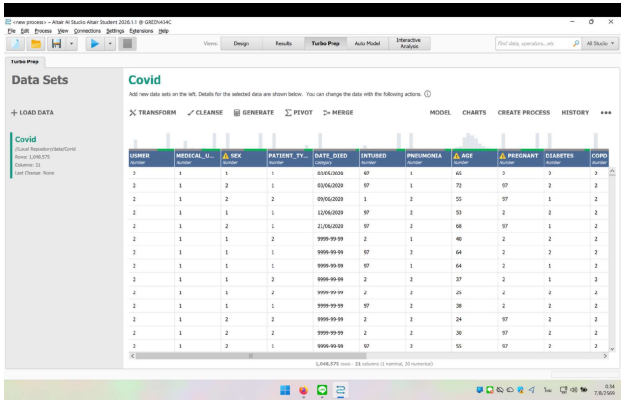

วิธีดำเนินการในโปรแกรม: ตรวจสอบ Data Sets ⟶ Rows/Columns ⟶ ตรวจสอบคอลัมน์ทั้งหมด ⟶ ยังไม่เข้าสู่ขั้นตอน MODEL

วัตถุประสงค์

- ยืนยันว่าชุดข้อมูลได้รับการนำเข้าอย่างครบถ้วน และเป็นชุดข้อมูลที่กำหนดสำหรับการวิเคราะห์
- ทำความเข้าใจโครงสร้างของข้อมูลดิบก่อนดำเนินการปรับปรุงข้อมูล

สาเหตุการดำเนินการ

- จำนวนแถว จำนวนคอลัมน์ และชนิดข้อมูลเป็นข้อมูลอ้างอิงสำหรับตรวจสอบความถูกต้องในขั้นตอนถัดไป
- ควรจำแนกตัวแปรเป้าหมาย ตัวแปรนำเข้า และตัวแปรที่อาจเปิดเผยผลลัพธ์ภายหลังก่อนสร้างแบบจำลอง

ผลลัพธ์และเกณฑ์การตรวจสอบ

- ข้อมูลมี 1,048,575 แถว และ 21 คอลัมน์
- พบ PATIENT_TYPE รวมถึง DATE_DIED, INTUBED, ICU และ CLASIFFICATION_FINAL

ขั้นตอนที่ 2 การนำคอลัมน์ PREGNANT ออกจากชุดข้อมูล

รูปที่ 2 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

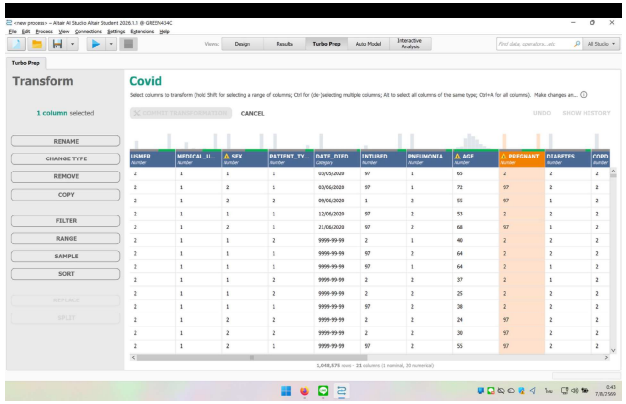

วิธีดำเนินการในโปรแกรม: เลือก PREGNANT ⟶ REMOVE ⟶ COMMIT TRANSFORMATION

วัตถุประสงค์

- ลดความซับซ้อนของการปฏิบัติการเบื้องต้น โดยนำ PREGNANT ออกจากชุดข้อมูล
- ป้องกันการตีความรหัส 97 (Not applicable) เป็นค่าปกติของตัวแปร

สาเหตุการดำเนินการ

- PREGNANT ใช้กับผู้ป่วยบางกลุ่มเท่านั้น จึงมีค่าที่ไม่เกี่ยวข้องเชิงโครงสร้างเป็นจำนวนมาก
- หากใช้รหัส 97 โดยไม่จัดการ แบบจำลองอาจเรียนรู้รูปแบบของรหัสแทนความหมายของตัวแปร

ผลลัพธ์และเกณฑ์การตรวจสอบ

- คอลัมน์ PREGNANT ไม่ปรากฏในตาราง
- จำนวนคอลัมน์ลดจาก 21 เหลือ 20

ขั้นตอนที่ 3 การตรวจสอบผลหลังการนำคอลัมน์ PREGNANT ออก

รูปที่ 3 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

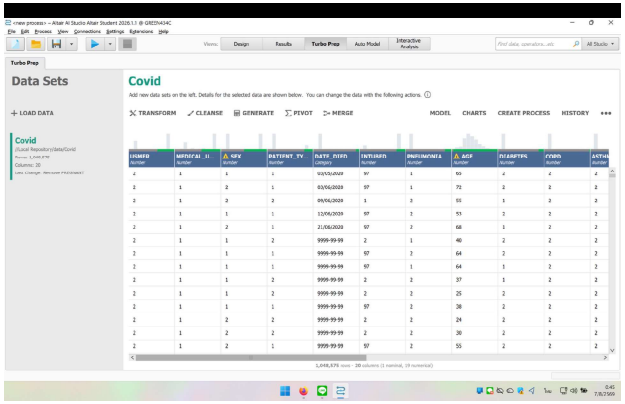

วิธีดำเนินการในโปรแกรม: กลับสู่หน้าหลัก Turbo Prep ⟶ ตรวจสอบ Last Change และจำนวน Columns ⟶ เตรียมดำเนินการกับตัวแปร Leakage ในขั้นตอนถัดไป

วัตถุประสงค์

- ตรวจสอบผลของการเปลี่ยนแปลงก่อนดำเนินการในขั้นตอนถัดไป
- ส่งเสริมกระบวนการควบคุมคุณภาพข้อมูล (Data Quality Control) อย่างเป็นลำดับ

สาเหตุการดำเนินการ

- การตรวจสอบทันทีช่วยให้สามารถระบุการลบคอลัมน์ที่ไม่ถูกต้องและแก้ไขได้อย่างรวดเร็ว
- ค่า Last Change และจำนวนคอลัมน์ใช้ยืนยันว่าคำสั่งก่อนหน้าได้รับการ Commit แล้ว

ผลลัพธ์และเกณฑ์การตรวจสอบ

- Last Change แสดง Remove PREGNANT
- ข้อมูลเหลือ 20 คอลัมน์ และยังพบ DATE_DIED กับ INTUBED

ขั้นตอนที่ 4 การระบุและนำคอลัมน์ที่ก่อให้เกิด Target Leakage ออก

รูปที่ 4 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

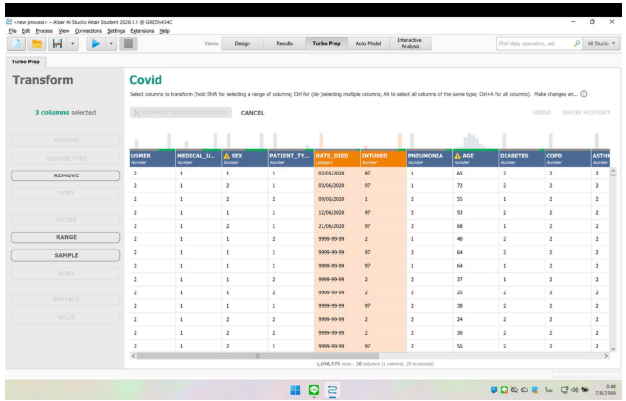

วัตถุประสงค์

- นำตัวแปรที่เกิดขึ้นภายหลังการประเมินผู้ป่วยออกจากชุดตัวแปรนำเข้า
- ป้องกันปัญหา Target Leakage ก่อนฝึกแบบจำลอง

สาเหตุการดำเนินการ

- DATE_DIED และ INTUBED สะท้อนเหตุการณ์หรือระดับความรุนแรงที่เกิดขึ้นภายหลัง
- หากนำตัวแปรดังกล่าวมาใช้ แบบจำลองอาจให้ค่าประสิทธิภาพสูงเกินจริงจากข้อมูลที่ไม่ควรทราบ ณ เวลาพยากรณ์

ผลลัพธ์และเกณฑ์การตรวจสอบ

- DATE_DIED และ INTUBED ถูกเลือกเป็นคอลัมน์ที่จะนำออก
- PATIENT_TYPE ยังคงอยู่ในชุดข้อมูลและไม่ถูกเลือกโดยไม่ตั้งใจ

วิธีดำเนินการในโปรแกรม: กด Ctrl ค้างไว้ ⟶ เลือก DATE_DIED และ INTUBED ⟶ REMOVE ⟶ COMMIT

ขั้นตอนที่ 5 การตรวจสอบผลหลังการนำ DATE_DIED และ INTUBED ออก

รูปที่ 5 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

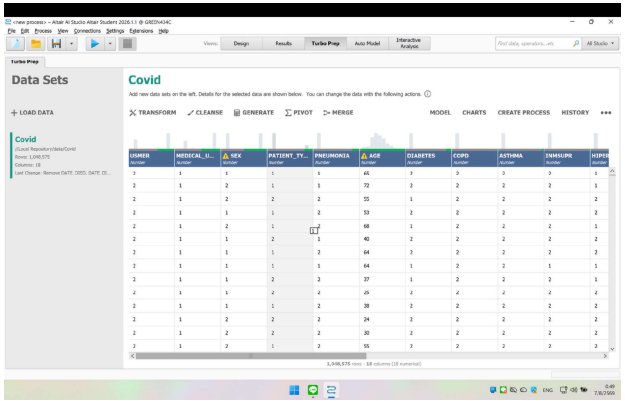

วัตถุประสงค์

- ยืนยันว่าตัวแปร Leakage ชุดแรกถูกนำออกเรียบร้อยแล้ว
- ตรวจสอบตัวแปรที่อยู่ทางด้านขวาของคาราง ก่อนสิ้นสุดขั้นตอนการคัดเลือกคอลัมน์

สาเหตุการดำเนินการ

- คารางมีหลายคอลัมน์และต้องเลื่อนในแนวนอน จึงอาจมีตัวแปรสำคัญที่ยังไม่ปรากฏในพื้นที่แสดงผล
- การตรวจสอบจำนวนคอลัมน์ช่วยยืนยันว่าการนำตัวแปรออกเป็นไปตามแผนที่กำหนด

ผลลัพธ์และเกณฑ์การตรวจสอบ

- DATE_DIED และ INTUBED ไม่ปรากฏในชุดข้อมูล
- ข้อมูลเหลือ 18 คอลัมน์ และยังต้องนำ ICU กับ CLASIFFICATION_FINAL ออก

วิธีดำเนินการในโปรแกรม: ตรวจสอบ Columns = 18 ⟶ เลื่อนแถบแนวนอนไปทางขวา ⟶ ตรวจหา ICU และ CLASIFFICATION_FINAL

ขั้นตอนที่ 6 การนำ ICU และ CLASIFFICATION_FINAL ออกเพื่อให้เหลือ 16 คอลัมน์

รูปที่ 6 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

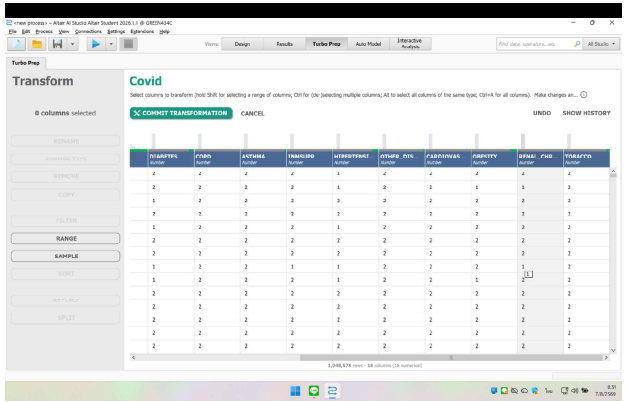

วัตถุประสงค์

- นำตัวแปร Leakage ที่เหลือออกให้ครบถ้วน และกำหนดขอบเขตข้อมูล ณ เวลาพยากรณ์
- เตรียมชุดข้อมูลให้พร้อมสำหรับการกำหนดชนิดของตัวแปร

สาเหตุการดำเนินการ

- ICU เป็นเหตุการณ์ที่เกิดขึ้นภายหลังการรับไว้รักษา ส่วน CLASIFFICATION_FINAL เป็นผลการจำแนกขั้นสุดท้าย
- การใช้ข้อมูลที่เกิดขึ้นภายหลังจะทำให้การพยากรณ์ไม่สะท้อนสถานการณ์ก่อนทราบผลอย่างแท้จริง

ผลลัพธ์และเกณฑ์การตรวจสอบ

- ข้อมูลเหลือ 1,048,575 แถว และ 16 คอลัมน์
- ไม่พบ PREGNANT, DATE_DIED, INTUBED, ICU และ CLASIFFICATION_FINAL

วิธีดำเนินการในโปรแกรม: เลือก ICU และ CLASIFFICATION_FINAL ⟶ REMOVE ⟶ COMMIT TRANSFORMATION

ขั้นตอนที่ 7 การกำหนดชนิดข้อมูลของ PATIENT_TYPE เป็น Category

รูปที่ 7 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

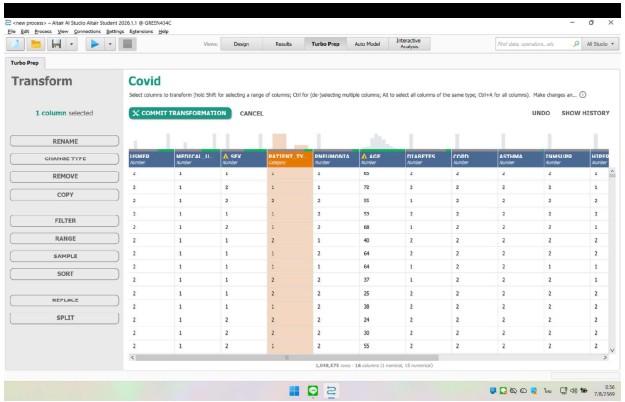

วัตถุประสงค์

- กำหนดให้โปรแกรมตีความ PATIENT_TYPE เป็นคลาส ไม่ใช่ค่าตัวเลขเชิงปริมาณ
- เตรียมตัวแปรเป้าหมายสำหรับ Binary Classification

สาเหตุการดำเนินการ

- ค่า 1 และ 2 เป็นรหัสของ Outpatient และ Hospitalized โดยไม่มีความหมายเชิงปริมาณระหว่างค่าทั้งสอง
- หากคงชนิดข้อมูลเป็น Number โปรแกรมอาจจัดการตัวแปรเป้าหมายไม่เหมาะสมกับงาน Classification

ผลลัพธ์และเกณฑ์การตรวจสอบ

- PATIENT_TYPE เปลี่ยนจาก Number เป็น Category/Nominal
- ค่าข้อมูลยังคงเป็นรหัส 1 และ 2 ตามเดิม

วิธีดำเนินการในโปรแกรม: PATIENT_TYPE ⟶ CHANGE TYPE ⟶ Change to nominal ⟶ APPLY ⟶ COMMIT

ขั้นตอนที่ 8 การกำหนดตัวแปรรหัสกลุ่มชุดแรกเป็น Category

รูปที่ 8 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

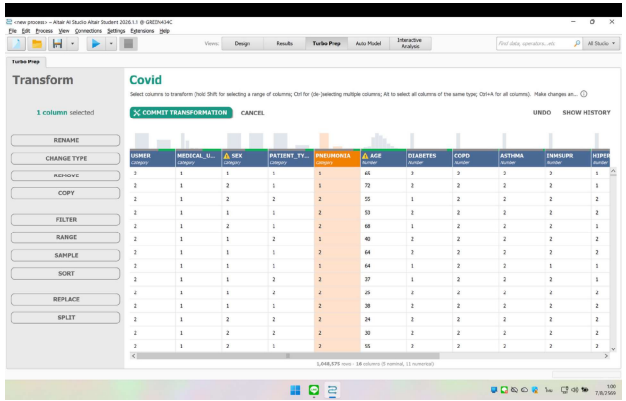

วัตถุประสงค์

- กำหนดชนิดข้อมูลของตัวแปรรหัสกลุ่มชุดแรกให้สอดคล้องกับความหมายของข้อมูล
- ป้องกันการตีความรหัสกลุ่มเป็นค่าปริมาณเชิงตัวเลข

สาเหตุการดำเนินการ

- USMER, MEDICAL_UNIT, SEX และ PNEUMONIA เป็นรหัสประเภท ไม่ใช่ตัวเลขต่อเนื่อง
- การกำหนดเป็น Category ช่วยให้แบบจำลองจัดการแต่ละกลุ่มตามความหมายเชิงประเภทแทนการใช้ระยะห่างของตัวเลข

ผลลัพธ์และเกณฑ์การตรวจสอบ

- USMER, MEDICAL_UNIT, SEX, PATIENT_TYPE และ PNEUMONIA เป็น Category
- สรุปชนิดข้อมูลแสดงประมาณ 5 nominal และ 11 numerical

วิธีดำเนินการในโปรแกรม: เลือกตัวแปรรหัสกลุ่มชุดแรก ⟶ CHANGE TYPE ⟶ Change to nominal ⟶ APPLY ⟶ COMMIT

ขั้นตอนที่ 9 การกำหนดตัวแปรโรคประจำตัวที่เหลือเป็น Category

รูปที่ 9 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

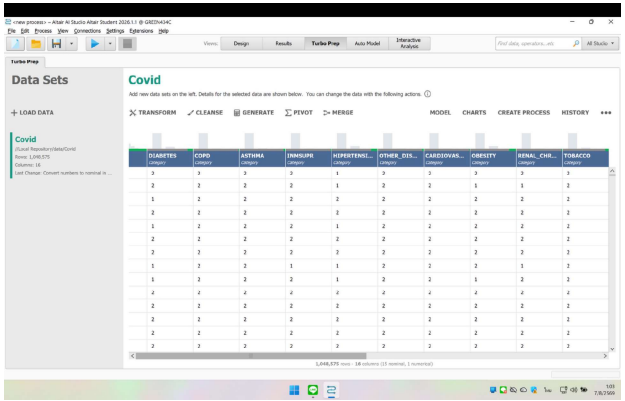

วัตถุประสงค์

- กำหนดตัวแปรโรคประจำตัวทั้งหมดให้เป็นข้อมูลประเภท Category
- คง AGE เป็นตัวแปรเชิงปริมาณเพียงตัวเดียว

สาเหตุการดำเนินการ

- ค่า 1/2/98/99 ของตัวแปรโรคประจำตัวเป็นรหัส Yes/No/Unknown ไม่ใช่ระดับความมากน้อย
- หากคงเป็น Number แบบจำลองเชิงเส้นอาจตีความระยะห่างระหว่างรหัส 98/99 ไม่สอดคล้องกับความหมายของข้อมูล

ผลลัพธ์และเกณฑ์การตรวจสอบ

- สรุปชนิดข้อมูลเป็น 15 nominal และ 1 numerical
- AGE เป็น Number เพียงคอลัมน์เดียว

วิธีดำเนินการในโปรแกรม: เลือก DIABETES ถึง TOBACCO ⟶ CHANGE TYPE ⟶ nominal ⟶ APPLY ⟶ COMMIT

ขั้นตอนที่ 10 การตรวจสอบกรณีเข้าสู่ Auto Model ด้วยชุดข้อมูลที่ไม่ถูกต้อง

รูปที่ 10 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

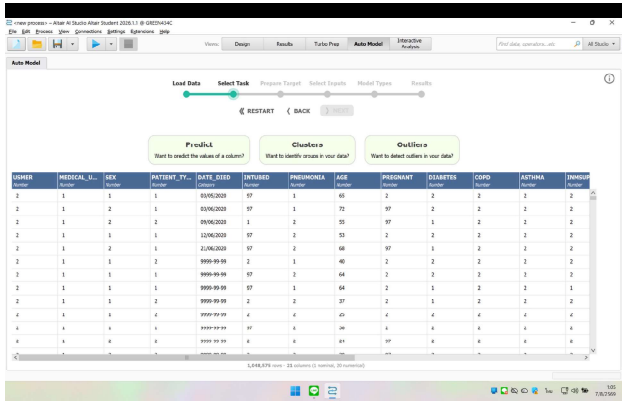

วัตถุประสงค์

- ตรวจสอบว่าชุดข้อมูลที่ใช้สร้างแบบจำลองเป็นชุดข้อมูลที่ผ่านการเตรียมแล้ว
- ระบุข้อผิดพลาดจากการเข้าสู่ Auto Model ด้วยข้อมูลต้นฉบับ

สาเหตุการดำเนินการ

- การเข้าสู่ Auto Model โดยตรงอาจทำให้โปรแกรมอ้างอิงชุดข้อมูลเดิมจำนวน 21 คอลัมน์
- ผลจากข้อมูลดิบอาจมี Target Leakage และชนิดข้อมูลที่ยังไม่ได้ปรับแก้ จึงไม่เหมาะสำหรับการเปรียบเทียบแบบจำลอง

ผลลัพธ์และเกณฑ์การตรวจสอบ

- หากพบ 21 คอลัมน์ หรือยังพบ DATE_DIED, INTUBED หรือ PREGNANT แสดงว่าใช้ชุดข้อมูลไม่ถูกต้อง
- ต้องกลับสู่ Turbo Prep และเข้าสู่ Auto Model จากชุดข้อมูลที่ผ่านการเตรียมแล้ว

วิธีดำเนินการในโปรแกรม: หากพบข้อมูลดิบ ⟶ กลับสู่ Turbo Prep ⟶ ใช้ปุ่ม MODEL จากชุดข้อมูลที่ผ่านการเตรียมแล้ว

ขั้นตอนที่ 11 การเข้าสู่ Auto Model ด้วยชุดข้อมูลที่ผ่านการเตรียมแล้ว

รูปที่ 11 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

ข้อสอบ 108–109

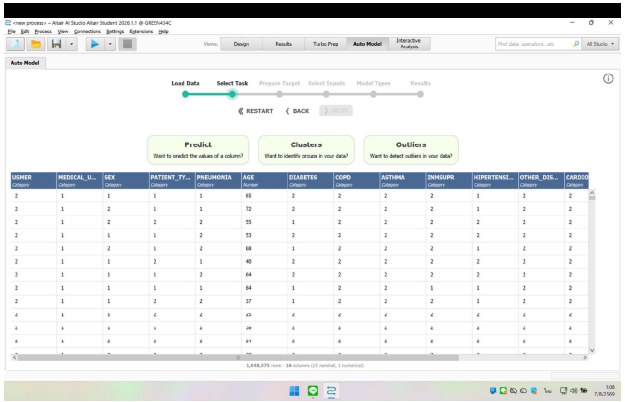

วัตถุประสงค์

- ส่งข้อมูลที่ผ่านการเตรียมแล้วเข้าสู่ Auto Model
- กำหนดชุดตัวแปรนำเข้าและชนิดข้อมูลให้ตรงตามที่ออกแบบไว้

สาเหตุการดำเนินการ

- การเข้าสู่ Auto Model ผ่านปุ่ม MODEL ใน Turbo Prep ช่วยให้โปรแกรมใช้การปรับข้อมูลล่าสุด
- ทุกแบบจำลองจะได้รับข้อมูลชุดเดียวกัน จึงสามารถเปรียบเทียบผลได้อย่างเป็นธรรม

ผลลัพธ์และเกณฑ์การตรวจสอบ

- ข้อมูลมี 16 คอลัมน์ ประกอบด้วย 15 nominal และ 1 numerical
- ไม่พบคอลัมน์ Leakage ที่นำออกไปแล้ว

วิธีดำเนินการในโปรแกรม: Turbo Prep ⟶ MODEL ⟶ ตรวจสอบ 16 columns / 15 nominal / 1 numerical

ขั้นตอนที่ 12 การกำหนดประเภทงานวิเคราะห์เป็น Predict

รูปที่ 12 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

ข้อสอบ 110, 117

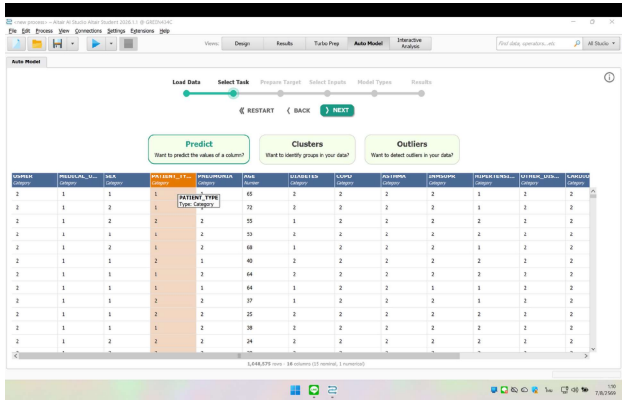

วิธีดำเนินการในโปรแกรม: เลือก Predict ⟶ NEXT

วัตถุประสงค์

- กำหนดประเภทงานวิเคราะห์เป็น Supervised Prediction
- ระบุให้ Auto Model พยากรณ์ค่าของตัวแปรเป้าหมาย

สาเหตุการดำเนินการ

- โจทย์มีคำตอบเดิมใน PATIENT_TYPE จึงเป็นงาน Classification ไม่ใช่ Clustering หรือ Outlier Detection
- การเลือกประเภทงานวิเคราะห์ที่ไม่สอดคล้องกับวัตถุประสงค์จะทำให้ขั้นตอนและตัวชี้วัดผลไม่เหมาะสม

ผลลัพธ์และเกณฑ์การตรวจสอบ

- ตัวเลือก Predict ถูกกำหนดเป็นงานวิเคราะห์
- ปุ่ม NEXT พร้อมสำหรับเข้าสู่ขั้นตอนถัดไป

ขั้นตอนที่ 13 การกำหนดตัวแปรเป้าหมายและการตรวจสอบความไม่สมดุลของคลาส

รูปที่ 13 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

ข้อสอบ 108–109

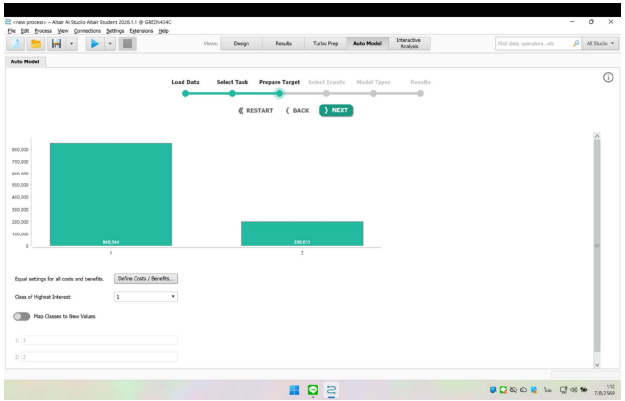

วิธีดำเนินการในโปรแกรม: Prepare Target ⟶ เลือก PATIENT_TYPE ⟶ วิเคราะห์กราฟจำนวนแต่ละคลาสก่อนกด NEXT

วัตถุประสงค์

- กำหนด Target = PATIENT_TYPE และตรวจสอบสัดส่วนของสองคลาส
- ประเมินปัญหา Class Imbalance ก่อนเลือกตัวชี้วัดประสิทธิภาพ

สาเหตุการดำเนินการ

- Outpatient มี 848,544 ราย และ Hospitalized มี 200,031 ราย หรือประมาณ 80.9% ต่อ 19.1%
- ภายใต้สัดส่วนดังกล่าว การพยากรณ์ทุกกระเบียนเป็น Outpatient จะได้ Accuracy ประมาณ 80.9% จึงไม่ควรพิจารณา Accuracy เพียงค่าเดียว

ผลลัพธ์และเกณฑ์การตรวจสอบ

- กราฟแสดงจำนวน 848,544 และ 200,031 ตามลำดับ
- ระบุได้ว่า Hospitalized เป็น Minority Class

ขั้นตอนที่ 14 การกำหนดชื่อคลาสให้สื่อความหมาย

รูปที่ 14 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

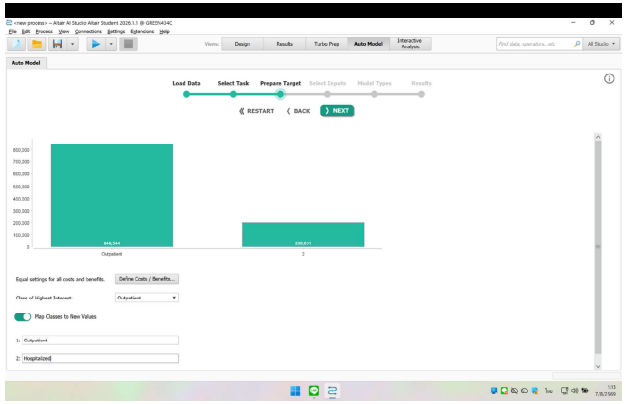

วิธีดำเนินการในโปรแกรม: เปิด Map Classes to New Values ⟶ กำหนด 1 = Outpatient และ 2 = Hospitalized

วัตถุประสงค์

- เปลี่ยนรหัสคลาส 1/2 ให้เป็นชื่อที่สามารถตีความได้โดยตรง
- เตรียมผลลัพธ์ใน Confusion Matrix และ Predictions ให้มีความชัดเจน

สาเหตุการดำเนินการ

- ชื่อ Outpatient และ Hospitalized ช่วยลดความคลาดเคลื่อนในการตีความกราฟ ตาราง และรายงาน
- การ Mapping เปลี่ยนเฉพาะชื่อที่ใช้แสดงผล โดยไม่เปลี่ยนจำนวนหรือสาระสำคัญของข้อมูล

ผลลัพธ์และเกณฑ์การตรวจสอบ

- กำหนด 1 = Outpatient และ 2 = Hospitalized
- ตรวจสอบ Class of Highest Interest ก่อนเข้าสู่ขั้นตอนถัดไป

ขั้นตอนที่ 15 การกำหนด Hospitalized เป็น Positive Class

รูปที่ 15 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

ข้อสอบ 114

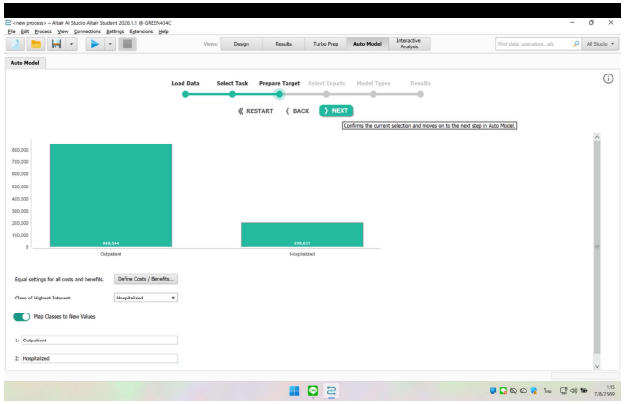

วิธีดำเนินการในโปรแกรม: Class of Highest Interest ⟶ Hospitalized ⟶ NEXT

วัตถุประสงค์

- กำหนด Hospitalized เป็น Positive Class หรือ Class of Highest Interest
- ให้ตัวชี้วัดประสิทธิภาพสะท้อนความสามารถในการตรวจพบผู้ป่วยที่ควรจัดเป็น Hospitalized

สาเหตุการดำเนินการ

- Precision, Recall, F1, TP และ FN คำนวณโดยอ้างอิงคลาสที่กำหนดเป็น Positive Class
- หากกำหนด Outpatient เป็น Positive Class ค่า Recall จะตอบคำถามที่แตกต่างจากวัตถุประสงค์ของกรณีศึกษา

ผลลัพธ์และเกณฑ์การตรวจสอบ

- Class of Highest Interest = Hospitalized
- การกระจายคลาสยังคงเป็น Outpatient 848,544 ราย และ Hospitalized 200,031 ราย

ขั้นตอนที่ 16 การกำหนดตัวแปรนำเข้าให้ครบ 15 ตัวแปร

รูปที่ 16 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

ข้อสอบ 113, 115

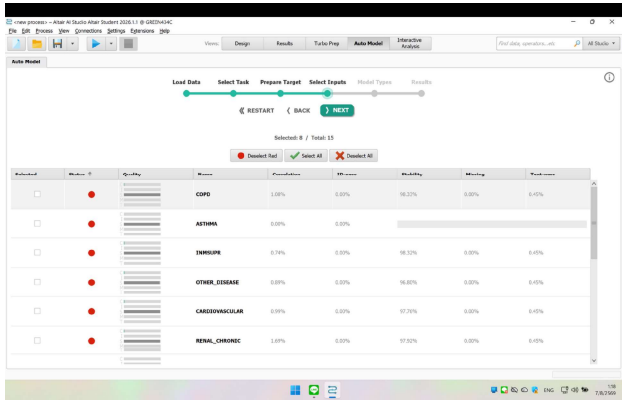

วัตถุประสงค์

- กำหนดชุดตัวแปรนำเข้าสำหรับการเปรียบเทียบเบื้องต้นให้ครบทั้ง 15 ตัวแปร
- จัดทำเกณฑ์อ้างอิง (Benchmark) ก่อนดำเนินการ Feature Selection ในการทดลองภายหลัง

สาเหตุการดำเนินการ

- Auto Model อาจนำบางตัวแปรออกโดยอัตโนมัติตามเกณฑ์ Stability หรือ Correlation
- ในการปฏิบัติการนี้ต้องการวิเคราะห์ผลของตัวแปรทุกตัวและฝึกอ่าน Feature Importance จึงกำหนดตัวแปรทั้งหมดหลังจากนำ Leakage ออกแล้ว

ผลลัพธ์และเกณฑ์การตรวจสอบ

- Selected = 15 / Total = 15
- PATIENT_TYPE ไม่อยู่ในรายการ Inputs เนื่องจากถูกกำหนดเป็น Target

วิธีดำเนินการในโปรแกรม: เลือก Select All ⟶ ตรวจสอบ Selected 15/15 ⟶ NEXT

ขั้นตอนที่ 17 การเลือกประเภทแบบจำลองสำหรับการทดสอบ

รูปที่ 17 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

ข้อสอบ 117

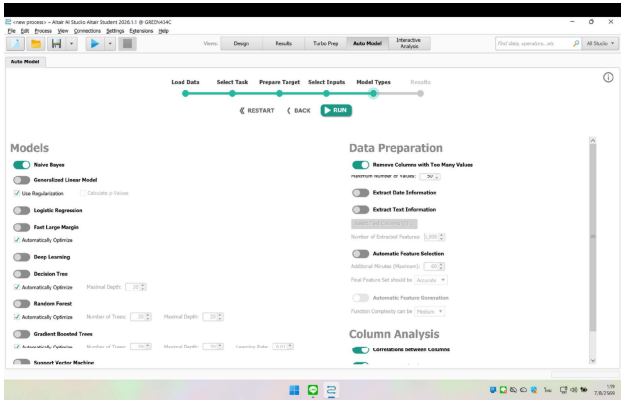

วัตถุประสงค์

- เลือกอัลกอริทึมหลายประเภทเพื่อเปรียบเทียบประสิทธิภาพและความสามารถในการอธิบายผล
- สร้างเกณฑ์เปรียบเทียบแบบจำลอง (Model Benchmark) แทนการพิจารณาแบบจำลองเพียงประเภทเดียว

สาเหตุการดำเนินการ

- แบบจำลองแต่ละประเภทมีสมมติฐาน ความซับซ้อน เวลาในการประมวลผล และความสามารถในการเรียนรู้รูปแบบแตกต่างกัน
- ไม่มีแบบจำลองประเภทใดที่เหมาะสมที่สุดกับทุกชุดข้อมูล จึงควรประเมินจากชุดข้อมูลทดสอบเดียวกัน

ผลลัพธ์และเกณฑ์การตรวจสอบ

- สวิตช์ของแบบจำลองที่กำหนดเป็นสีเขียว
- เตรียมทดสอบ Naive Bayes, GLM, Logistic Regression, Decision Tree, Random Forest, GBT, SVM และแบบจำลองอื่นที่เลือก

วิธีดำเนินการในโปรแกรม: เปิดสวิตช์ Model Types ที่ต้องการทดสอบ ⟶ ตรวจสอบรายชื่อแบบจำลองให้ครบถ้วน

ขั้นตอนที่ 18 การทดสอบหลายแบบจำลองและการปิดการปรับพารามิเตอร์อัตโนมัติในรอบแรก

รูปที่ 18 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

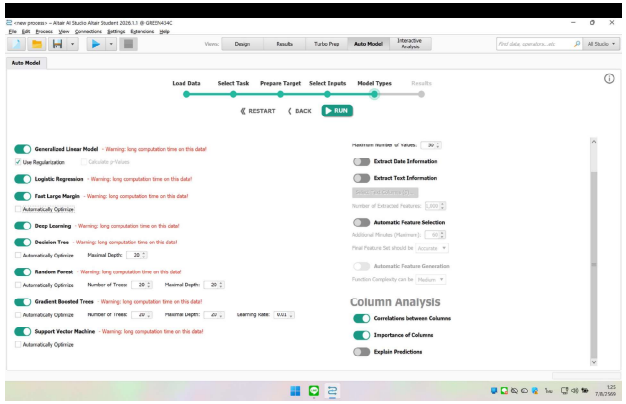

วัตถุประสงค์

- สร้างค่าประสิทธิภาพพื้นฐาน (Baseline) ของหลายแบบจำลองด้วยพารามิเตอร์มาตรฐานก่อนดำเนินการ Tuning
- ควบคุมระยะเวลาประมวลผลและการใช้ทรัพยากรเมื่อชุดข้อมูลมีมากกว่า 1 ล้านระเบียน

สาเหตุการดำเนินการ

- Automatically Optimize จะฝึกแบบจำลองซ้ำหลายชุดและเพิ่มระยะเวลาประมวลผลอย่างมาก
- ควรเปรียบเทียบผลพื้นฐานก่อน แล้วจึงปรับพารามิเตอร์เฉพาะแบบจำลองที่มีศักยภาพสูงเพื่อให้กระบวนการทดลองเป็นระบบ

ผลลัพธ์และเกณฑ์การตรวจสอบ

- แบบจำลองที่กำหนดลูกเปิดใช้งาน และ Automatically Optimize ถูกปิดในรอบแรก
- ข้อความ Warning: long computation time เป็นคำเตือนด้านระยะเวลาประมวลผล ไม่ใช่ข้อผิดพลาดของระบบ

วิธีดำเนินการในโปรแกรม: เปิดแบบจำลองที่ต้องการ ⟶ ปิด Automatically Optimize ⟶ คง Column Analysis ⟶ RUN

ขั้นตอนที่ 19 การติดตามผลการประมวลผลและการวิเคราะห์หน้า Comparison

รูปที่ 19 ภาพประกอบการดำเนินการ วัตถุประสงค์ สาเหตุการดำเนินการ และเกณฑ์การตรวจสอบ

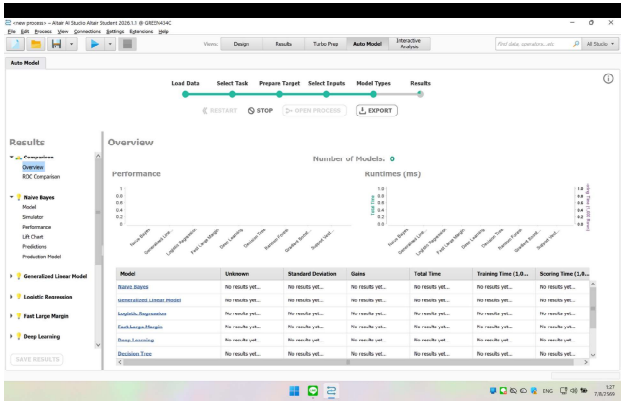

วัตถุประสงค์

- ติดตามสถานะการประมวลผลและเตรียมเปรียบเทียบผลของแบบจำลองอย่างเป็นระบบ
- จำแนกสถานะการประมวลผลปกติออกจากข้อผิดพลาดของระบบ

สาเหตุการดำเนินการ

- แบบจำลองหลายประเภทบนข้อมูลมากกว่า 1 ล้านระเบียนใช้ระยะเวลาประมวลผลแตกต่างกัน และผลลัพธ์จะปรากฏตามลำดับที่คำนวณเสร็จ
- การดูสถานะการประมวลผลก่อนเวลาอันเหมาะสมอาจทำให้ตาราง Comparison มีผลลัพธ์ไม่ครบถ้วน

ผลลัพธ์และเกณฑ์การตรวจสอบ

- Number of Models เพิ่มขึ้นจาก 0 เมื่อแต่ละแบบจำลองประมวลผลเสร็จ
- เมื่อมีผลลัพธ์ ให้พิจารณา Accuracy, Precision/Recall ของ Hospitalized, F1, AUC และ Runtime

วิธีดำเนินการในโปรแกรม: รอจนมีผลลัพธ์ ⟶ Comparison ⟶ Overview ⟶ เปรียบเทียบ Recall, F1, AUC, Accuracy และ Runtime

การวิเคราะห์ผลการประเมินประสิทธิภาพของแบบจำลอง

ใช้หน้า Results ⟶ Comparison ⟶ Overview และ Performance เพื่อเปรียบเทียบประสิทธิภาพของแต่ละแบบจำลอง

Accuracy = สัดส่วนการพยากรณ์ที่ถูกต้องเมื่อพิจารณาทุกคลาส
Precision (Hospitalized) = สัดส่วนของผู้ที่แบบจำลองพยากรณ์เป็น Hospitalized และเป็น Hospitalized จริง
Recall (Hospitalized) = สัดส่วนของผู้ที่เป็น Hospitalized จริงและแบบจำลองสามารถตรวจพบได้
F1-Score = ค่าที่สะท้อนความสมดุลระหว่าง Precision และ Recall
AUC = ความสามารถของแบบจำลองในการจำแนกสองคลาสภายใต้ค่า Threshold ที่แตกต่างกัน

สำหรับกรณีศึกษานี้ควรให้ความสำคัญกับ Recall ของ Hospitalized เนื่องจาก False Negative หมายถึงผู้ป่วยที่ควรได้รับการจัดประเภทเป็น Hospitalized แต่แบบจำลองพยากรณ์ไม่ถูกต้อง

ค่าอ้างอิงพื้นฐาน (Baseline): หากพยากรณ์ทุกระเบียนเป็น Outpatient จะได้ Accuracy ประมาณ 80.9% ดังนั้นค่า Accuracy ที่สูงกว่าค่าอ้างอิงเพียงเล็กน้อยไม่เพียงพอที่จะสรุปว่าแบบจำลองสามารถตรวจพบ Hospitalized ได้อย่างมีประสิทธิภาพ

การยืนยันชนิดข้อมูลของ Target และความพร้อมก่อนเข้าสู่ Auto Model

ภาคขยาย Covid Prepare • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

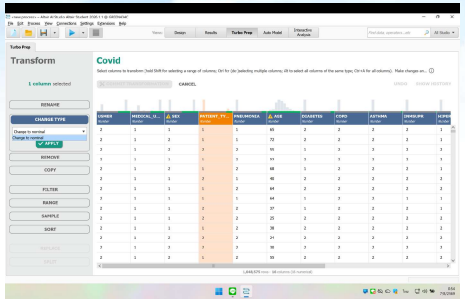

00.54.56 — PATIENT_TYPE ⟶ Change to nominal

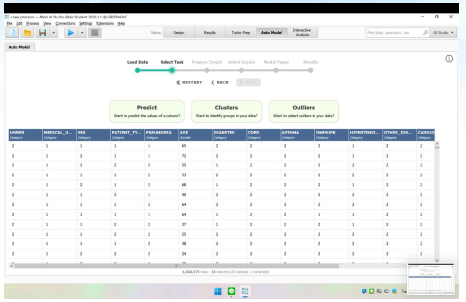

01.08.29 — Auto Model / Select Task หลังเตรียมข้อมูล

วิธีดำเนินการ
- เลือก PATIENT_TYPE แล้วใช้ CHANGE TYPE ⟶ Change to nominal ⟶ APPLY ⟶ COMMIT TRANSFORMATION
- เข้าสู่ Auto Model จากข้อมูลที่ผ่าน Turbo Prep แล้ว และตรวจจำนวน/ชนิดคอลัมน์ก่อนเลือก Predict

การตีความ
- PATIENT_TYPE ใช้รหัส 1/2 เพื่อแทนคลาส จึงต้องเป็น Nominal ไม่ใช่ค่าปริมาณ
- เมื่อเข้าสู่ Auto Model ต้องเห็น 16 columns โดย AGE เป็น numerical เพียงตัวเดียว

เกณฑ์การตรวจสอบ
- PATIENT_TYPE แสดง Category/Nominal หลัง Commit
- Auto Model แสดง 15 nominal, 1 numerical และไม่มีตัวแปร Leakage ที่นำออกแล้ว

Model Comparison: ภาพรวม F-Measure และ Runtime

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 129–131

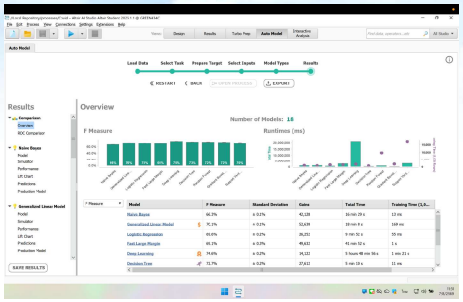

11.31.04

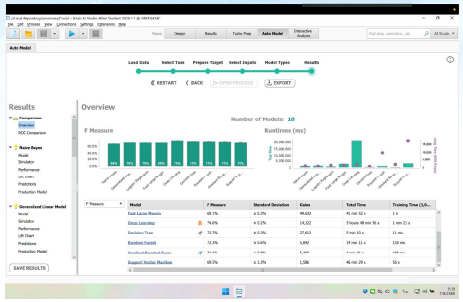

11.31.15

วิธีดำเนินการ
- เปิด Results ⟶ Comparison ⟶ Overview แล้วเลือกตัวชี้วัด เช่น F Measure/Accuracy/AUC
- อ่านกราฟ Runtimes ควบคู่กับค่าประสิทธิภาพ

การตีความ
- แท่งที่สูงกว่าแสดงค่าตัวชี้วัดที่สูงกว่าเมื่อใช้ชุดประเมินเดียวกัน
- ชุดข้อมูลไม่สมดุล จึงไม่ควรเลือกโมเดลจาก Accuracy เพียงค่าเดียว

เกณฑ์การตรวจสอบ
- Number of Models ต้องแสดงผลครบก่อนสรุปอันดับ
- ใช้ Recall/F1/AUC ของ Hospitalized ร่วมกับ Runtime

ROC Comparison: เปรียบเทียบความสามารถในการแยกสองคลาส

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 131

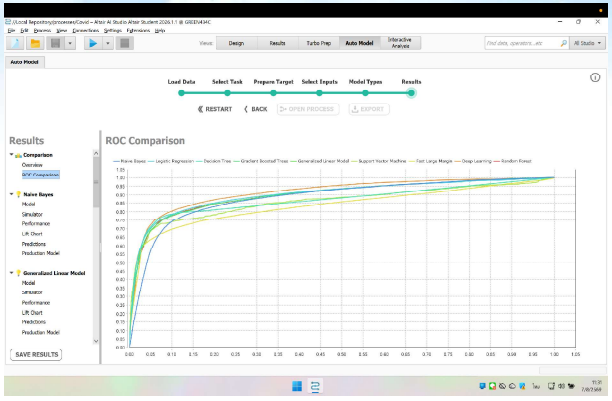

11.31.26

วิธีดำเนินการ
- เปิด Results ⟶ Comparison ⟶ ROC Comparison
- เปรียบเทียบเส้น ROC ภายใต้ threshold หลายค่า

การตีความ
- เส้นที่ใกล้มุมซ้ายบนและมีพื้นที่ใต้กราฟมากกว่ามักแยกคลาสได้ดีกว่า
- ROC/AUC ลดการพึ่งพา threshold เดียว

เกณฑ์การตรวจสอบ
- ใช้ AUC ร่วมกับ Recall/F1 ของ Hospitalized
- อย่าสรุปหากผลโมเดลยังไม่ครบ

ประเด็นสำคัญ: เส้นที่ใกล้มุมซ้ายบนและมีพื้นที่ใต้กราฟมากกว่ามักแยกคลาสได้ดีกว่า ROC/AUC ลดการพึ่งพา threshold เดียว

Naive Bayes: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

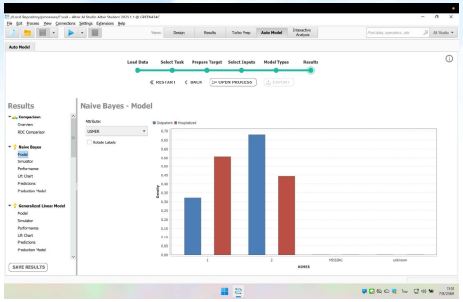

11.31.32

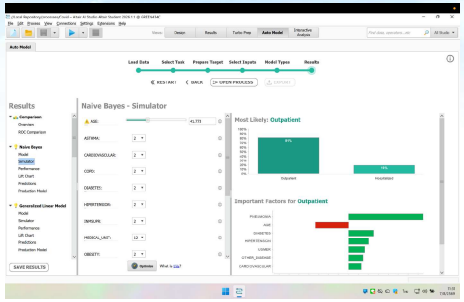

11.31.39

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Naive Bayes คำนวณความน่าจะเป็นของแต่ละคลาสจากตัวแปรนำเข้า ภายใต้สมมติฐานความเป็นอิสระแบบมีเงื่อนไข
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Naive Bayes: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

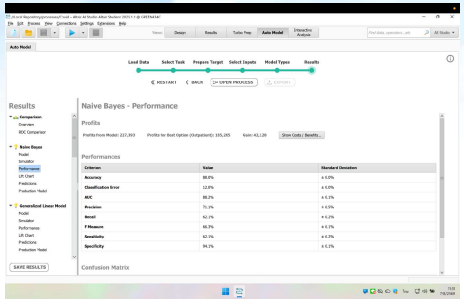

11.31.45

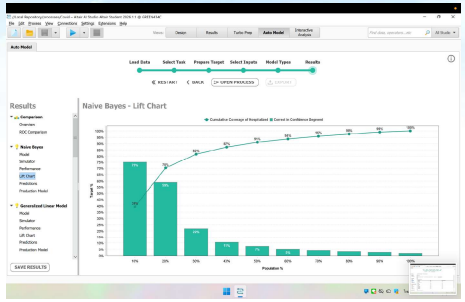

11.31.48

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Naive Bayes: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

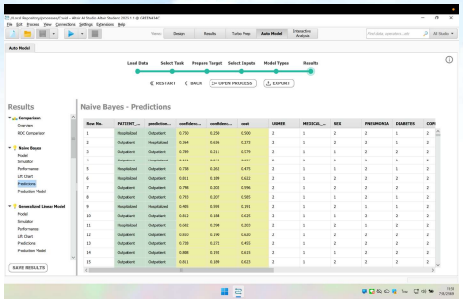

11.31.55

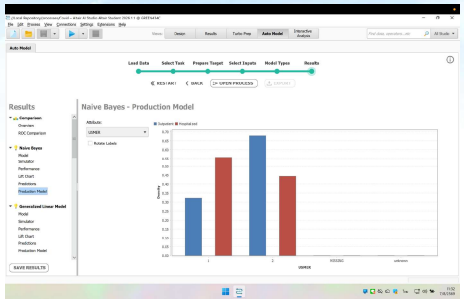

11.32.01

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Naive Bayes คำนวณความน่าจะเป็นของแต่ละคลาสจากตัวแปรนำเข้า ภายใต้สมมติฐานความเป็นอิสระแบบมีเงื่อนไข

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Generalized Linear Model: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

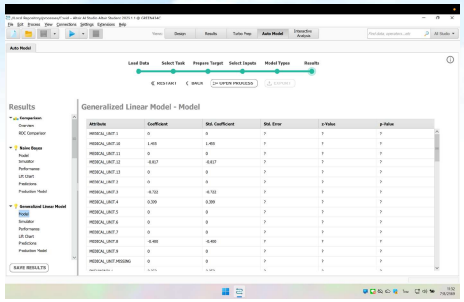

11.32.07

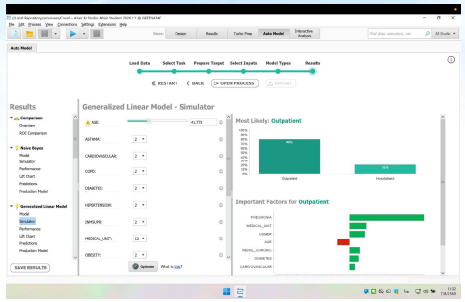

11.32.14

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- GLM แสดงค่าสัมประสิทธิ์ของตัวแปรและระดับหมวดหมู่ ช่วยดูทิศทางและขนาดของผลต่อการพยากรณ์
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Generalized Linear Model: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

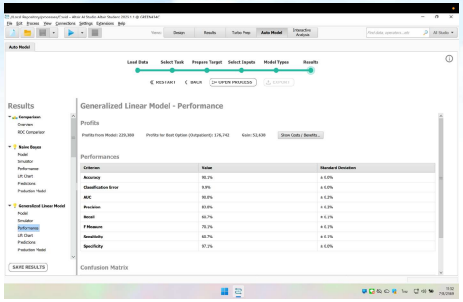

11.32.20

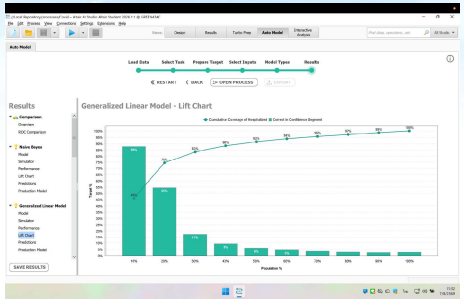

11.32.26

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Generalized Linear Model: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

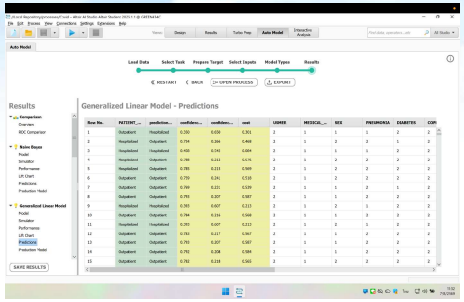

11.32.32

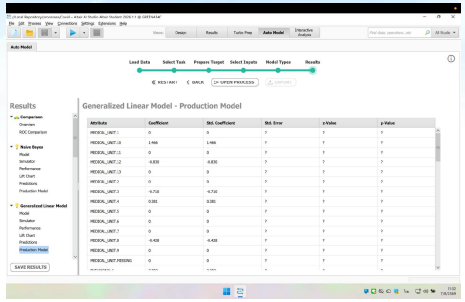

11.32.39

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- GLM แสดงค่าสัมประสิทธิ์ของตัวแปรและระดับหมวดหมู่ ช่วยดูทิศทางและขนาดของผลต่อการพยากรณ์

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Logistic Regression: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 116, 120–122

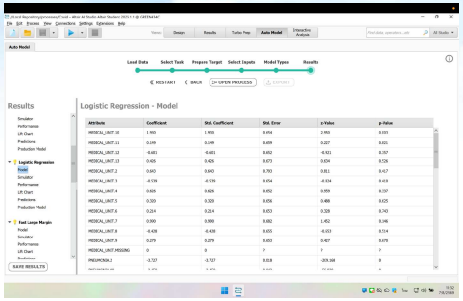

11.32.46

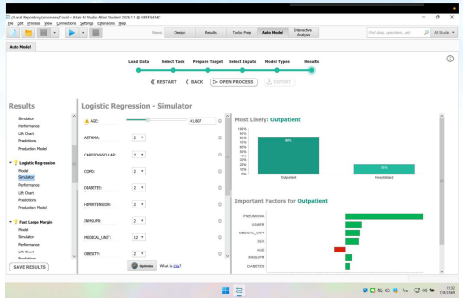

11.32.52

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Logistic Regression แปลงผลรวมเชิงเส้นเป็นความน่าจะเป็นของคลาส และอธิบายได้ผ่านค่าสัมประสิทธิ์
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Logistic Regression: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 129–131

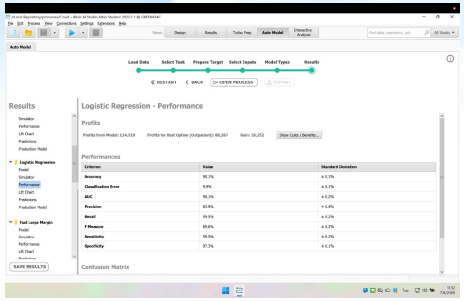

11.32.58

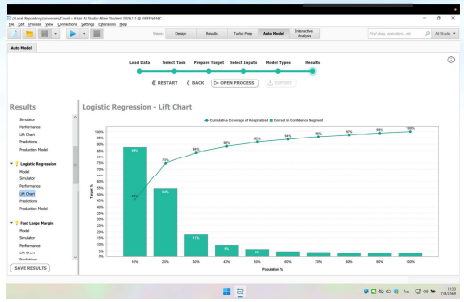

11.33.05

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Logistic Regression: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 136–138

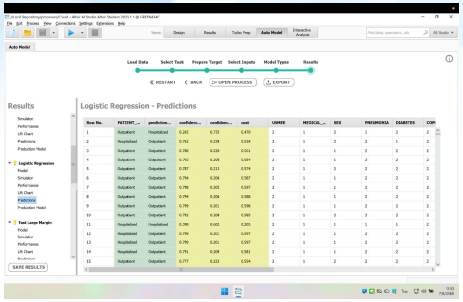

11.33.11

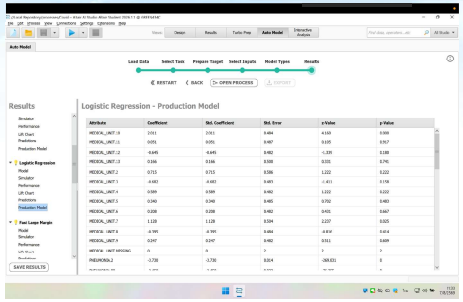

11.33.17

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Logistic Regression แปลงผลรวมเชิงเส้นเป็นความน่าจะเป็นของคลาส และอธิบายได้ผ่านค่าสัมประสิทธิ์

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Fast Large Margin: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

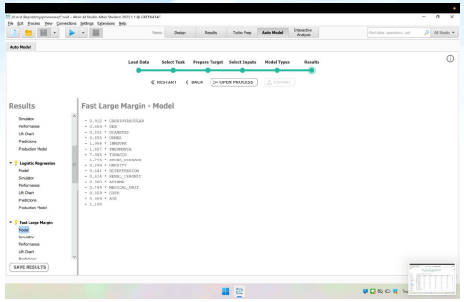

11.33.20

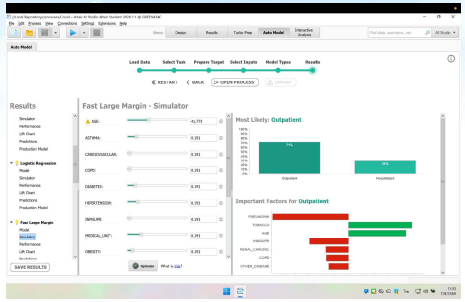

11.33.39

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Fast Large Margin เน้นเส้นแบ่งคลาสที่มี margin กว้าง จึงควรอ่านร่วมกับ Performance มากกว่าตีความค่าสัมประสิทธิ์แบบตรงตัว
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Fast Large Margin: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

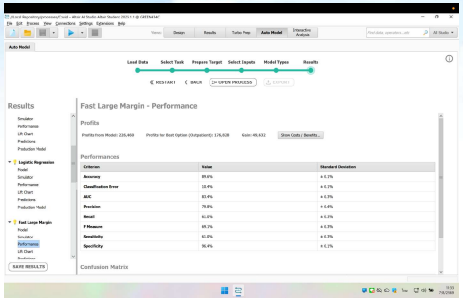

11.33.45

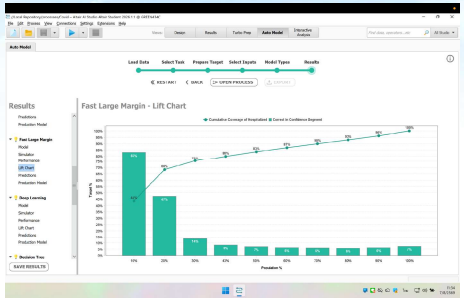

11.34.05

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Fast Large Margin: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

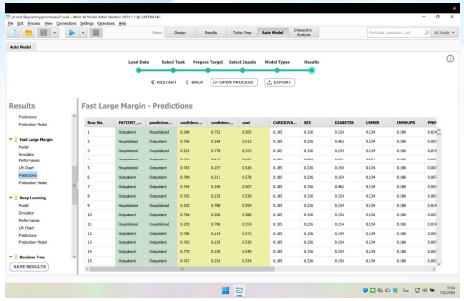

11.34.11

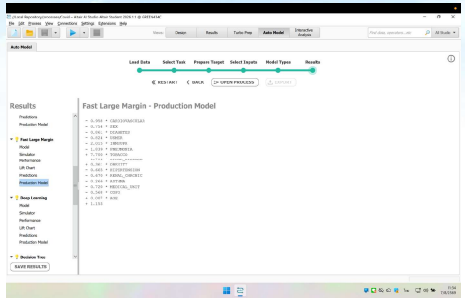

11.34.18

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Fast Large Margin เน้นเส้นแบ่งคลาสที่มี margin กว้าง จึงควรอ่านร่วมกับ Performance มากกว่าตีความค่าสัมประสิทธิ์แบบตรงตัว

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Deep Learning: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

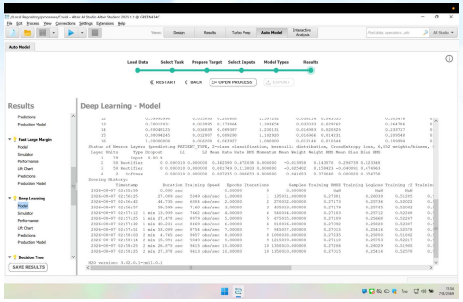

11.34.25

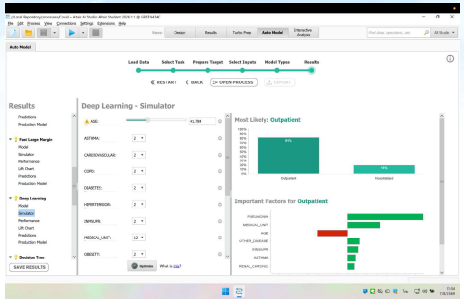

11.34.31

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Deep Learning เรียนรู้ความสัมพันธ์แบบไม่เชิงเส้นผ่านหลายชั้น จึงควรเน้น validation/test, simulator และ performance มากกว่าพารามิเตอร์ดิบ
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Deep Learning: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

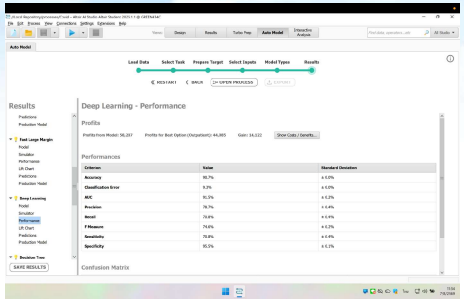

11.34.38

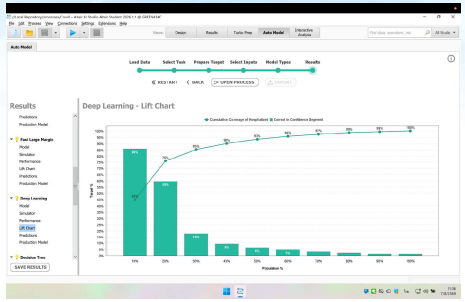

11.36.06

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Deep Learning: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

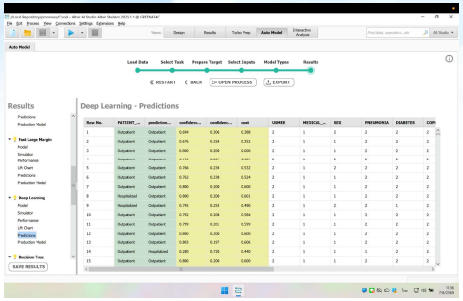

11.36.12

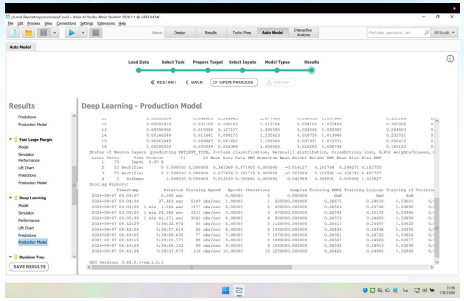

11.36.18

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Deep Learning เรียนรู้ความสัมพันธ์แบบไม่เชิงเส้นผ่านหลายชั้น จึงควรเน้น validation/test, simulator และ performance มากกว่าพารามิเตอร์ดิบ

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Decision Tree: ตรวจโครงสร้างต้นไม้และเส้นทางการตัดสินใจ (1/4)

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 123–125

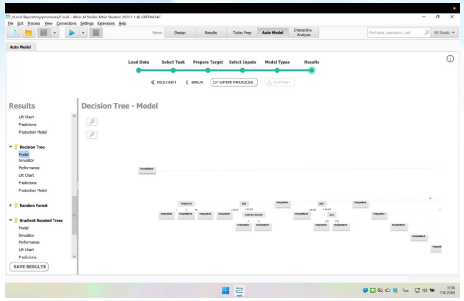

11.36.34

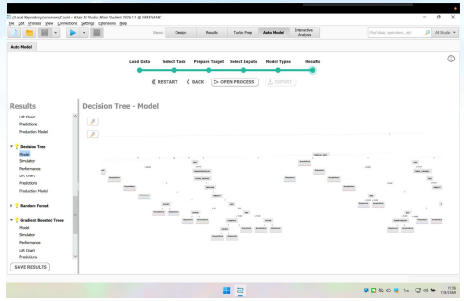

11.36.49

วิธีดำเนินการ

- เปิด Decision Tree ⟶ Model แล้วใช้การเลื่อน/ซูมตรวจส่วนต่าง ๆ ของต้นไม้
- ไล่เงื่อนไขจาก root ผ่าน node ไป leaf

การตีความ

- แต่ละ node เป็นเงื่อนไขบนตัวแปรและค่าแบ่ง; leaf แสดงคลาสผลลัพธ์
- ต้องใช้หลายภาพเพราะต้นไม้มีขนาดใหญ่กว่าหนึ่งหน้าจอ

เกณฑ์การตรวจสอบ

- ตรวจว่ามีเส้นทางที่จบทั้ง Outpatient และ Hospitalized
- ไม่สรุปความสำคัญจาก node เดียว; ใช้ Performance ร่วมด้วย

Decision Tree: ตรวจโครงสร้างต้นไม้และเส้นทางการตัดสินใจ (2/4)

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 123–125

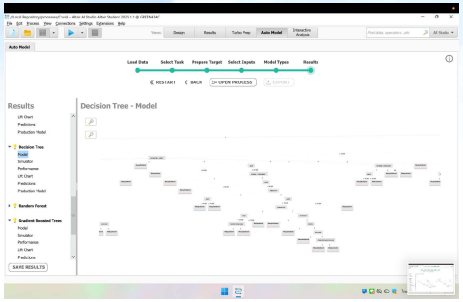

11.36.54

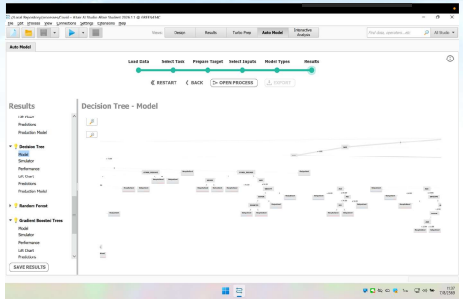

11.37.03

วิธีดำเนินการ

- เปิด Decision Tree ⟶ Model แล้วใช้การเลื่อน/ซูมตรวจส่วนต่าง ๆ ของต้นไม้
- ไล่เงื่อนไขจาก root ผ่าน node ไป leaf

การตีความ

- แต่ละ node เป็นเงื่อนไขบนตัวแปรและค่าแบ่ง; leaf แสดงคลาสผลลัพธ์
- ต้องใช้หลายภาพเพราะต้นไม้มีขนาดใหญ่กว่าหนึ่งหน้าจอ

เกณฑ์การตรวจสอบ

- ตรวจว่ามีเส้นทางที่จบทั้ง Outpatient และ Hospitalized
- ไม่สรุปความสำคัญจาก node เดียว; ใช้ Performance ร่วมด้วย

Decision Tree: ตรวจโครงสร้างต้นไม้และเส้นทางการตัดสินใจ (3/4)

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 123–125

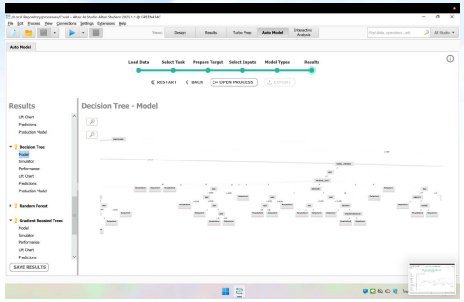

11.37.09

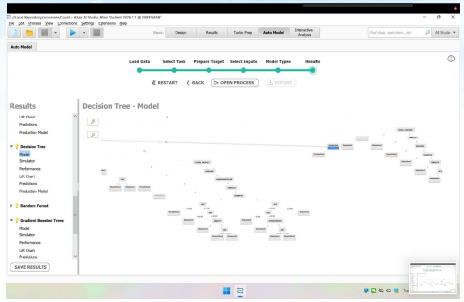

11.37.13

วิธีดำเนินการ

- เปิด Decision Tree ⟶ Model แล้วใช้การเลื่อน/ซูมตรวจส่วนต่าง ๆ ของต้นไม้
- ไล่เงื่อนไขจาก root ผ่าน node ไป leaf

การตีความ

- แต่ละ node เป็นเงื่อนไขบนตัวแปรและค่าแบ่ง; leaf แสดงคลาสผลลัพธ์
- ต้องใช้หลายภาพเพราะต้นไม้มีขนาดใหญ่กว่าหนึ่งหน้าจอ

เกณฑ์การตรวจสอบ

- ตรวจว่ามีเส้นทางที่จบทั้ง Outpatient และ Hospitalized
- ไม่สรุปความสำคัญจาก node เดียว; ใช้ Performance ร่วมด้วย

Decision Tree: ตรวจโครงสร้างต้นไม้และเส้นทางการตัดสินใจ (4/4)

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 123–125

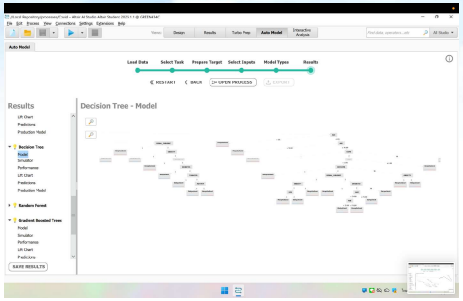

11.37.18

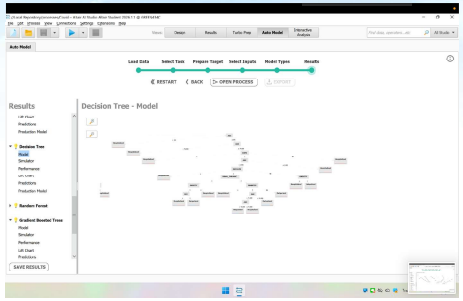

11.37.20

วิธีดำเนินการ

- เปิด Decision Tree ⟶ Model แล้วใช้การเลื่อน/ซูมตรวจส่วนต่าง ๆ ของต้นไม้
- ไล่เงื่อนไขจาก root ผ่าน node ไป leaf

การตีความ

- แต่ละ node เป็นเงื่อนไขบนตัวแปรและค่าแบ่ง; leaf แสดงคลาสผลลัพธ์
- ต้องใช้หลายภาพเพราะต้นไม้มีขนาดใหญ่กว่าหนึ่งหน้าจอ

เกณฑ์การตรวจสอบ

- ตรวจว่ามีเส้นทางที่จบทั้ง Outpatient และ Hospitalized
- ไม่สรุปความสำคัญจาก node เดียว; ใช้ Performance ร่วมด้วย

Decision Tree: Simulator และ Performance

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 123–125

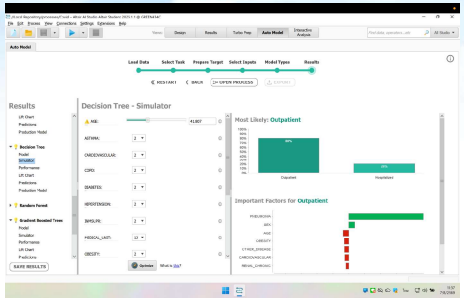

11.37.27

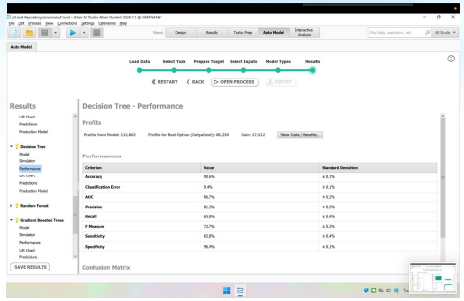

11.37.31

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Decision Tree อธิบายด้วยเส้นทางการแบ่งกิ่งจาก root ไป leaf โดยแต่ละเงื่อนไขสะท้อนกฎการตัดสินใจ
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Decision Tree: Performance รายละเอียดและ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

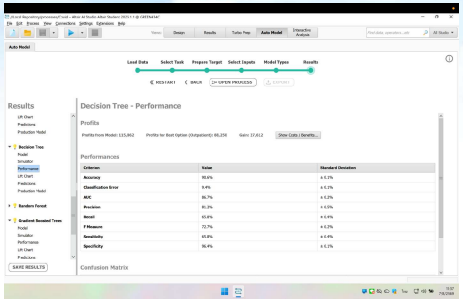

11.37.38

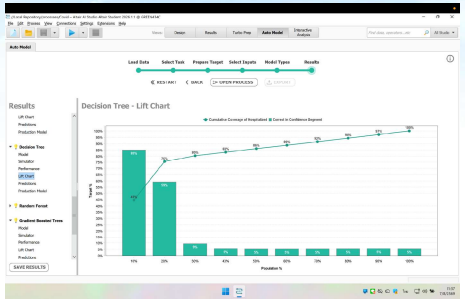

11.37.45

วิธีดำเนินการ

- เลื่อน Performance เพื่อดู metric/Confusion Matrix ให้ครบ
- เปิด Lift Chart เพื่อดู cumulative gain ของ Positive class

การตีความ

- Confusion Matrix ใช้ระบุ False Negative ของ Hospitalized โดยตรง
- Lift Chart ประเมินความสามารถในการจัดลำดับเคสที่ควรให้ความสำคัญ

เกณฑ์การตรวจสอบ

- ตรวจ Recall/F1 และจำนวน FN
- ผลต้องสอดคล้องกับ Performance ก่อนหน้าและ Positive Class ต้องไม่สลับ

Decision Tree: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

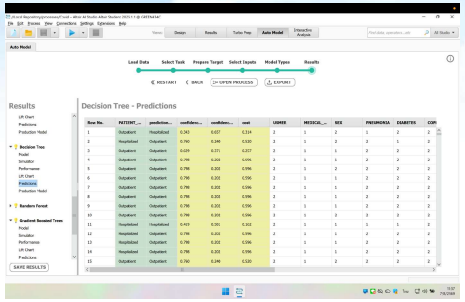

11.37.51

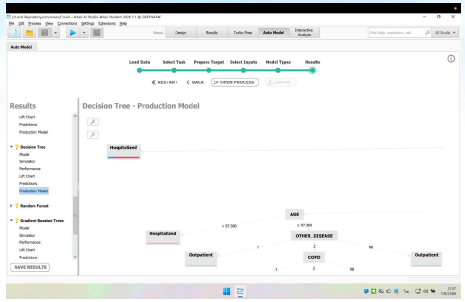

11.37.57

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Decision Tree อธิบายด้วยเส้นทางการแบ่งกิ่งจาก root ไป leaf โดยแต่ละเงื่อนไขสะท้อนกฎการตัดสินใจ

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Random Forest: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 126–128

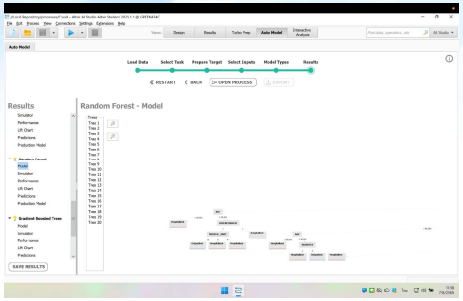

11.38.11

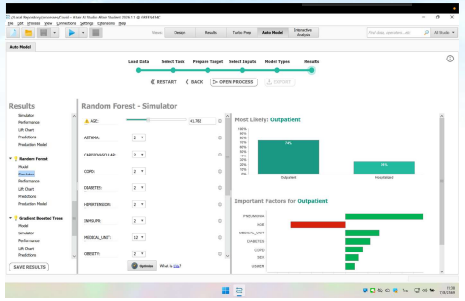

11.38.18

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Random Forest รวมผลจากต้นไม้จำนวนมาก ลดความแปรปรวนและควรตีความจากผลรวม/importance มากกว่าต้นไม้เดี่ยว
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Random Forest: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 129–135, 139–140

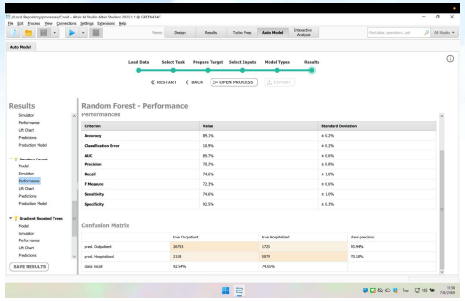

11.38.26

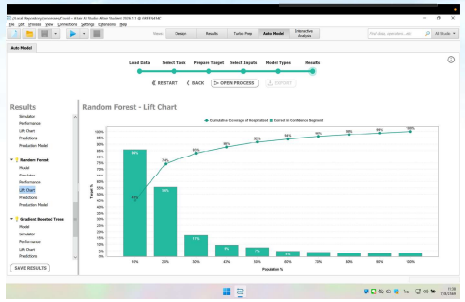

11.38.33

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Random Forest: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 136–138

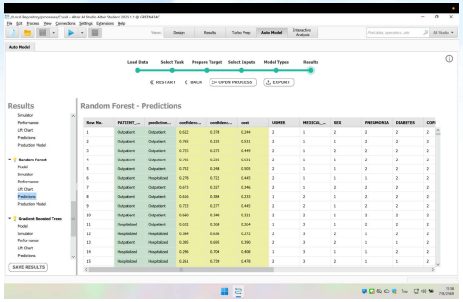

11.38.39

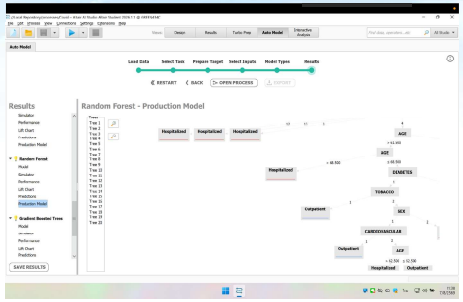

11.38.59

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Random Forest รวมผลจากต้นไม้จำนวนมาก ลดความแปรปรวนและควรดีความจากผลรวม/importance มากกว่าต้นไม้เดี่ยว

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Random Forest: ตรวจ Production Model เพิ่มเติม

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 126–128

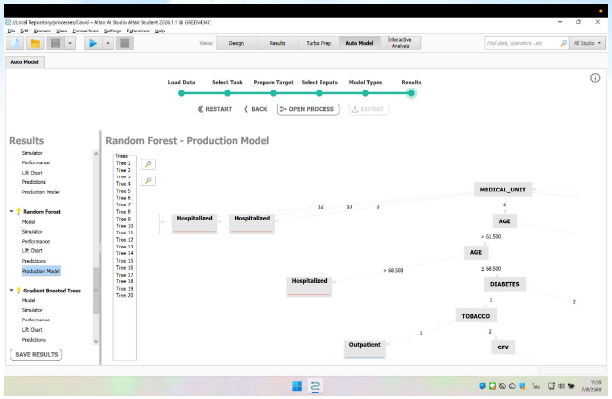

11.39.07

วิธีดำเนินการ

- เปิด Production Model และเลือกดูต้นไม้/ส่วนประกอบเพิ่มเติม
- ใช้การเลื่อนหรือเลือก tree เพื่อดูรายละเอียดโดยไม่ถือว่าต้นไม้ดีเยี่ยวแทนทั้ง ensemble

การตีความ

- Random Forest ตัดสินใจจากผลรวมของหลายต้นไม้ จึงไม่ควรอธิบายจาก tree เดียว
- ภาพนี้ยืนยันว่า production representation ถูกสร้างครบ

เกณฑ์การตรวจสอบ

- Production Model เปิดได้และไม่มี error
- ใช้ Performance/importance เป็นหลักเมื่อต้องเลือกโมเดล

ประเด็นสำคัญ: Random Forest **ตัดสินใจจากผลรวมของหลายต้นไม้ จึงไม่ควรอธิบายจาก** tree **เดียว ภาพนี้ยืนยันว่า** production representation **ถูกสร้างครบ**

Gradient Boosted Trees: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

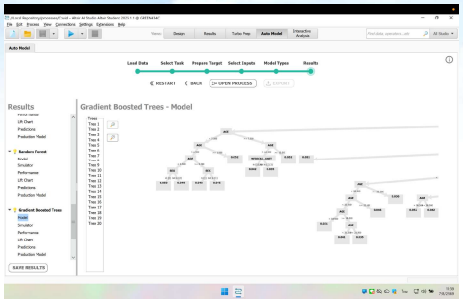

11.39.24

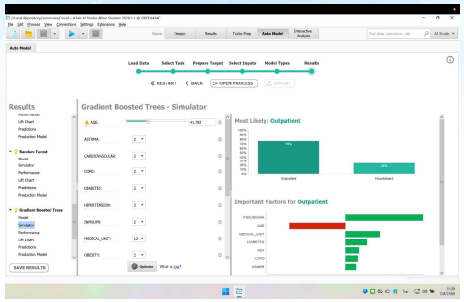

11.39.31

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- Gradient Boosted Trees สร้างต้นไม้ต่อเนื่องเพื่อแก้ข้อผิดพลาดของต้นก่อนหน้า มักให้ผลดีแต่มีความซับซ้อนสูงขึ้น
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Gradient Boosted Trees: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

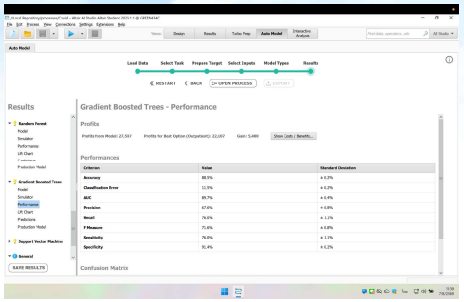

11.39.37

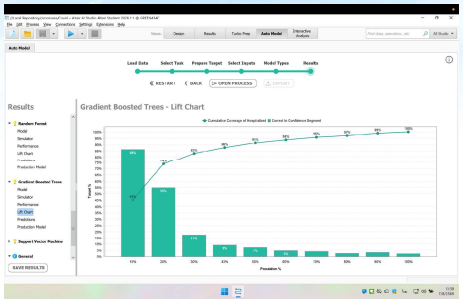

11.39.43

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Gradient Boosted Trees: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

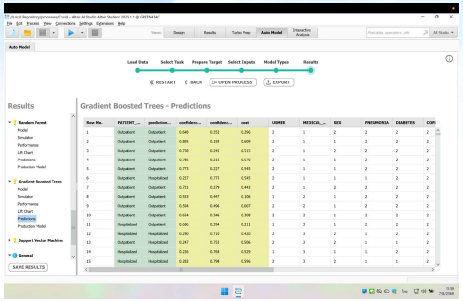

11.39.50

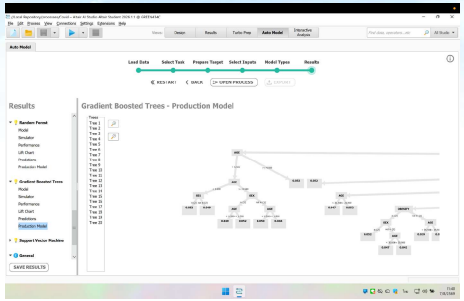

11.40.10

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- Gradient Boosted Trees สร้างต้นไม้ต่อเนื่องเพื่อแก้ข้อผิดพลาดของต้นก่อนหน้า มักให้ผลดีแต่มีความซับซ้อนสูงขึ้น

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Support Vector Machine: Model และ Simulator

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

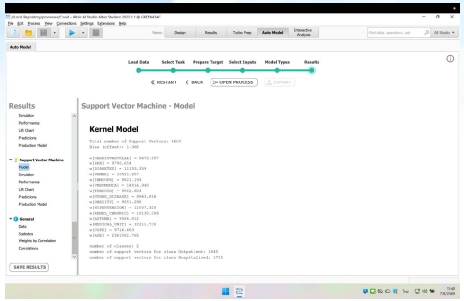

11.40.22

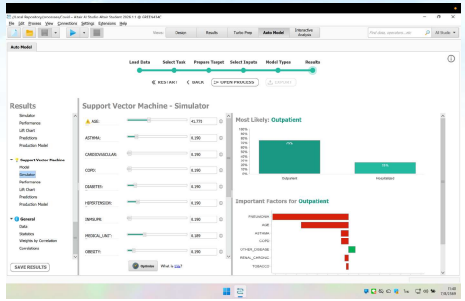

11.40.29

วิธีดำเนินการ

- เลือกชื่อโมเดลจากแถบซ้าย ⟶ Model เพื่อดูโครงสร้าง/พารามิเตอร์
- เปิด Simulator แล้วปรับตัวแปรนำเข้าเพื่อดู predicted class และ confidence

การตีความ

- SVM สร้างขอบเขตแบ่งคลาสด้วย margin และ kernel; ค่าภายในไม่ควรตีความเหมือน coefficient ของ Logistic Regression
- Simulator เป็น What-if ไม่ใช่ค่าประสิทธิภาพบน test set

เกณฑ์การตรวจสอบ

- ผลพยากรณ์ต้องแสดง Outpatient/Hospitalized ถูกต้อง
- Input ใน Simulator เปลี่ยนได้และไม่มี error จากชนิดข้อมูล

Support Vector Machine: Performance และ Lift Chart

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

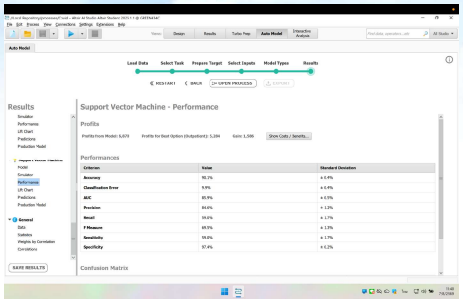

11.40.35

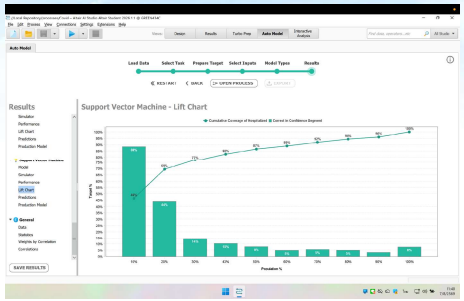

11.40.41

วิธีดำเนินการ

- เปิด Performance เพื่อตรวจ Accuracy, AUC, Precision, Recall, F Measure และ Confusion Matrix
- เปิด Lift Chart เพื่อดูความสามารถในการจัดลำดับ Positive

การตีความ

- Performance ใช้เปรียบเทียบบนข้อมูลประเมิน ไม่ใช่จากข้อมูลฝึกอย่างเดียว
- Lift ที่เพิ่มเร็วช่วงต้นหมายถึงช่วยจัดลำดับเคส Positive ได้ดีกว่า baseline

เกณฑ์การตรวจสอบ

- เน้น Recall/F1/AUC ของ Hospitalized
- ตรวจ TP, FP, FN, TN และระวัง Accuracy สูงแต่ Recall ต่ำ

Support Vector Machine: Predictions และ Production Model

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

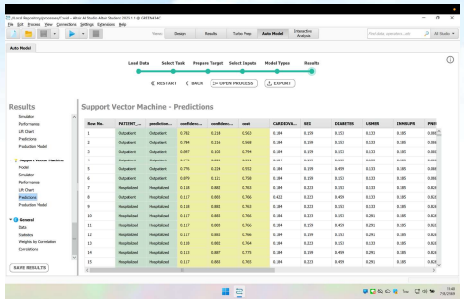

11.40.47

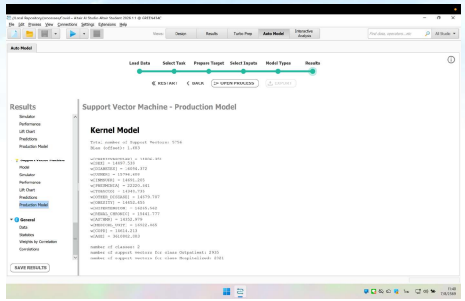

11.40.54

วิธีดำเนินการ

- เปิด Predictions เพื่อดู actual target, prediction และ confidence ระดับระเบียน
- เปิด Production Model เพื่อดู representation ที่ Auto Model สร้างสำหรับใช้ต่อ

การตีความ

- Predictions ช่วยหาเคสที่ทายผิด/ความเชื่อมั่นต่ำ
- SVM สร้างขอบเขตแบ่งคลาสด้วย margin และ kernel; ค่าภายในไม่ควรตีความเหมือน coefficient ของ Logistic Regression

เกณฑ์การตรวจสอบ

- ชื่อคลาสและ confidence ต้องสอดคล้องกับ Positive Class = Hospitalized
- Production Model ต้องสร้างสำเร็จและตรงกับ algorithm

Data และ Statistics: ตรวจข้อมูลที่ใช้ประเมินและการกระจาย AGE

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

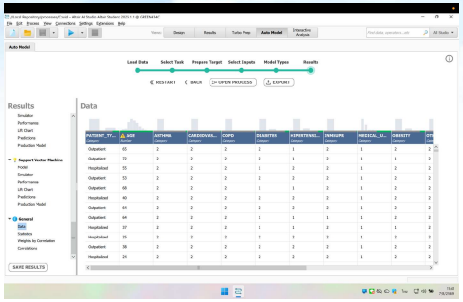

11.41.00

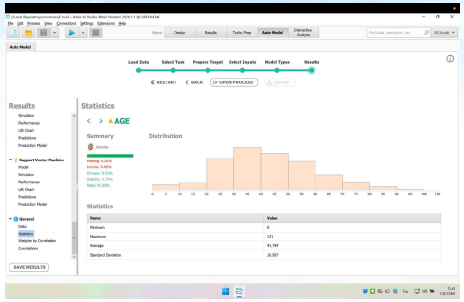

11.41.07

วิธีดำเนินการ

- เปิด Results ⟶ General ⟶ Data เพื่อตรวจตัวแปรที่เข้าสู่ผลลัพธ์
- เปิด Statistics แล้วเลือก AGE เพื่อดู distribution และสถิติสรุป

การตีความ

- Data view ใช้ตรวจว่า Leakage ถูกนำออก และ target/prediction อยู่ในรูปที่คาดหวัง
- AGE เป็น numerical เพียงตัวเดียว จึงควรตรวจ range/distribution

เกณฑ์การตรวจสอบ

- ข้อมูลควรมี predictors ที่เตรียมไว้และ PATIENT_TYPE ที่ map แล้ว
- AGE ต้องไม่กลายเป็น Nominal และไม่ควรมีค่าผิดปกติจากการเปลี่ยน type

Weights by Correlation และ Correlation Matrix

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

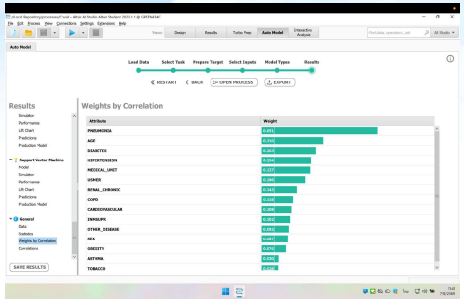

11.41.13

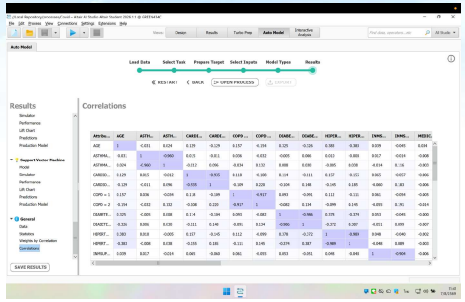

11.41.19

วิธีดำเนินการ

- เปิด Weights by Correlation เพื่อจัดอันดับความสัมพันธ์กับ target
- เปิด Correlations เพื่อดูความสัมพันธ์ระหว่างตัวแปรเป็นมหทริซ์

การตีความ

- Correlation เป็น screening เบื้องต้น ไม่ใช่เหตุและผล
- คู่ตัวแปรสัมพันธ์สูงอาจมีข้อมูลซ้ำซ้อนและกระทบโมเดลเชิงเส้น

เกณฑ์การตรวจสอบ

- ใช้ร่วมกับ domain knowledge และ feature importance
- อย่าตัดตัวแปรจาก correlation เพียงค่าเดียว โดยไม่วัด performance หลังปรับ

Correlation Matrix: ตรวจเมทริกซ์ในมุมมองเพิ่มเติม

ภาคขยาย Covid Model • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

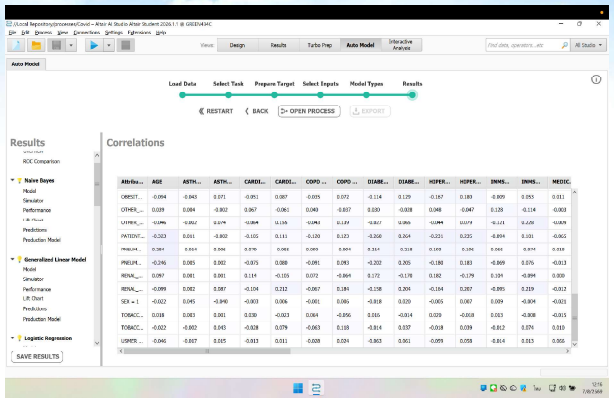

12.16.48

วิธีดำเนินการ

- เลื่อน/ขยายตาราง Correlations เพื่อดูคู่ตัวแปรนอกหน้าจอแรก
- เปรียบเทียบค่าบวก/ลบและขนาดสหสัมพันธ์

การตีความ

- ภาพเพิ่มเติมช่วยให้ตรวจเมทริกซ์กว้างได้ครบ
- ค่าสูงมากอาจบอกความซ้ำซ้อน แต่ต้องยืนยันผลต่อ performance

เกณฑ์การตรวจสอบ

- ตรวจครบตัวแปรสำคัญและไม่พบ Leakage variables
- หากทำ feature reduction ให้บันทึก baseline และวัด metric หลังปรับ

ประเด็นสำคัญ: ภาพเพิ่มเติมช่วยให้ตรวจเมทริกซ์กว้างได้ครบ ค่าสูงมากอาจบอกความซ้ำซ้อน แต่ต้องยืนยันผลต่อ performance

Evaluation: Overview และสถานะผลลัพธ์ของโมเดล

ภาคขยาย Covid Eva • ใช้ภาพต่อเนื่องเพื่อยืนยันการเปรียบเทียบผลอย่างครบถ้วน

ข้อสอบ 129–131

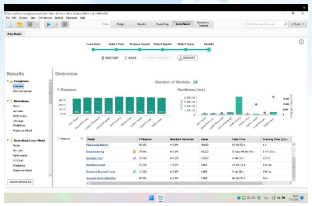

16.44.19

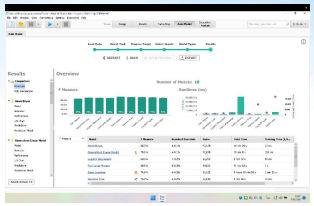

16.47.36

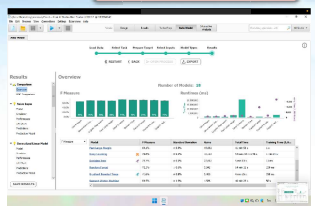

16.47.41

วิธีดำเนินการ

- เปิด Comparison ⟶ Overview และรอ Number of Models ให้ครบ
- ตรวจลำดับตาราง ค่า metric ที่เลือก และ Runtimes

การตีความ

- Overview ใช้คัดโมเดลเบื้องต้นก่อนลงรายละเอียดราย metric
- Runtime ที่สูงมากอาจไม่คุ้มถ้าคุณภาพเพิ่มเพียงเล็กน้อย

เกณฑ์การตรวจสอบ

- จำนวนโมเดลต้องครบก่อนสรุป
- ใช้ test/validation เดียวกัน ไม่เทียบผลจากรอบคนละข้อมูล

Evaluation: Accuracy Comparison

ภาคขยาย Covid Eva • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 131, 134

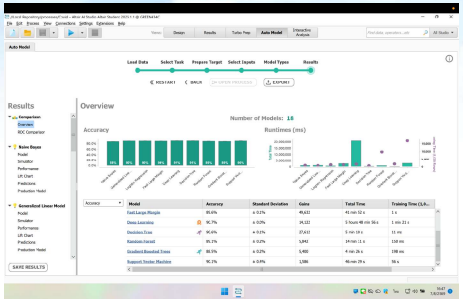

16.47.54

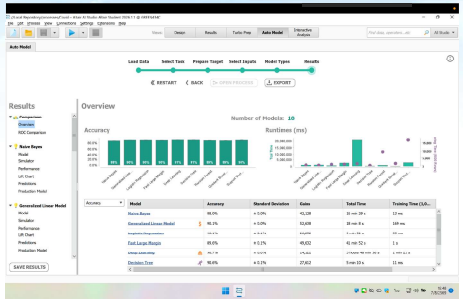

16.48.00

วิธีดำเนินการ

- เลือก metric = Accuracy ใน Comparison ⟶ Overview
- เปรียบเทียบ Accuracy และ Runtime

การตีความ

- Accuracy คือสัดส่วนการทายถูกทั้งหมด แต่ Outpatient มีประมาณ 80.9%
- Accuracy สูงอาจซ่งพลาด Hospitalized มากได้

เกณฑ์การตรวจสอบ

- เปรียบเทียบกับ baseline ~80.9%
- ต้องตรวจ Recall/F1/AUC ต่อ ไม่สรุปจาก Accuracy อย่างเดียว

Evaluation: AUC Comparison

ภาคขยาย Covid Eva • ใช้ภาพต่อเนื่องเพื่อยืนยันการเปรียบเทียบผลอย่างครบถ้วน

ข้อสอบ 131

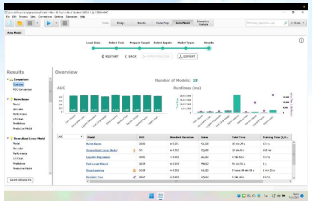

16.48.07

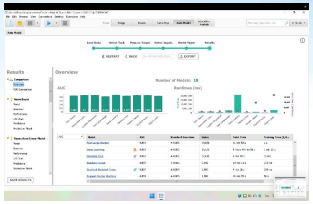

16.48.10

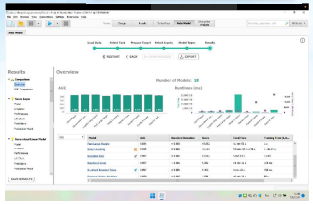

16.48.16

วิธีดำเนินการ

- เลือก metric = AUC และเปรียบเทียบกราฟ/ตาราง
- ใช้ AUC ร่วมกับ ROC Comparison

การตีความ

- AUC สูงหมายถึงความสามารถจัดอันดับ Positive เหนือ Negative โดยรวมดีกว่า
- AUC ไม่บอก threshold จริงหรือ False Negative โดยตรง

เกณฑ์การตรวจสอบ

- เลือกโมเดลที่ AUC สูงและ Recall/F1 ไม่ตก
- หาก AUC ใกล้กันให้ดู Runtime, interpretability และ Recall

Evaluation: Precision ของ Positive Class (Hospitalized)

ภาคขยาย Covid Eva • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 130

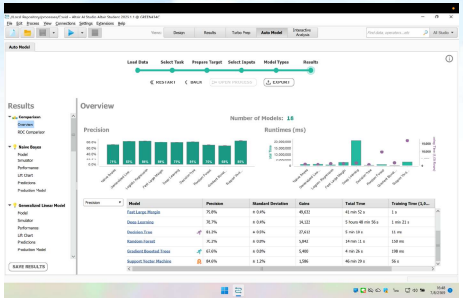

16.48.23

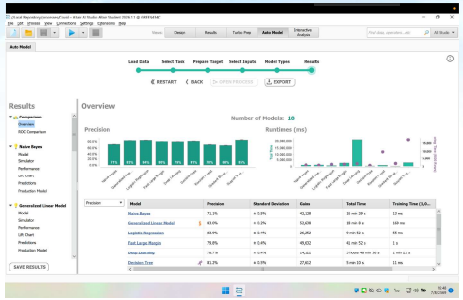

16.48.29

วิธีดำเนินการ

- เลือก metric = Precision
- อ่านสัดส่วนผู้ที่ทำนายเป็น Hospitalized แล้วเป็น Hospitalized จริง

การตีความ

- Precision สูงช่วยลด False Positive
- Precision สูงอย่างเดียวอาจเกิดจากทาย Positive น้อยจน Recall ต่ำ

เกณฑ์การตรวจสอบ

- ตรวจคู่ Recall และ F1
- Positive Class ต้องเป็น Hospitalized มิฉะนั้นความหมายจะกลับด้าน

Evaluation: Recall ของ Positive Class (Hospitalized)

ภาคขยาย Covid Eva • แสดงภาพหน้าจอจริงจากไฟล์ที่ผู้ใช้จัดเตรียม

ข้อสอบ 129, 132

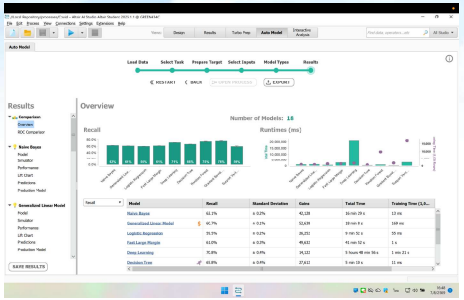

16.48.35

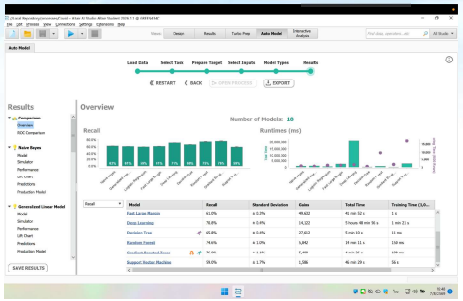

16.48.45

วิธีดำเนินการ

- เลือก metric = Recall
- อ่านสัดส่วน Hospitalized จริงที่โมเดลตรวจพบ

การตีความ

- Recall สำคัญเพราะ False Negative คือผู้ป่วย Hospitalized ที่ถูกพลาด
- Recall สูงขึ้นอาจแลกกับ Precision จึงดู F1/Confusion Matrix ร่วม

เกณฑ์การตรวจสอบ

- แน้นโมเดลที่ลด FN และรักษา Precision เหมาะสม
- ตรวจ Positive Class = Hospitalized ก่อนตีความ

Evaluation: F-Measure / F1 Comparison

ภาคขยาย Covid Eva • ใช้ภาพต่อเนื่องเพื่อยืนยันการเปรียบเทียบผลอย่างครบถ้วน

ข้อสอบ 139

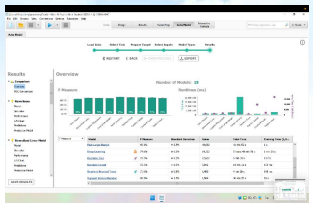

16.48.50

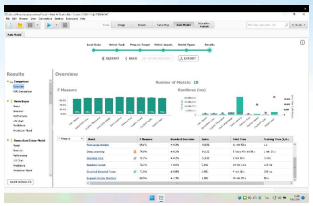

16.48.57

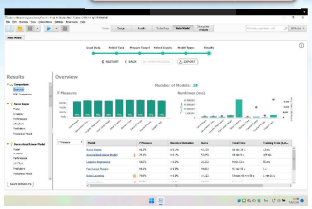

16.49.03

วิธีดำเนินการ

- เลือก metric = F Measure/F1
- เปรียบเทียบ F1 กับ Runtime และตรวจ Precision/Recall ของโมเดลลำดับต้น

การตีความ

- F1 เป็น harmonic mean ของ Precision และ Recall
- เหมาะกับข้อมูลไม่สมดุลเมื่อทั้ง FP และ FN มีความสำคัญ

เกณฑ์การตรวจสอบ

- ใช้ F1 shortlist แล้วตรวจ Recall ของ Hospitalized
- สรุปจากหลาย metric ไม่ใช่ F1 เพียงค่าเดียว

Auto Model: อ่านหน้าตั้งค่าให้ตอบ Target, Positive Class, Input และ Preprocessing

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 108–110, 113–117

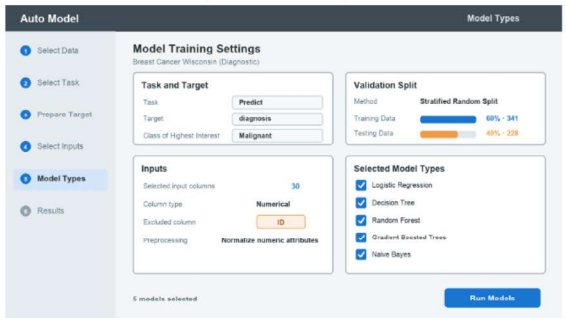

สิ่งที่ต้องอ่านจากภาพ

- Task = Predict; Target = diagnosis
- Class of Highest Interest = Malignant
- Selected inputs = 30; Excluded = ID
- Preprocessing = Normalize numeric attributes

หลักการตอบข้อสอบ

- diagnosis มี 2 ค่า ⟶ Binary Classification
- ID เป็นรหัสระเบียน ไม่ใช่ predictor ที่มีความหมาย
- Normalization ทำให้ตัวแปรเชิงตัวเลขต่างหน่วยอยู่ในสเกลใกล้กัน

ลำดับ Auto Model ที่ควรจำ

- Select Task ⟶ Prepare Target ⟶ Select Inputs ⟶ Model Types ⟶ Results
- Positive Class ระบุคลาสที่ใช้คำนวณ Precision / Recall / F1 และใช้ตีความ TP, FP, FN, TN

Training / Testing และ Stratified Random Split

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 111–112, 118–119

Training Data — 60% = 341

- ใช้ให้ Algorithm เรียนรู้รูปแบบและสร้างโมเดล
- ไม่ใช้ข้อมูลสำหรับรายงานผลสุดท้ายเพียงอย่างเดียว

Testing Data — 40% = 228

- กันไว้จากการฝึก เพื่อเป็นข้อมูลที่โมเดล "ไม่เคยเห็น"
- ใช้ประเมินความสามารถในการพยากรณ์ข้อมูลใหม่

Stratified Random Split

- สุ่มแบ่งข้อมูล แต่รักษาสัดส่วน Benign/Malignant ให้ใกล้เคียงต้นฉบับ
- เหมาะกับงาน Classification โดยเฉพาะเมื่อคลาสไม่สมดุล

569 ระเบียน ⟶ 341 Training + 228 Testing = 569 ระเบียน

ข้อควรระวัง

- ห้ามให้ Testing Data ไหลกลับไปเป็นข้อมูลฝึก เพราะทำให้การประเมินมองโลกในแง่ดีเกินจริง
- Stratified Split ไม่ได้ทำให้จำนวนสองคลาสเท่ากัน แต่รักษา "สัดส่วน" ของคลาส

Logistic Regression: Normalization และการตีความ Coefficient

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 116, 120–122

การตีความเครื่องหมาย

- Coefficient > 0: ตัวแปรสูงขึ้นสัมพันธ์กับแนวโน้ม Positive Class (Malignant) สูงขึ้น เมื่อค่าอื่นคงที่
- Coefficient < 0: ตัวแปรสูงขึ้นสัมพันธ์กับแนวโน้ม Positive Class ลดลง เมื่อค่าอื่นคงที่

ตัวอย่างจากภาพ

- worst texture = +1.183 ⟶ ค่าบวกสูงสุดในรายการ
- compactness error = −0.756 ⟶ ทิศทางสัมพันธ์กับ Malignant ลดลง

เหตุผลของ Normalization

- Logistic Regression ใช้ค่าตัวแปรเชิงตัวเลขหลายตัวที่หน่วยและช่วงค่าแตกต่างกัน จึงควรปรับให้อยู่ในสเกลใกล้เคียงกัน
- Coefficient บอกความสัมพันธ์เชิงโมเดล ไม่ใช่หลักฐานว่า feature เป็น "สาเหตุ" โดยตรง

Decision Tree: Root Node ⟶ Branch ⟶ Leaf Node

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 123–125

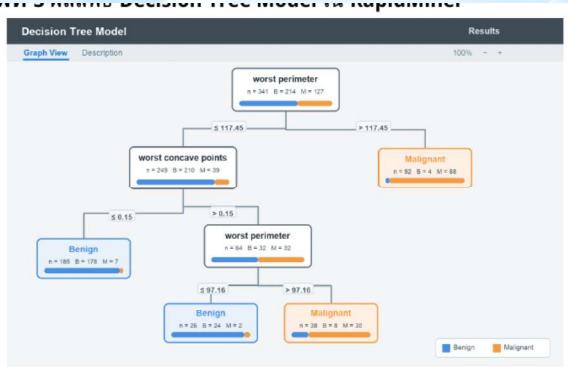

ตัวอย่าง: worst perimeter > 117.45 ⟶ Malignant

Root Node

- โหนดแรกคือ worst perimeter
- เป็นเงื่อนไขแรกที่ใช้แบ่งข้อมูล

วิธีอ่านต้นไม้

- เริ่มจาก Root Node แล้วเลือกเส้นทางตามเงื่อนไข
- ทำต่อเนื่องจนถึง Leaf Node

Leaf Node

- แสดงคลาส/ผลลัพธ์สุดท้ายที่โมเดลพยากรณ์
- หนึ่งระเบียนเดินเพียงหนึ่งเส้นทาง ไม่ได้ผ่านทุก Leaf

Random Forest และ Feature Importance

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 126–128

Random Forest ทำงานอย่างไร

- สร้าง Decision Tree หลายต้นจากข้อมูล/ตัวแปรที่สุ่มแตกต่างกัน
- รวมผลการพยากรณ์ของหลายต้นไม้เพื่อลดความแปรปรวน

อ่าน Feature Importance

- ค่ามาก = feature มีส่วนร่วมต่อการตัดสินใจของโมเดลมากกว่าในโมเดลนี้
- จากภาพ: worst concave points = 15.0% สูงสุด

ข้อจำกัดของ Feature Importance

- Importance ไม่ได้ชี้นัยความเป็นเหตุและผล (Causality)
- Importance ต่ำไม่แปลว่า feature ไม่มีประโยชน์ในทุกโมเดล และ 15% ไม่ใช่ Accuracy 15%

Model Comparison: เลือก Metric ให้ตรงกับต้นทุนของความผิดพลาด

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 129–131

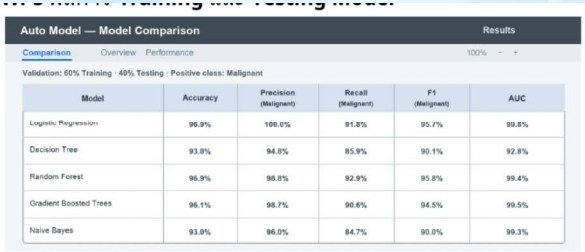

Model	Accuracy	Precision (Malignant)	Recall (Malignant)	F1 (Malignant)	AUC
Logistic Regression	96.9%	100.0%	91.8%	95.7%	99.8%
Decision Tree	93.0%	94.8%	85.9%	90.1%	92.8%
Random Forest	96.9%	98.8%	92.9%	95.8%	99.4%
Gradient Boosted Trees	96.1%	98.7%	90.6%	94.5%	99.5%
Naive Bayes	93.0%	96.0%	84.7%	90.0%	99.3%

เมื่อต้องลด False Negative

- ให้ความสำคัญกับ Recall ของ Positive Class
- ในตาราง Random Forest มี Recall 92.9% สูงสุด

เมื่อต้องลด False Positive

- ให้ความสำคัญกับ Precision
- Logistic Regression มี Precision 100.0% และ Recall 91.8%

Accuracy เท่ากัน ไม่ได้แปลว่าเหมือนกัน

- Decision Tree และ Naive Bayes มี Accuracy 93.0% เท่ากัน แต่ AUC ต่างกัน
- จึงต้องพิจารณา metric หลายมิติ

AUC ช่วยอะไร

- วัดความสามารถจัดอันดับ Positive เหนือ Negative โดยรวมหลาย threshold
- ใช้เสริม Accuracy / Precision / Recall ไม่ใช่แทนทุก metric

Confusion Matrix: อ่าน TP, TN, FP, FN และคำนวณ Metric สำคัญ

ภาคทบทวนเพิ่มเติมสำหรับข้อสอบ ส่วนที่ 7 Data Model และส่วนที่ 8 Evaluation

ครอบคลุม 132–133, 139–140

ค่าจาก Random Forest

- TN = 142, FP = 1, FN = 6, TP = 79
- Accuracy = (TP+TN)/N = 221/228 = 96.9%
- Precision = TP/(TP+FP) = 79/80 = 98.8%
- Recall = TP/(TP+FN) = 79/85 = 92.9%
- Specificity = TN/(TN+FP) = 142/143 = 99.3%
- FNR = FN/(TP+FN) = 6/85 = 7.1%

F1-Score

- F1 = 2 × Precision × Recall ÷ (Precision + Recall)
- = 2(98.8)(92.9) ÷ 191.7 ≈ 95.8%

การอ่าน "ส่งเคสที่ทำนาย Malignant ไปตรวจเพิ่ม"

- Prediction = Malignant มีทั้งหมด 80 ราย
- ในนั้น Malignant จริง 79 ราย (TP) และ Benign จริง 1 ราย (FP)

Baseline Accuracy และ Cost-sensitive Evaluation

ครอบคลุม 134–135

Baseline: ทายทุกเคสเป็น Benign

- Benign จริง = 143 จาก Testing 228
- Baseline Accuracy = 143/228 ≈ 62.7%
- Random Forest Accuracy = 96.9%
- เพิ่มขึ้น ≈ 34.2 จุดเปอร์เซ็นต์ (96.9 − 62.7)

Cost-sensitive: ความผิดพลาดมีต้นทุนไม่เท่ากัน

- กำหนด Cost(FN) = 10 หน่วย, Cost(FP) = 1 หน่วย
- Random Forest มี FN = 6 และ FP = 1
- Total Error Cost = 6×10 + 1×1 = 61 หน่วย

หลักคิด: โมเดลที่ Accuracy สูงที่สุดอาจไม่ใช่โมเดลที่ "ต้นทุนความผิดพลาด" ต่ำที่สุด

ใช้เมื่อใด

- ใช้ Baseline เพื่อพิสูจน์ว่าโมเดลดีกว่าวิธีง่าย ๆ อย่างมีนัยสำคัญเชิงปฏิบัติ
- ใช้ Cost-sensitive Evaluation เมื่อ FN และ FP ส่งผลกระทบทางธุรกิจ/คลินิกต่างกัน

Threshold: เปลี่ยนจุดตัดแล้ว Prediction, Recall และ Precision เปลี่ยนได้

ครอบคลุม 136–138

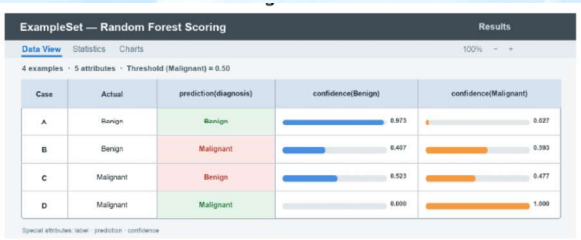
ExampleSet — Random Forest Scoring

Results

Data View Statistics Charts

4 examples · 5 attributes · Threshold (Malignant) = 0.50

Case	Actual	prediction(diagnosis)	confidence(Benign)	confidence(Malignant)
A	Benign	Benign	0.973	0.027
B	Benign	Malignant	0.407	0.593
C	Malignant	Benign	0.523	0.477
D	Malignant	Malignant	0.000	1.000

Special attributes: label · prediction · confidence

Case B: confidence(M) = 0.593

- ที่ threshold 0.50 ⟶ Malignant
- ถ้าเพิ่ม threshold เป็น 0.60 ⟶ 0.593 < 0.60 จึงเปลี่ยนเป็น Benign

Case C: confidence(M) = 0.477

- ที่ threshold 0.50 ⟶ Benign
- ถ้าลด threshold เป็น 0.45 ⟶ 0.477 > 0.45 จึงเปลี่ยนเป็น Malignant

ลด Threshold

- พยากรณ์ Positive มากขึ้น
- Recall มักเพิ่ม / FN มักลด
- Precision อาจลด / FP อาจเพิ่ม

เพิ่ม Threshold

- พยากรณ์ Positive น้อยลง
- Precision อาจเพิ่ม / FP อาจลด
- Recall อาจลด / FN อาจเพิ่ม