การเตรียมข้อมูลสุขภาพหัวใจ

Workshop 4 Data Preparation ชุดข้อมูลปี 2020

งานนีตรวจคุณภาพ heart_2020_cleaned.csv และสร้างข้อมูลทีทำซ้าได้สำหรับ Workshop 5 โดยรักษาคำตอบและจำนวนผู้ตอบครบเดิม ผลเตรียมผ่าน AI Studio native engine แบบ official batch ตรวจแล้วว่าครบ 319,795 แถว 19 คอลัมน์ และค่าเดิมทุกช่องไม่เปลียน ส่วนการใช้ Turbo Prep และภาพหน้าจอ GUI ยังรอหลักฐานจริง

ขอบเขตและข้อมูลต้นทาง

เลือกไฟล์ปี 2020 จาก Dataset ทีอาจารย์โพสต์ตามขอบเขตทีผู้ใช้อนุมัติ ไม่อ้างว่า Classroom ระบุเวอร์ชันนีโดยละเอียด เป้าหมาย HeartDisease เป็นการจำแนกคำตอบประวัติโรคหัวใจย้อนหลัง เป็น label Yes/No ไม่ใช่วันเกิดโรคในอนาคต

รายการ	ก่อนเตรียม	หลังเตรียม
ระเบียน	319,795	319,795
คอลัมน์	18	19
ค่าว่างจริง	0	0
Yes	27,373	27,373
No	292,422	292,422
แถวซ้าทุกคอลัมน์	18,078	18,078

เก็บต้นฉบับทัง bytes ไว้ data/heart_2020_cleaned.csv และสำเนาชือเดิมข้าง .rmp ไฟล์ heart_2020_prepared.csv เป็นผลเตรียมทีแยกออกมา มีตัวแปรใหม่ AnyUnhealthyDays โดยคอลัมน์เดิมทุกค่าและ Target ไม่เปลียน

เหตุผลการจัดการคุณภาพ

ไม่เติมค่าว่างเพราะไม่พบค่าว่าง ไม่ลบ 18,078 แถวทีมีค่าตรงกันทุกช่องเพราะข้อมูลไม่มีรหัสผู้ตอบ คนต่างคนอาจมี profile เดียวกัน การลบอาจเปลียนน้ำหนักเชิงจำนวนของคำตอบ สำหรับการแบ่งโมเดลจะจัด profile ทีมี inputs เหมือนกันไว้ชุดเดียวกันเพือป้องกันการปะปนข้าม train/test

ค่าปลายของ BMI และซัวโมงนอนไม่ถูกลบโดยอัตโนมัติ เกณฑ์ IQR ใช้ระบุค่าทีควรทบทวน ไม่ได้พิสูจน์ว่าค่าทางสุขภาพผิด จึงเก็บค่าเดิมและบันทึกจำนวน flag

พจนานุกรมข้อมูล

ตัวแปร	ชนิด	ความหมาย
HeartDisease	หมวดหมู่ 2 ค่า	ประวัติโรคหัวใจตามคำตอบแบบสำรวจ Yes เป็น positive class
BMI	ตัวเลข	ดัชนีมวลกายตามไฟล์
Smoking	Yes หรือ No	ประวัติสูบบุหรี่ตามคำถามแบบสำรวจ
AlcoholDrinking	Yes หรือ No	การดื่มหนักตามตัวแปรแบบสำรวจ
Stroke	Yes หรือ No	ประวัติโรคหลอดเลือดสมองตามคำตอบ
PhysicalHealth	ตัวเลข	จำนวนวันที่สุขภาพกายไม่ดีใน 30 วันที่ผ่านมา
MentalHealth	ตัวเลข	จำนวนวันที่สุขภาพจิตไม่ดีใน 30 วันที่ผ่านมา
DiffWalking	Yes หรือ No	มีความลำบากในการเดินหรือขึ้นบันได
Sex	หมวดหมู่	Female หรือ Male ตามไฟล์
AgeCategory	หมวดหมู่	ช่วงอายุ 13 ระดับจาก 18–24 ถึง 80 or older
Race	หมวดหมู่	กลุ่มเชื้อชาติ 6 ระดับตามไฟล์
Diabetic	หมวดหมู่	4 ค่า รวม borderline และ during pregnancy ไม่ยุบเป็น 2 ค่า
PhysicalActivity	Yes หรือ No	การมีกิจกรรมทางกายตามแบบสำรวจ
GenHealth	หมวดหมู่	การประเมินสุขภาพทั่วไป 5 ระดับ
SleepTime	ตัวเลข	ชั่วโมงการนอนตามคำตอบ
Asthma	Yes หรือ No	ประวัติหอบหืดตามคำตอบ
KidneyDisease	Yes หรือ No	ประวัติโรคไตตามคำตอบ
SkinCancer	Yes หรือ No	ประวัติมะเร็งผิวหนังตามคำตอบ
AnyUnhealthyDays	หมวดหมู่ 2 ค่า	Yes เมื่อ PhysicalHealth>0 หรือ MentalHealth>0 สร้างโดยไม่ใช้ Target

ผลตรวจตัวเลขและค่าผิดปกติ

ตัวแปร	ต่ำสุด	มัธยฐาน	สูงสุด	IQR flags
BMI	12.02	27.34	94.85	10,396
PhysicalHealth	0	0	30	47,146
MentalHealth	0	0	30	51,576
SleepTime	1	7	24	4,543

สูตร flag คือค่าต่ำกว่า Q1 − 1.5×IQR หรือสูงกว่า Q3 + 1.5×IQR ไม่มีการ winsorize หรือ drop แถว พบ BMI ตั้งแต่ 12.02 ถึง 94.85 และ SleepTime 1 ถึง 24 ชั่วโมง ซึ่งควรตรวจบริบทต้นทาง แต่ไม่มีหลักฐานรายแถวว่าผิด จึงยังไม่แก้ค่า

การตรวจตรรกะพบ 0 แถวที่ BMI≤0, PhysicalHealth/MentalHealth อยู่นอก 0–30 วัน หรือ SleepTime อยู่นอก 0–24 ชั่วโมง ตัวเลขนี้เป็นการตรวจขอบเขตค่าตอบ ไม่ใช่การรับรองความถูกต้องทางการแพทย์

การเปลี่ยนแปลงที่ทำจริง

ขั้นตอน	แถวหลังขั้นตอน	การดำเนินการ
นำเข้าต้นฉบับ	319,795	อ่าน comma CSV และตรวจชนิด
ค่าว่างและแถวซ้ำ	319,795	ตรวจและเก็บทุกแถวตามเหตุผล
Outlier	319,795	บันทึก flags ไม่ตัดค่า
สร้าง AnyUnhealthyDays	319,795	Yes ถ้ามี PhysicalHealth>0 หรือ MentalHealth>0
ส่งต่อ Workshop 5	319,795	เพิ่ม fixed group split แยกใน modeling CSV

ตรวจแล้วว่า prepared CSV รักษาคอลัมน์เดิมทุกค่าและ Target counts ครบเดิม SHA-256 ของต้นฉบับกับสำเนาตรงกัน Feature ใหม่สร้างโดยไม่ใช้ Target

ผล native และหลักฐานที่ยังต้องทำ

AI Studio 2026.1.1 official batch รัน RMP สำเร็จวันที่ 11 ตุลาคม 2026 ได้ heart_2020_prepared_native.csv ผลตรวจยืนยันค่าเดิมทั้งหมดและ AnyUnhealthyDays ทุกแถว บันทึกอยู่ใน native_batch.log และ native_batch_verification.json

ย้ายสำเนาไปอีกโฟลเดอร์และรันด้วย native batch สำเร็จ ผล CSV ตรงกับการรันหลักทุก bytes ต้นฉบับคง bytes เดิม ส่วน Turbo Prep GUI และภาพ process/results ยังรอหลักฐานจริง

แหล่งข้อมูลและบทเรียน

Kamil Pytlak Indicators of Heart Disease Kaggle https://www.kaggle.com/datasets/kamilpytlak/personal-key-indicators-of-heart-disease ใช้ heart_2020_cleaned.csv จำนวน 319,795 ระเบียน ไม่เปลี่ยนเป็นไฟล์ปี 2022 ตามชื่อหน้าปัจจุบัน

CDC BRFSS 2020 https://www.cdc.gov/brfss/annual_data/annual_2020.html และ Summary Matrix of Calculated Variables https://www.cdc.gov/brfss/annual_data/2020/Summary_Matrix_20.html นิยามคำตอบประวัติโรคหัวใจมาจาก coronary heart disease หรือ myocardial infarction

บทเรียน BI06 Data Preparation หน้า PDF 1–3 สไลด์ 1–11 โดยเฉพาะ Data Quality และ Turbo Prep สไลด์ 4 และ 9–11 และขอบเขตที่อนุมัติให้ใช้ข้อมูลที่อาจารย์เคยโพสต์ Classroom ไม่ได้ให้คำสั่งไฟล์หรือจำนวนโมเดลเฉพาะงานนี้