Workshop 6 - เกณฑ์ประเมินโมเดล 5 ข้อ

ตัวอย่างจริง: Naive Bayes จำแนก PATIENT_TYPE จาก COVID Data ใน Mini Project2. Positive class = Hospitalized (รหัส2); Negative class = Outpatient (รหัส1). Positive ในงานนี้หมายถึงประเภทผู้ป่วยที่รับไว้รักษา ไม่ใช่ผลตรวจเชื้อหรือการเสียชีวิต.

โจทย์1.txt ระบุ Precision, Recall, Accuracy, F-Measure และ AUC. รายงานใช้ภาพ native_NB_performance.png และ checkpoint ที่บันทึกจาก Auto Model จริง ไม่สร้างผลการ Run ใหม่. ภาพ GUI แสดง Altair AI Studio Educational2026.1.1; serialized checkpoint มี object version12.1.1.

เกณฑ์	Native mean ±SD (percentage points)	GUI
Precision	71.109069% ± 0.497624	71.1%
Recall	62.068102% ± 0.189530	62.1%
Accuracy	87.950319% ± 0.035857	88.0%
F1	66.280408% ± 0.119428	66.3%
AUC	88.184825% ± 0.139976	88.2%

ตัวเลขด้านบนเป็นค่าเฉลี่ยแบบ robust ของ5holdout batches ที่คงไว้จาก7batches. เป็นการเฉลี่ยตาม batches ไม่ใช่ class macro average และไม่ใช่ five-fold cross-validation. จะเทียบกับค่า pooled จาก confusion counts และ class macro แยกในรายงาน.

แหล่งบทเรียน: BI06 เป็นพื้นฐาน Data Preparation/Turbo Prep; รายการเกณฑ์และตัวอย่าง Evaluation/Confusion Matrix/F1 อยู่ใน BI08. ใช้ตัวอย่าง COVID เป็นบริบทและใช้ผล Naive Bayes จริงของงานนี้เป็นตัวเลข.

Confusion Matrix และความหมายของ counts

รายงานจัดแถวเป็นค่าจริง และคอลัมน์เป็นค่าพยากรณ์ เพื่ออ่านสูตรได้ตรงกัน. ภาพ GUI เดิมแสดงแถวเป็นค่าพยากรณ์และคอลัมน์เป็นค่าจริง ซึ่งเป็นการ transpose ตาราง ไม่ใช่ counts ต่างชุด.

Actual /Prediction	Outpatient (-)	Hospitalized (+)	**รวมจริง**
Outpatient (-)	TN=228,013	FP=14,416	242,429
Hospitalized (+)	FN=21,684	TP=35,480	57,164
รวมพยากรณ์	249,697	49,896	N=299,593

TP: พยากรณ์ Hospitalized และเป็น Hospitalized จริง. FP: พยากรณ์ Hospitalized แต่จริงเป็น Outpatient. FN: พยากรณ์ Outpatient แต่จริงเป็น Hospitalized. TN: พยากรณ์ Outpatient และเป็น Outpatient จริง.

Counts รวมที่ถูกเก็บใน checkpoint เท่ากับ299,593ระเบียน; ROC ของ5batchesรวม positives=57,164และ negatives=242,429ตรงกัน. จำนวนนี้ไม่ใช่จำนวนผู้ป่วยไม่ซ้ำ และไม่ใช่หลักฐานว่าโมเดลทั้ง9ใช้ Testing Set ร่วมกัน.

ค่าจาก countsรวม	การแทนค่า	ผล
Precision	35,480/(35,480+14,416)	71.107904%
Recall	35,480/(35,480+21,684)	62.067035%
Accuracy	(35,480+228,013)/299,593	87.950319%
F1	2×35,480/(2×35,480+14,416+21,684)	66.280590%

1. Precision และ2. Recall

Precision = TP/(TP+FP). ถามว่า ในระเบียนทีโมเดลพยากรณ์เป็น Positive มีส่วนทีเป็น Positive จริงเท่าไร. ตัวหารเป็นจำนวนพยากรณ์ Positive ไม่ใช่จำนวน Positive จริง.

ตัวอย่าง pooled: ใน49,896ระเบียนทีพยากรณ์ Hospitalized มี35,480ระเบียนเป็น Hospitalized จริง จึงได้ Precision=71.107904%. Native batch mean=71.109069% และ GUIปัดเป็น71.1%.

Recall = TP/(TP+FN), เรียก Sensitivity หรือ True Positive Rate. ถามว่า ใน Positive จริงทังหมด โมเดลค้นพบถูกต้องเท่าไร. ตัวหารเป็นจำนวน Positive จริง.

ตัวอย่าง pooled: Hospitalizedจริง57,164ระเบียน ค้นพบถูก35,480ระเบียน จึงได้ Recall=62.067035%. ยังมี FN=21,684ระเบียน หรือ37.9330%ของPositiveจริงทีพยากรณ์เป็นOutpatient. Native mean=62.068102% และ GUI62.1%.

ประเด็น	Precision	Recall
ตัวหาร	TP+FP: พยากรณ์Positive	TP+FN: Positiveจริง
ความผิดพลาดทีกดค่า	FP มากทำให้ลด	FN มากทำให้ลด
อ่านกรณีนี	ประมาณ71%ของPositiveทีทายเป็นจริง	พบประมาณ62%ของPositiveจริง

เลือกเกณฑ์ให้สัมพันธ์กับต้นทุนความผิดพลาดตามโจทย์: ต้องตรวจ FP เมือสนใจความน่าเชือถือของผล Positive และต้องตรวจ FN เมือสนใจ Positive ทีพลาด. ตัวเลขไม่บอกเหตุผลเชิงสาเหตุหรือความเหมาะสมในการใช้งานใหม่โดยตัวมันเอง.

3. Accuracy และ4. F-Measure /F1

Accuracy = (TP+TN)/(TP+TN+FP+FN). เป็นสัดส่วนพยากรณ์ถูกทั้งหมด รวมทั้งสองคลาส.

ตัวอย่าง pooled: (35,480+228,013)/299,593 = 87.950319%. Native robust mean=87.950319%, GUI88.0%. ในcountsชุดนี หากพยากรณ์ทุกระเบียนเป็นOutpatientจะได้ baseline=242,429/299,593=80.9194% จึงไม่ควรใช้ Accuracy เพียงค่าเดียวกับคลาสทีไม่สมดุล.

F1 = 2×Precision×Recall/(Precision+Recall) = 2TP/(2TP+FP+FN). เป็น harmonic mean ทีรวม Precision และRecall; ไม่ใช่ (Precision+Recall)/2.

ตัวอย่าง pooled: 70,960/107,060 = 66.280590%. Native mean F1=66.280408%, GUI66.3%.

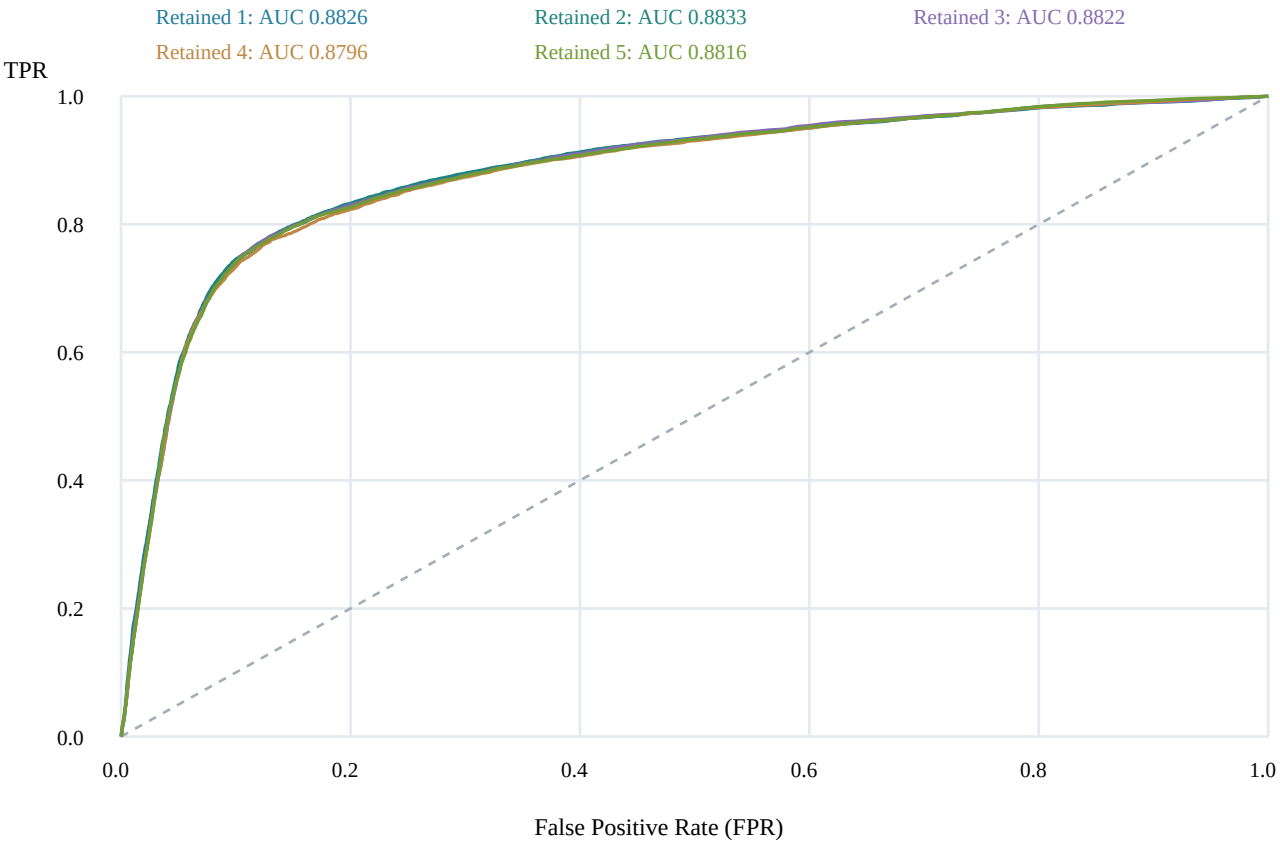
F1จากP/Rทีเฉลียแล้ว = 66.281705% ซึงต่างจากค่าเฉลียF1จริง. ต้องคำนวณF1ของแต่ละbatchก่อนเฉลีย เพราะสูตรเป็น nonlinear; ไม่แทนค่า meanP/meanRแล้วเรียกว่าค่าnativeเดียวกัน.

SD ที GUI Accuracy แสดง ±0.0% ไม่ได้แปลว่า SDเป็นศูนย์: checkpoint มี SD=0.035857percentage points ก่อนปัด. SDสะท้อนความแตกต่างใน5batches ไม่ใช่ confidence interval ของ Accuracy.

5. Area Under Curve (AUC-ROC)

ROC วางแกนY = TPR = TP/(TP+FN) และแกนX = FPR = FP/(FP+TN). เปลียน threshold แล้วได้หลายจุด; AUC คือพืนทีใต้เส้น ROC. ไม่ใช่ Accuracy และหาไม่ได้จาก confusion matrix ของ threshold เดียว.

สูตรพืนทีแบบ trapezoid: AUC = Σ (FPR[i]-FPR[i-1])×(TPR[i]+TPR[i-1])/2.
AUCวัดการจัดอันดับคะแนนPositiveเทียบNegative. สำหรับคะแนนเสมอกัน Altair AUCแบบneutralใช้ค่าเฉลียของ optimistic และpessimistic.



รูปด้านบนวาดใหม่จากจุด ROC จริงใน native checkpoint ทัง5ชุด ไม่ใช่ภาพหน้าจอ GUIหรือเส้นสมมติ. ชือRetained1-5ใช้แสดงลำดับทีเก็บ ไม่ใช่หมายเลขfold. คำนวณพืนทีจากทุกจุดก่อนลดจำนวนจุดเพือวาดรูป.

ROC retained batch	AUCคำนวณจากจุดจริง	Positive /Negative
1	0.882562017	11,404 / 48,515
2	0.883273156	11,582 / 48,337
3	0.882249301	11,405 / 48,514
4	0.879600764	11,388 / 48,530
5	0.881556015	11,385 / 48,533
mean	0.881848251	averageCount=5

ค่าเฉลียพืนทีตรงกับnative AUC=0.881848251; GUIแสดง88.2%.
ค่า0.5เป็นระดับการจัดอันดับสุ่มในความหมายROC; ค่า0.881848ไม่ได้หมายถึงทายถูก88.1848%ของระเบียน.

การเฉลีย3แบบทีต้องแยกให้ชัด

1) Native robust batch mean: คำนวณ metricแต่ละbatchแล้วให้นำหนักเท่ากันใน5ชุดทีคงไว้. mean=meanSum/averageCount; SD=sqrt((meanSquaredSum-meanSum²/k)/(k-1)), k=5. ค่า GUI Performance ใช้วิธีนี.

2) Pooled positive-class metric: รวม TP/FP/FN/TNทีเก็บ แล้วค่อยคำนวณสูตรของHospitalized. ตัวหารและการให้นำหนักต่างจากmeanของอัตราส่วน จึงต่างเล็กน้อยได้โดยไม่ใช่ข้อผิดพลาด.

3) Class macro: คำนวณ Precision/Recall/F1ของHospitalizedและOutpatientแยกกันแล้วเฉลียสองคลาสเท่ากัน. Macro F1=(F1Hospitalized+F1Outpatient)/2 ไม่ใช่ F1จากmacroP/R.
ค่าเหล่านีด้านล่างคำนวณเพิมจากcountsจริง แต่ไม่ได้อ้างว่าเป็นค่าใน GUI.

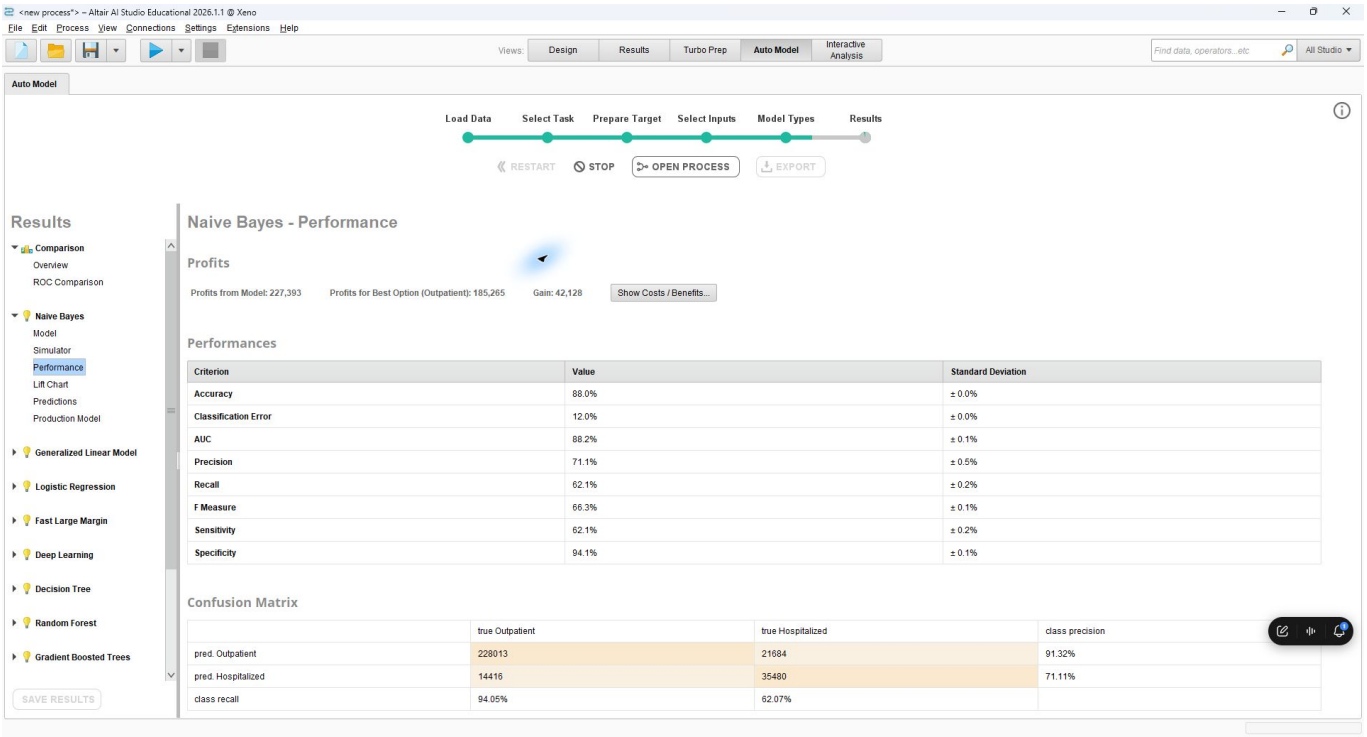
Metric	Native batch mean	PooledHospitalized	Class macro
Precision	71.109069%	71.107904%	81.211890%
Recall	62.068102%	62.067035%	78.060276%
F1	66.280408%	66.280590%	79.472535%
Accuracy	87.950319%	87.950319%	ไม่ใช้class-macroaccuracy
AUC	0.881848251	CMเดียวคำนวณไม่ได้	ไม่ได้คำนวณclassmacroAUC

เพิมเติม: micro averagingข้ามทังสองคลาสรวม TP/FP/FNของทุกคลาสก่อนคำนวณ. สำหรับ single-label classificationนี microPrecision=microRecall=microF1=Accuracy=87.950319%. ไม่ใช่ pooledHospitalizedPrecision71.1079%. การเรียกทุกแบบว่าmacroหรือmicroโดยไม่ระบุขอบเขตจึงทำให้สรุปผิด.

ตัวอย่างนีไม่ใช้ผลdefault9โมเดลเพือเลือกผู้ชนะบนTestingSetร่วมกัน: native auditยืนยันว่ามี initial sample capsและจำนวนconfusion recordsไม่เท่ากัน. งานcommon-holdoutของMini2ยังเป็นอีกขันตอนหนึง; รายงานWS6นีไม่ได้ประกาศว่างานนันเสร็จแล้ว.

หลักฐาน native และการตรวจซ้ำ

ภาพทีใช้คือnative_NB_performance.pngจากMini Project2 โดยคัดลอกเหมือนต้นฉบับทุกbyte. CountsทีมุมตารางและmetricทีGUIปัดหนึงตำแหน่ง ตรงกับcheckpoint. ผู้จัดทำWS6ไม่ได้ทำnativeRunใหม่หรือสร้างภาพหน้าจอแทนของจริง.



ภาพต้นฉบับจริง: UIชือNaive Bayes - Performance. ด้านล่างขยายส่วนPerformanceและConfusion Matrixจากภาพเดียวกันโดยไม่ปรับตัวเลข.

Criterion	Value	Standard Deviation
Accuracy	88.0%	± 0.0%
Classification Error	12.0%	± 0.0%
AUC	88.2%	± 0.1%
Precision	71.1%	± 0.5%
Recall	62.1%	± 0.2%
F Measure	66.3%	± 0.1%
Sensitivity	62.1%	± 0.2%
Specificity	94.1%	± 0.1%

	true Outpatient	true Hospitalized	class precision
pred. Outpatient	228013	21684	91.32%
pred. Hospitalized	14416	35480	71.11%
class recall	94.05%	62.07%	

แหล่งข้อมูลและวิธีตรวจความถูกต้อง

รายการงาน: Workshop6/1.txt ระบุเกณฑ์ทั้ง5. Presentation/BI06 Data Preparation.pdf, PDFpages1-3 เป็นพื้นฐานDataPreparation/TurboPrep. Presentation/BI08 Data Model and Evaluation.pdf, PDFpage19/printedslide77 ให้บริบทF1; PDFpage20/printedslides85-86 ให้การเลือกmetricและConfusionMatrix; page21/slides87-88 ให้baselineและthreshold. ตัวอย่างบางslideเป็นคนละdataset จึงใช้เฉพาะแนวคิด.

ตัวเลขจริงมาจากNative_AI_Repository/MiniProject2_AutoModel_9Models/Naive Bayes/Performance.rmperf. อ่านaveragesListโดยชนิดcriterionและtypecode แทนการเดาชื่อ: Accuracy=MultiClassificationPerformance/type0; Precision=BinaryClassificationPerformance/type0; Recall/type1; F1/type4; AUC=AreaUnderCurve$Neutral.

ตรวจ meanSum/5 และsampleSDกับnative_result_audit.json; ตรวจsum4cells=299593; ตรวจจำนวนpositive/negativeรวมจากROC5ชุดตรงกับmatrix; คำนวณAUCจากทุกROCpointแล้วตรวจmeanตรงnativeภายใน1e-12. แยกnative mean, pooled, classmacroและmicroไว้ในsupport/metrics_verification.json.

เอกสารสูตรทางการ: Altair/RapidMiner Performance (Binominal Classification): https://docs.rapidminer.com/latest/studio/operators/validation/performance/predictive/performance_binominal_classification.html

นิยามclass macro/microเพิ่มเติม: scikit-learn model evaluation (ใช้เป็นนิยามเท่านั้น ไม่ได้ฝึกโมเดลPythonแทนnative): https://github.com/scikit-learn/scikit-learn/blob/main/doc/modules/model_evaluation.rst

ขอบเขตงาน: มีPDF/README/ภาพจริงและผลตรวจคำนวณสำหรับWorkshop6. ไม่เปลี่ยนMini2/raw/native repository, ไม่ทำGUI/Runใหม่, ไม่ส่งข้อมูลหรือเผยแพร่. การเปรียบเทียบ9โมเดลด้วยTestingSetเดียวกันและfinalmodelของMini2เป็นงานแยกที่ยังไม่อ้างว่าสำเร็จในรายงานนี้.